

SEMINÁRIO

Previsão de Séries Temporais com Modelagem ARIMA (Box-Jenkins)



Fábio Daros de Freitas

Departamento de Engenharia Elétrica/PPGEE – UFES

Terça-feira, 1 de abril de 2003 - 16:00h

Local: Auditório do CT - UFES

Informações: Prof. Alberto F. Souza- (27) 3335 2641



Previsão de Séries Temporais com Modelagem ARIMA (Box-Jenkins)

Fábio Daros de Freitas

Departamento de Informática - Departamento de Engenharia
Elétrica/PPGEE – UFES



Visão Geral

- Objetivos
- Séries Temporais
- Modelo ARIMA (Box-Jenkins)
- Metodologia Box-Jenkins
- Ferramenta TSTOOL/ARIMA
- Conclusão
- Discussão



Objetivos do Seminário

- Introdução ao modelo ARIMA e à metodologia Box-Jenkins para previsão de séries temporais.
- Apresentar uma implementação de um ambiente para modelagem e previsão ARIMA.
- Modelos **sazonais** não serão abordados.



Séries Temporais

- Séries Temporais
- Séries Temporais e Processos Estocásticos
- Análise de Séries Temporais




Séries Temporais

- Uma série temporal (ST) é uma seqüência de observações tomadas seqüencialmente no tempo em intervalos regulares.

$$\mathbf{Z} = (Z_t, Z_{t-1}, Z_{t-2}, \dots, Z_{t-N})$$

- Exemplo: preços de fechamento de ações na bolsa de valores.

Séries Temporais



369 cotações da ação ordinária da IBM entre 17-MAI-1961 e 2-NOV-1962



Séries Temporais

- Não é uma série temporal:

$$\mathbf{Z} = (Z_t, Z_{t-1}, Z_{t-5}, Z_{t-10})$$

amostragem em intervalos irregulares

- As inferências em ST se dão no mesmo intervalo da amostragem ou, recursivamente, em múltiplos inteiros deste.


$$\mathbf{Z} = (Z_t, Z_{t-10}, Z_{t-20}, \dots)$$

$$\hat{Z}_{t+20} \rightarrow \text{OK!}$$

$$\hat{Z}_{t+5} \rightarrow \text{NÃO!}$$

Séries Temporais e Processos Estocásticos

- Um fenômeno estatístico que evolui no tempo segundo as leis da probabilidade é denominado *processo estocástico*.
- A realização de um processo estocástico é um conjunto de variáveis aleatórias (VA) – o registro temporal dos valores é uma série temporal.





Séries Temporais e Processos Estocásticos

- Processos estocásticos ***estacionários*** são aqueles cujas propriedades estatísticas não se alteram com o deslocamento da origem no tempo.
- Algumas propriedades estatísticas:

- Média: nível sobre o qual o processo oscila

$$\bar{z} = \mu = \frac{1}{N} \sum_{t=1}^N z_t$$

- Variância: espalhamento da oscilação

$$\sigma_z^2 = \frac{1}{N} \sum_{t=1}^N (z_t - \bar{z})^2$$



Séries Temporais e Processos Estocásticos

- Análise de séries temporais

- desenvolve um conjunto de métodos para o **tratamento das séries temporais como a realização de processos estocásticos.**



Modelo ARIMA (Box-Jenkins)

- Visão Geral
- Modelos Lineares Estacionários (ARMA).
- Modelos Lineares Não-Estacionários (ARIMA).

Modelo ARIMA – Visão Geral

- Modelo de séries temporais baseado na estrutura de dependência serial (temporal) da série histórica.
 - dependência serial = influência que um valor (evento) recebe dos valores (eventos) anteriores.

$$x_t = f(x_{t-1}, x_{t-2}, \dots) + K$$

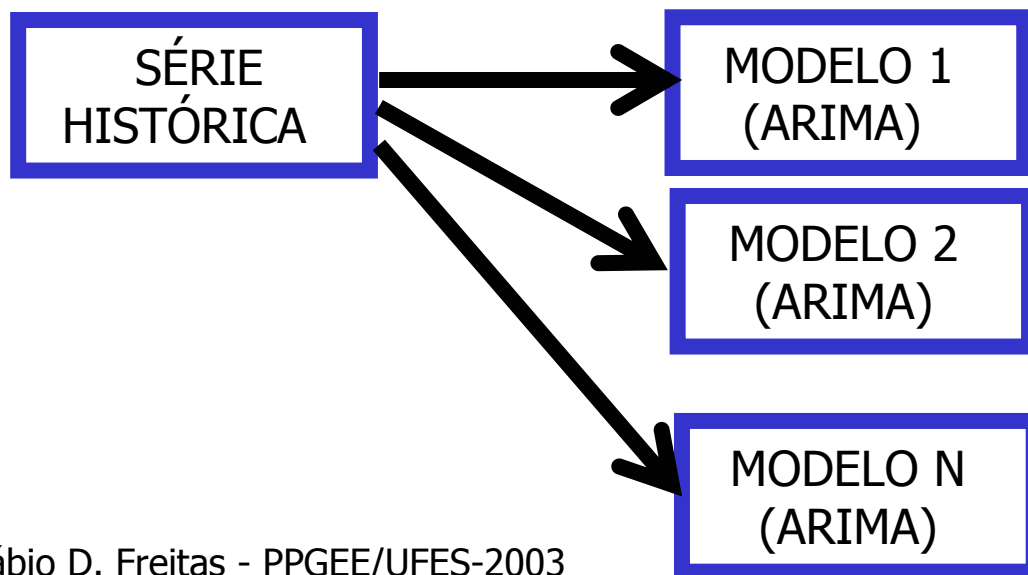
- Nos modelos ARIMA f é **linear em \mathbf{x}** e do tipo:

$$f(x_{t-1}, x_{t-2}, \dots, x_{t-k}) = b_1 x_{t-1} + b_2 x_{t-2} + \dots + \dots b_k x_{t-k} + C$$

onde k é o tamanho (ordem) da dependência serial.


Modelo ARIMA – Visão Geral

- Um modelo é definido pelo conjunto de valores dos parâmetros k , b_1 , b_2 , etc...
- “Modelagem” de uma série histórica é seleção de um modelo a partir dos valores da série, que se aproxime do processo real que gerou a série.
- Uma série histórica pode dar origem a vários modelos.



Modelo ARIMA – Visão Geral

- No escopo da modelagem, os termos *Modelo* e *Processo* são equivalentes – o modelo é uma tentativa de “engenharia reversa” do processo.






Modelo ARIMA – Visão Geral

- ARIMA é uma família de **modelos (processos) lineares estacionários**:
 - $AR(p)$ – Autoregressivo (*autoregressive*)
 - $MA(q)$ – Médias móveis (*moving average*)
 - $ARMA(p, q)$ – Autoregressivo-médias móveis (*autoregressive-moving average*)
- e **não estacionários**
 - $ARIMA(p, d, q)$ – Autoregressivo-Integrado-médias móveis (*autoregressive-integrated-moving average*).
- p, q são os tamanhos das dependências seriais, ou *ordem do modelo*.
- d é o grau da diferenciação da série histórica que garanta sua estacionariedade ► **será visto adiante**.

Modelos Lineares Estacionários

- Representam processos estacionários



Modelos Lineares Estacionários

- AR(p) $\rightarrow \quad \tilde{z}_t = \varphi_1 \tilde{z}_{t-1} + \varphi_2 \tilde{z}_{t-2} + \dots + \varphi_p \tilde{z}_{t-p} + a_t$
- MA(q) $\rightarrow \quad \tilde{z}_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$

$\tilde{z}_t = z_t - \mu$: desvios do processo em relação à sua média .

a_t, a_{t-1}, \dots : resíduo - (ruído branco) distribuição normal, média zero e variância σ_a^2

- ARMA(p, q) = AR(p) “+” MA(q) \rightarrow

$$\tilde{z}_t = \underbrace{\varphi_1 \tilde{z}_{t-1} + \dots + \varphi_p \tilde{z}_{t-p}}_{\text{AR(p)}} + \underbrace{a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}}_{\text{MA(q)}}$$



Modelos Lineares Estacionários

- Operadores em ST:

- Operador *backward shift* (B)

$$B^j z_t = z_{t-j} \quad \left\{ \begin{array}{l} B^0 z_t = z_t \\ B^1 z_t = z_{t-1} \end{array} \right.$$

- Operador *forward shift* (F)

$$F = B^{-1}$$
$$F^j z_t = z_{t+j} \quad \left\{ \begin{array}{l} F^0 z_t = z_t \\ F^1 z_t = z_{t+1} \end{array} \right.$$

Modelos Lineares Estacionários

■ Processo AR(p) – Autoregressivo de ordem p.

- z_t depende linearmente dos seus valores passados.

$$\tilde{z}_t = \phi_1 \tilde{z}_{t-1} + \phi_2 \tilde{z}_{t-2} + \dots + \phi_p \tilde{z}_{t-p} + a_t$$

- Utilizando o operador B:

$$\phi(B) \tilde{z}_t = a_t$$

onde,

$$\phi(B) = 1 - \phi_1 B^1 - \phi_2 B^2 - \dots - \phi_p B^p$$

$\tilde{z}_t = z_t - \mu$: desvios do processo em relação à sua média .

a_t, a_{t-1}, \dots : resíduo - ruído branco : distribuição normal, média zero e variância σ^2



Modelos Lineares Estacionários

- Condição de estacionariedade de AR(p)

- Raízes de $\varphi(B) = 0$
(equação característica do processo)

devem estar fora do círculo unitário complexo.

$$\text{AR}(1): |\phi_1| < 1 \quad \text{AR}(2): \begin{cases} |\phi_2| < 1 \\ \phi_2 + \phi_1 < 1 \\ \phi_2 - \phi_1 < 1 \end{cases}$$

- Condição de invertibilidade de AR(p)

- Invertível para quaisquer φ .



Modelos Lineares Estacionários

- **Processo MA(q) – Médias móveis de ordem q.**
 - z_t depende linearmente dos valores passados dos erros a . O sinal negativo é convenção.

$$\tilde{z}_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$

- Utilizando o operador B:

$$\tilde{z}_t = \theta(B)a_t$$

onde,

$$\theta(B) = 1 - \theta_1 B^1 - \theta_2 B^2 - \dots - \theta_q B^q$$



Modelos Lineares Estacionários

- Condição de estacionariedade de $MA(q)$:
 - Estacionário para quaisquer θ .
- Condição de invertibilidade de $MA(q) \rightarrow$ satisfaz a dualidade dos modelos:
 - Raízes de $\theta(B) = 0$
(equação característica do processo)
devem estar fora do círculo unitário.

$$MA(1): |\theta_1| < 1 \quad MA(2): \begin{cases} |\theta_2| < 1 \\ \theta_2 + \theta_1 < 1 \\ \theta_2 - \theta_1 < 1 \end{cases}$$

Modelos Lineares Estacionários

■ Dualidade entre modelos invertíveis:

- AR(p) pode ser escrito como MA(∞).

$$\phi(B)\tilde{z}_t = a_t \rightarrow \tilde{z}_t = \phi^{-1}(B)a_t$$

$$\text{Ex}^*. \text{AR}(1): \tilde{z}_t = a_t + \phi_1 a_{t-1} + \phi_1^2 a_{t-2} + \phi_1^3 a_{t-3} + \dots$$

- MA(q) pode ser escrito como AR(∞).

$$\tilde{z}_t = \theta(B)a_t \rightarrow \theta^{-1}(B)\tilde{z}_t = a_t$$

$$\text{Ex}^*. \text{MA}(1): \tilde{z}_t = a_t - \theta_1 z_{t-1} - \theta_1^2 z_{t-2} - \theta_1^3 z_{t-3} - \dots$$

(*) Expansão Binomial: $(1+x)^n = 1 + \frac{nx}{1!} + \frac{n(n-1)x^2}{2!} + \frac{n(n-1)(n-2)x^3}{3!} + \dots$

Modelos Lineares Estacionários - ARMA

- Processo ARMA(p,q) - misto
Autoregressivo-Médias Móveis de ordem p ,
 q .

- z_t depende linearmente dos seus valores passados e dos erros a .

$$\tilde{z}_t = \varphi_1 \tilde{z}_{t-1} + \dots + \varphi_p \tilde{z}_{t-p} + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$$

- Utilizando o operador B:

$$\varphi(B)\tilde{z}_t = \theta(B)a_t$$

$\tilde{z}_t = z_t - \mu$: desvios do processo em relação à sua média .

a_t, a_{t-1}, \dots : resíduo - ruído branco : distribuição normal, média zero e variância σ^2

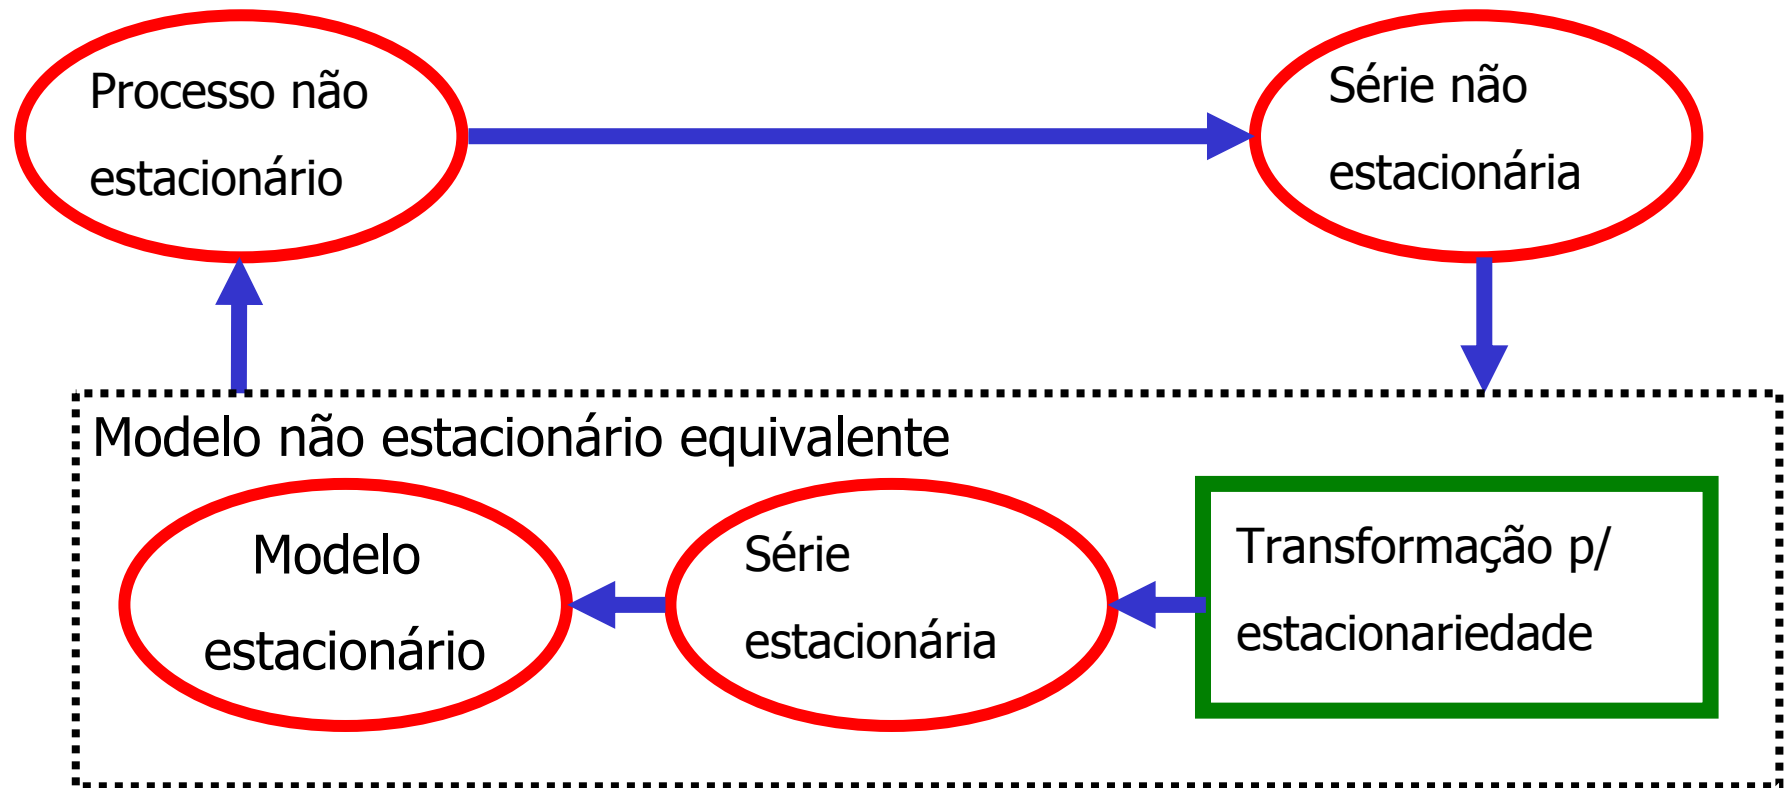


Modelos Lineares Estacionários - ARMA

- Importância do modelo ARMA(p,q):
 - Permite modelar uma série estacionária com menos parâmetros (modelo menor) que um AR(p) ou MA(q).
 $\rightarrow (p_{ARMA} + q_{ARMA}) < p_{AR}, q_{MA}$.
- Condições de estacionariedade e invertibilidade necessárias:
 - Raízes de $\phi(B) = 0$ e $\theta(B) = 0$ fora do círculo unitário complexo.

Modelos Lineares Não Estacionários

- Representam processos não estacionários





Modelos Lineares Não Estacionários

- Operador *d-diferenças* (∇ nabla)

$$\nabla^d = (1 - B)^d \quad \left\{ \begin{array}{l} \nabla^0 z_t = z_t \\ \nabla^1 z_t = z_t - z_{t-1} \\ \nabla^2 z_t = z_t - z_{t-2} \end{array} \right.$$



Modelos Lineares Não Estacionários

- Exemplo:

- Expressão recursiva para o operador de diferenças.

$$\nabla z_t = (1 - B)z_t = z_t - z_{t-1}$$

$$\begin{aligned}\nabla^2 z_t &= (1 - B)^2 z_t = (1 - B)(1 - B)z_t \\ &= (1 - B)(z_t - z_{t-1}) = (z_t - z_{t-1}) - (z_{t-1} - z_{t-2})\end{aligned}$$

.

$$\nabla^d z_t = \nabla^{d-1} z_t - \nabla^{d-1} z_{t-1}$$



Modelos Lineares Não Estacionários

- Operador *soma infinita* (S)

$$Sx_t = \sum_{h=-\infty}^t x_h = (1 + B + B^2 + \dots)x_t$$

$$S^1 = (1 - B)^{-1} = \nabla^{-1}$$

$$S^2 = Sx_t + Sx_{t-1} + Sx_{t-2} + \dots = (1 + 2B + 3B^2 + \dots)x_t$$



Modelos Lineares Não-Estacionários

■ Exemplo:

➤ Tecnicamente, as infinitas somas do operador S não convergem. Portanto, na prática é utilizado o operador finito S_m . Assim, a integração finita utiliza um z_k ($k < t$) como valor inicial.

➤ Para $d=1$ e $m=t-k$ temos:

$$z_t = w_t + w_{t-1} + \dots + w_{k+1} + z_k$$

Modelos Lineares Não Estacionários

■ Obtenção da estacionariedade.

- Se z é uma série não estacionária homogênea*:

$$\mathbf{w} = \nabla^d \mathbf{z} = (\nabla^d z_t, \nabla^d z_{t+1} \dots)$$

é uma **série estacionária!**

- Se \mathbf{z} tem N observações, \mathbf{w} terá $N - d$.
- Analogamente, a série z é obtida pela integração das suas d -diferenças \mathbf{w} .

$$z_t = S^d w_t$$

■ Ainda, temos que:

$$\nabla^d \tilde{z}_t = \nabla^d z_t, \forall d \geq 1$$

(*) apresenta tendência estocástica.

Modelos Lineares Não Estacionários

- $\text{ARIMA}(p, d, q) = \text{ARI}(p, d) \text{ " + " } \text{IMA}(d, q)$

$$\nabla^d z_t = \underbrace{\phi_1 \nabla^d z_{t-1} + \dots + \phi_p \nabla^d z_{t-p}}_{\text{ARI}(p, d)} + \delta + a_t - \underbrace{\theta_1 a_{t-1} - \dots - \theta_q a_{t-q}}_{\text{IMA}(d, q)}$$

$$\phi(B) \nabla^d z_t = \delta + \theta(B) a_t$$

- Ou, em w

$$w_t = \varphi_1 w_{t-1} + \dots + \varphi_p w_{t-p} + \zeta + a_t - \theta_1 a_{t-1} - \dots - \theta_q a_{t-q}$$

$$\varphi(B) w_t = \zeta + \theta(B) a_t$$

ζ é uma constante de nível do modelo.




Modelos Lineares Não Estacionários

- ARIMA(p, d, q)

- O termo *Integrado* faz alusão ao fato da série ***z*** ser obtida pela integração (soma finita em *d* vezes) da séries estacionária ***w***.

ARIMA - Checkpoint 1



- ARIMA(p, d, q)

- $\text{ARIMA}(p, 0, 0) = \text{AR}(p)$
- $\text{ARIMA}(0, 0, q) = \text{MA}(q)$
- $\text{ARIMA}(p, 0, q) = \text{ARMA}(p, q)$
- $\text{ARIMA}(p, d, 0) = \text{ARI}(p, d)$
- $\text{ARIMA}(0, d, q) = \text{IMA}(d, q)$

- Séries não estacionárias $\rightarrow \mathbf{w} = \nabla^d \mathbf{z}$

- Condições de estacionariedade e invertibilidade:
raízes de $\varphi(B) = 0$ fora do círculo unitário. $\theta(B) = 0$



Metodologia Box-Jenkins

- Objetivos
- Etapas da Metodologia
 - Identificação
 - Estimação
 - Diagnóstico
 - *Forecast*



Metodologia Box-Jenkins

- Objetivo: obter parâmetros de modelo que minimizem o erro médio quadrático dos *forecasts*.
- Parâmetros:

p = ordem do operador AR não sazonal

$\phi_1, \phi_2, \dots, \phi_p$ = coeficientes AR

q = ordem do operador MA não sazonal

$\theta_1, \theta_2, \dots, \theta_q$ = coeficientes MA

$\delta = \mu_z (1 - \phi_1 - \phi_2 - \dots - \phi_p)$



Metodologia Box-Jenkins

- Etapas da Metodologia:
 - **Identificação**: define a ordem do modelo e uma primeira aproximação dos parâmetros a partir da série histórica.
 - **Estimação**: obtenção de estimativas eficientes dos parâmetros a partir do modelo identificado e da série histórica.
 - **Diagnóstico**: verificação da qualidade dos parâmetros estimados para o modelo.



Metodologia Box-Jenkins

- Dinâmica da Método:


- Repetir as etapas 2 e 3 (eventualmente 1, 2, e 3) até que o resultado do modelo seja satisfatório.

1. Identificação

2. Estimação

3. Diagnóstico

4. *Forecast*





Identificação

- Objetivos:

- ? Ordem das d -diferenças que torne a série estacionária.
- ? Ordens p e q dos operadores $AR(p)$ e $MA(q)$.
- ? Estimativas iniciais dos parâmetros AR e MA .




Identificação

- Ferramentas:

- Para obter d e q :
 - Análise da Função Autocorrelação Amostral – ACF (*Sample Autocorrelation Function*).
- Para obter p :
 - Análise da Função Autocorrelação Amostral Parcial – PACF (*Sample Partial Autocorrelation Function*).
- Estimativas iniciais de AR(p) e MA(q):
 - Método Box-Jenkins

Função Autocorrelação (ACF)

A ACF mostra como a correlação (dependência serial) entre dois valores z_t e z_{t+k} da série varia com o aumento da distância (lag k) entre eles.




- Fornece uma visão estrutural de dependência serial da série histórica para vários intervalos k .
- *Correlograma* é o gráfico da ACF em função de k .

Função Autocorrelação (ACF)

■ Cálculo dos coeficientes da ACF

$$r_k = \frac{\frac{1}{N} \sum_{t=1}^{N-k} (z_t - \bar{z})(z_{t+k} - \bar{z})}{\sigma_z^2}$$

$$r_0 = 1$$





Função Autocorrelação (ACF)

- Significância estatística dos valores da ACF
 - Erro Padrão (*standard error*) dos coeficientes da ACF - Critério de Bartlett.


$$se_{r_k} = \sqrt{\sigma_{r_k}^2} \Rightarrow \sigma_{r_k}^2 = \frac{1 + 2 \sum_{j=1}^{k-1} r_j^2}{N}$$

$$r_k < 1.96 se_{r_k} \rightarrow r_k \cong 0$$

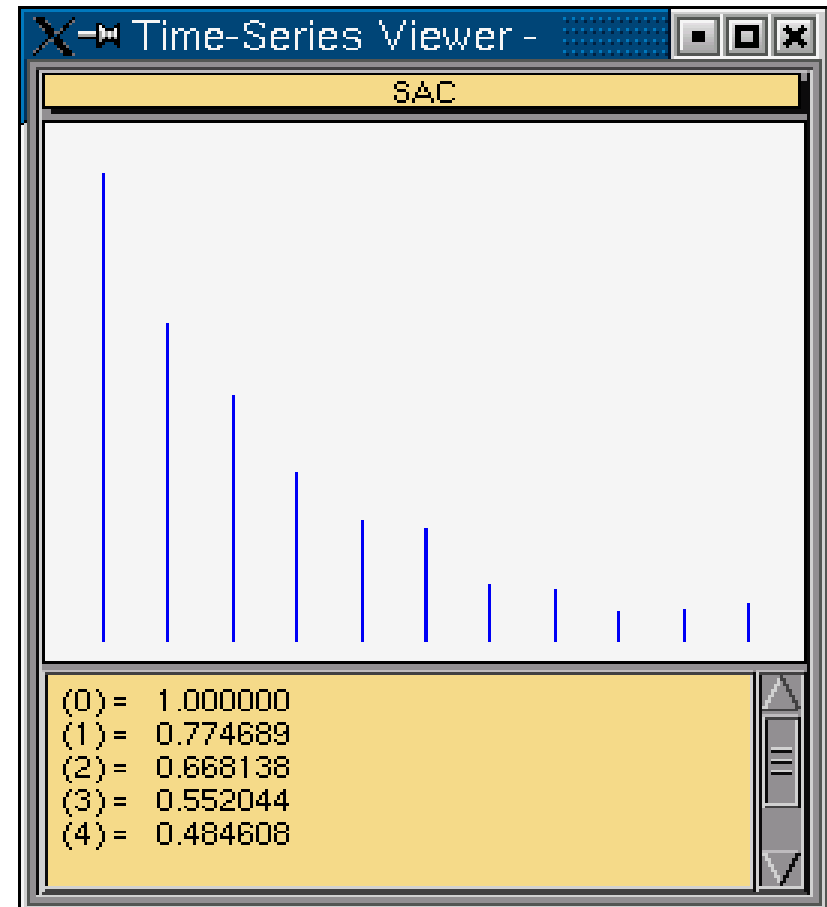
- i.e. valores menores que o SE são desprezados (estatisticamente = 0).

Função Autocorrelação (ACF)

- Comportamentos típicos da ACF (correlograma)



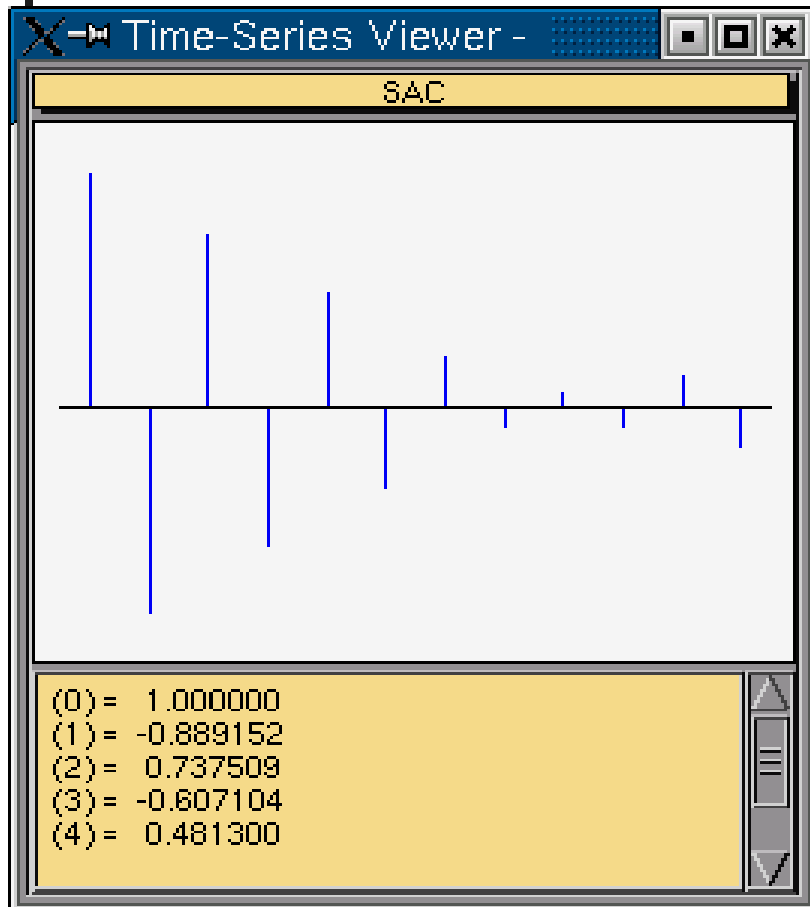
a) com corte no lag k



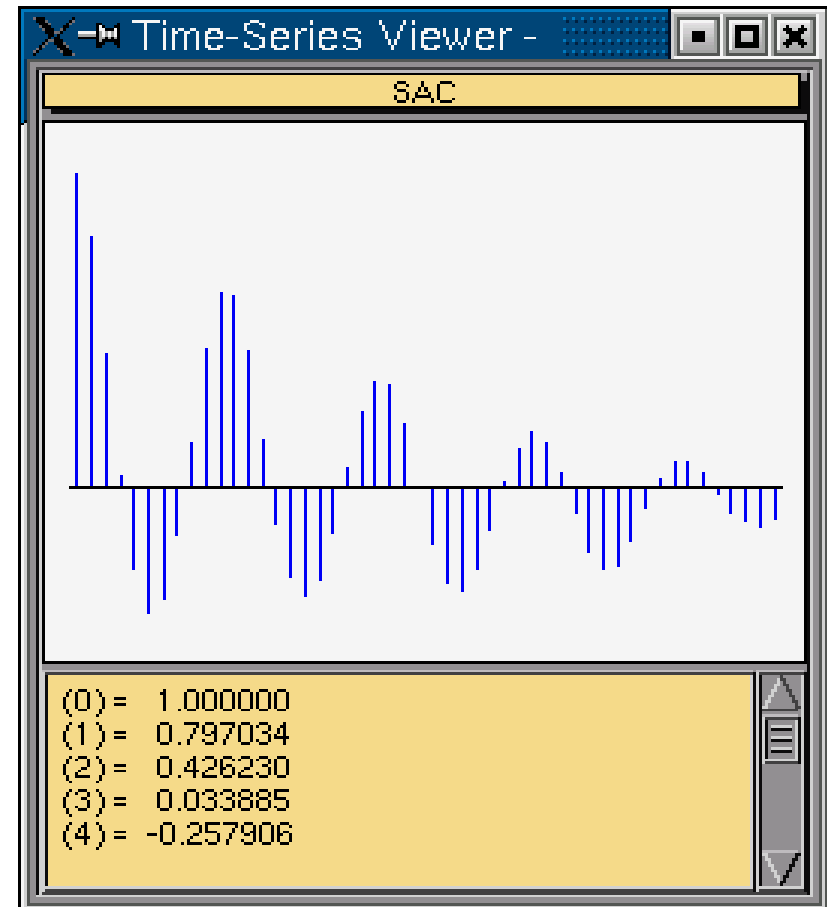
b) amort. exponencial – sem oscilação

Função Autocorrelação (ACF)

- Comportamentos típicos da ACF (correlograma)



c) amort. exponencial – com oscilação



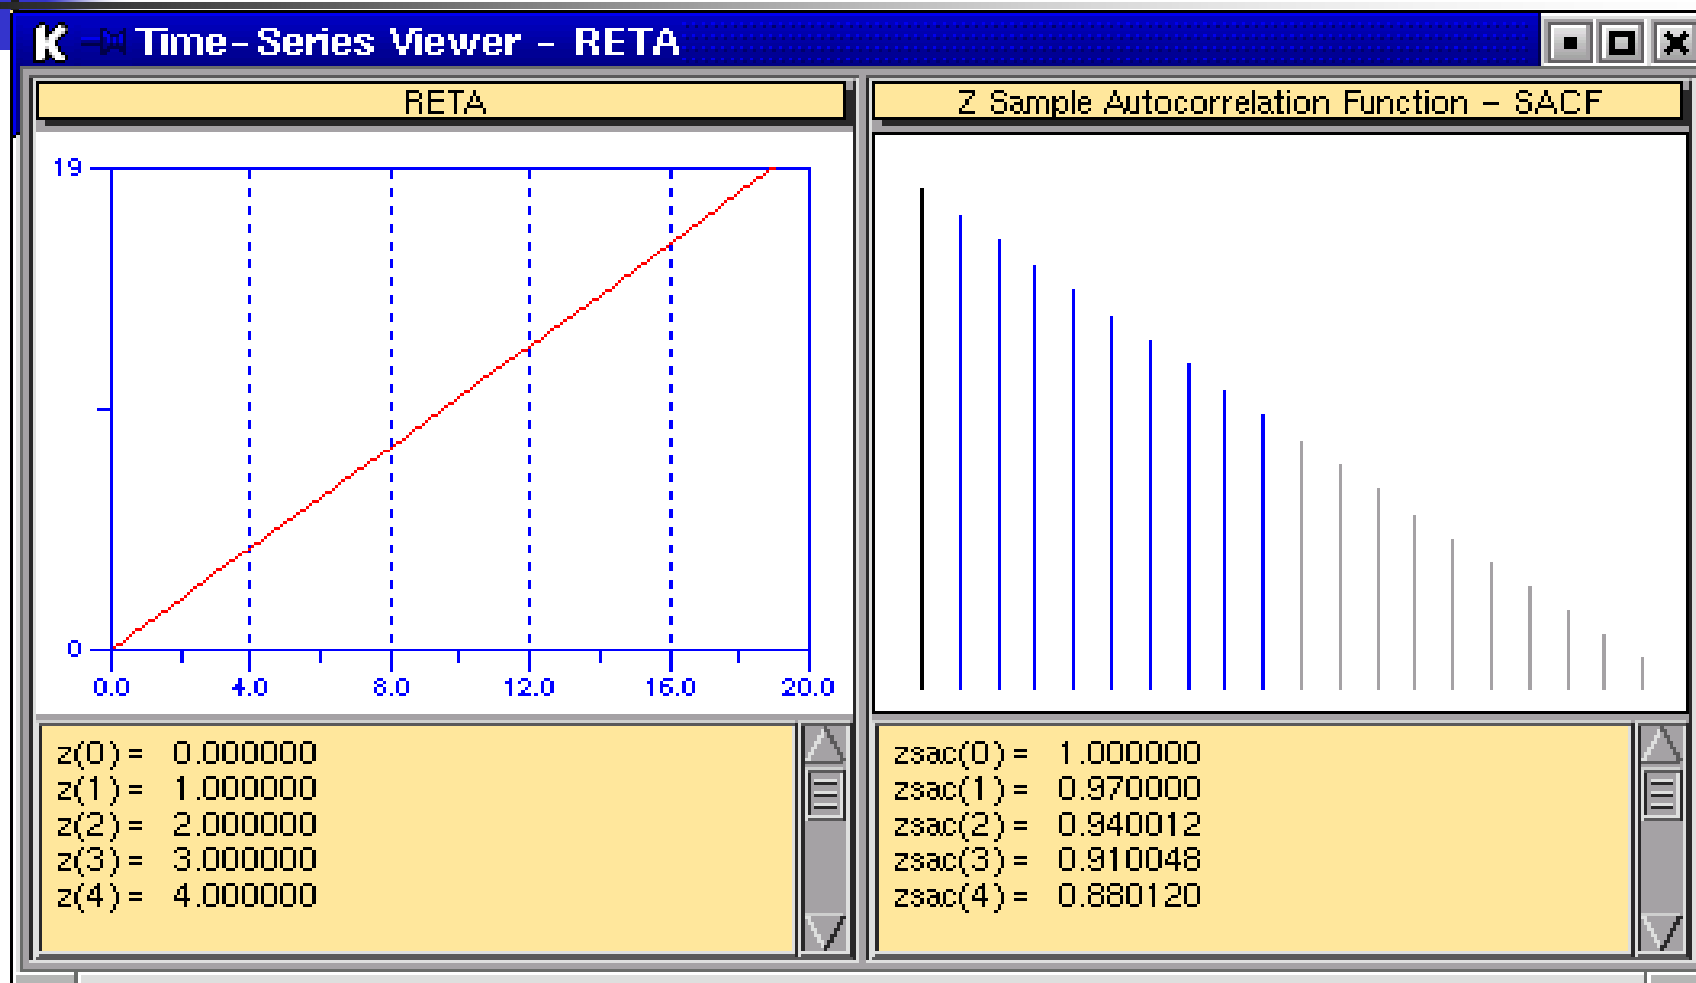
d) amortecimento senoidal



Função Autocorrelação (ACF)

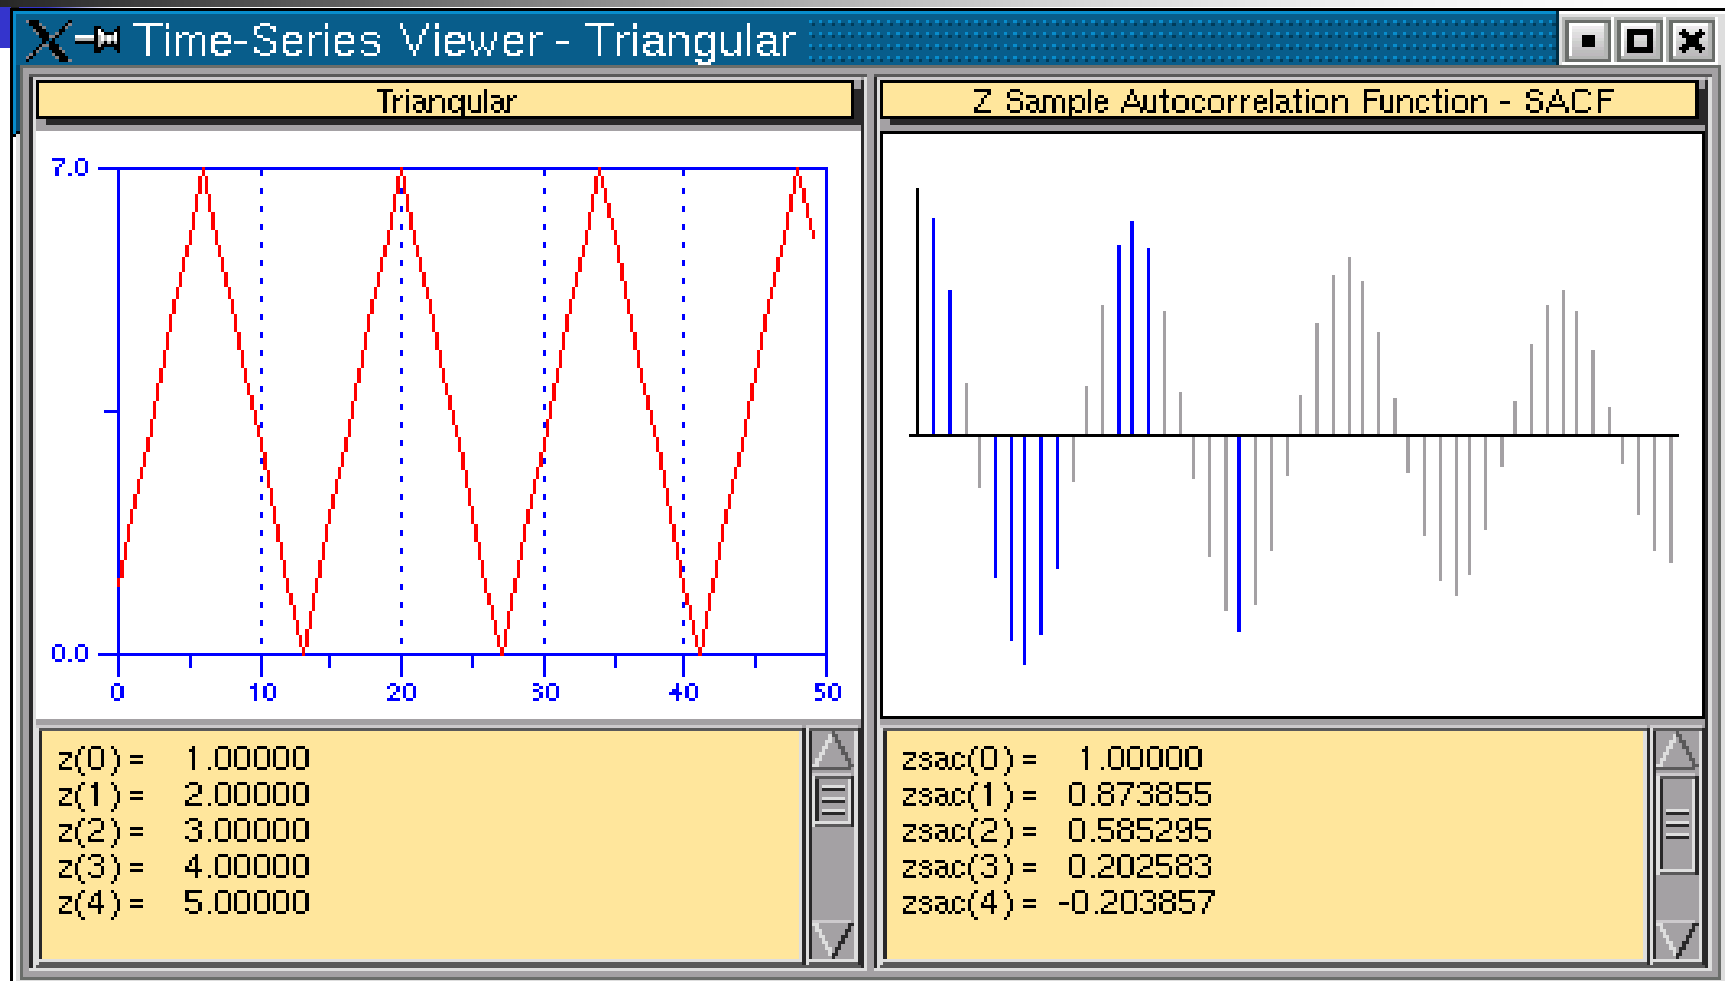
- Estacionariedade da série através do comportamento da ACF:
 - Corte ou amortecimento súbito com ou sem oscilações:
→ série estacionária
 - Amortecimento lento com ou sem oscilações (1º valor próximo a 1):
→ série não estacionária

Função Autocorrelação (ACF)



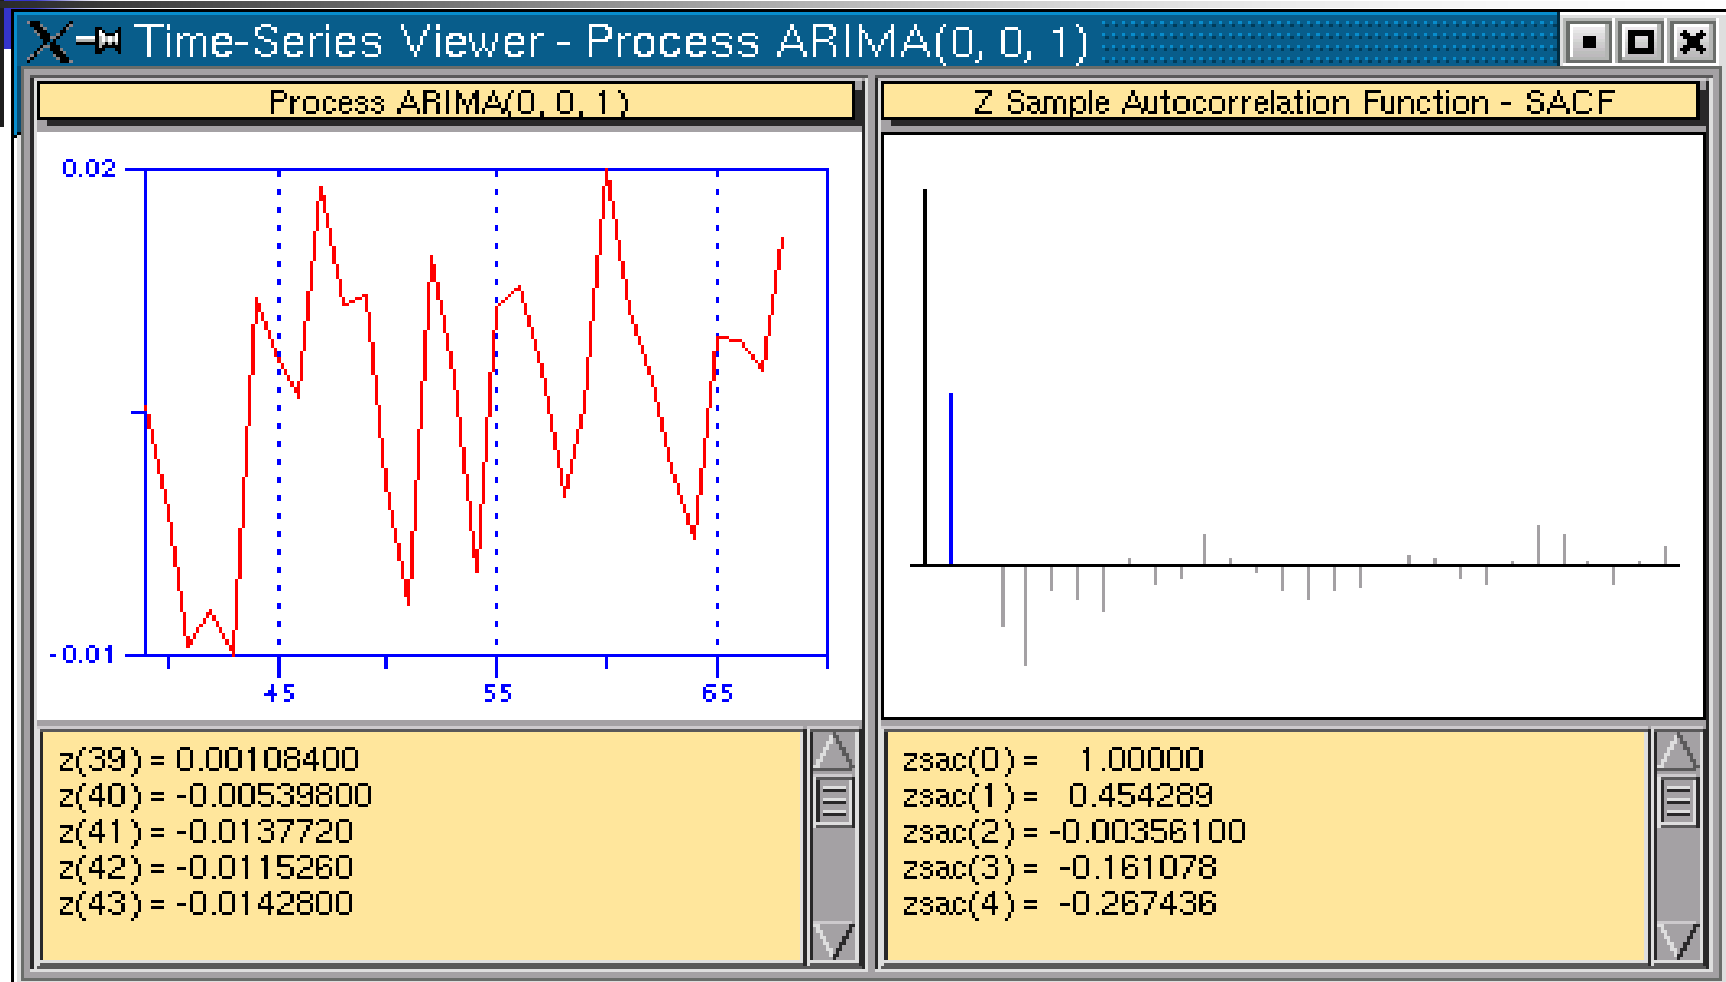
Série Não Estacionária

Função Autocorrelação (ACF)



Série com estacionariedade

Função Autocorrelação (ACF)




Série MA(1) $\Phi = -0.8$ - Estacionária



Função Autocorrelação (ACF)


- **Série não estacionária:** aplica-se o método das diferenças ($d=1, 2, \dots$) até que a nova série torne-se estacionária.
 - Tipicamente $d=0, 1$, ou 2 :
 - $d = 0$ (série original estacionária)
 - $d = 1$ (série original com tendência constante)
 - $d = 2$ (série original com tendência variável no tempo).
 - A ordem ótima da diferenciação geralmente apresenta o menor desvio padrão da série.
 - $d=0$ implica em $\delta \neq 0$ (constante do modelo).
- Usualmente a inspeção das 20 primeiras autocorrelações é suficiente.

Função Autocorrelação (ACF)



Série A (BoxJenkins) - Não Estacionária

Função Autocorrelação (ACF)



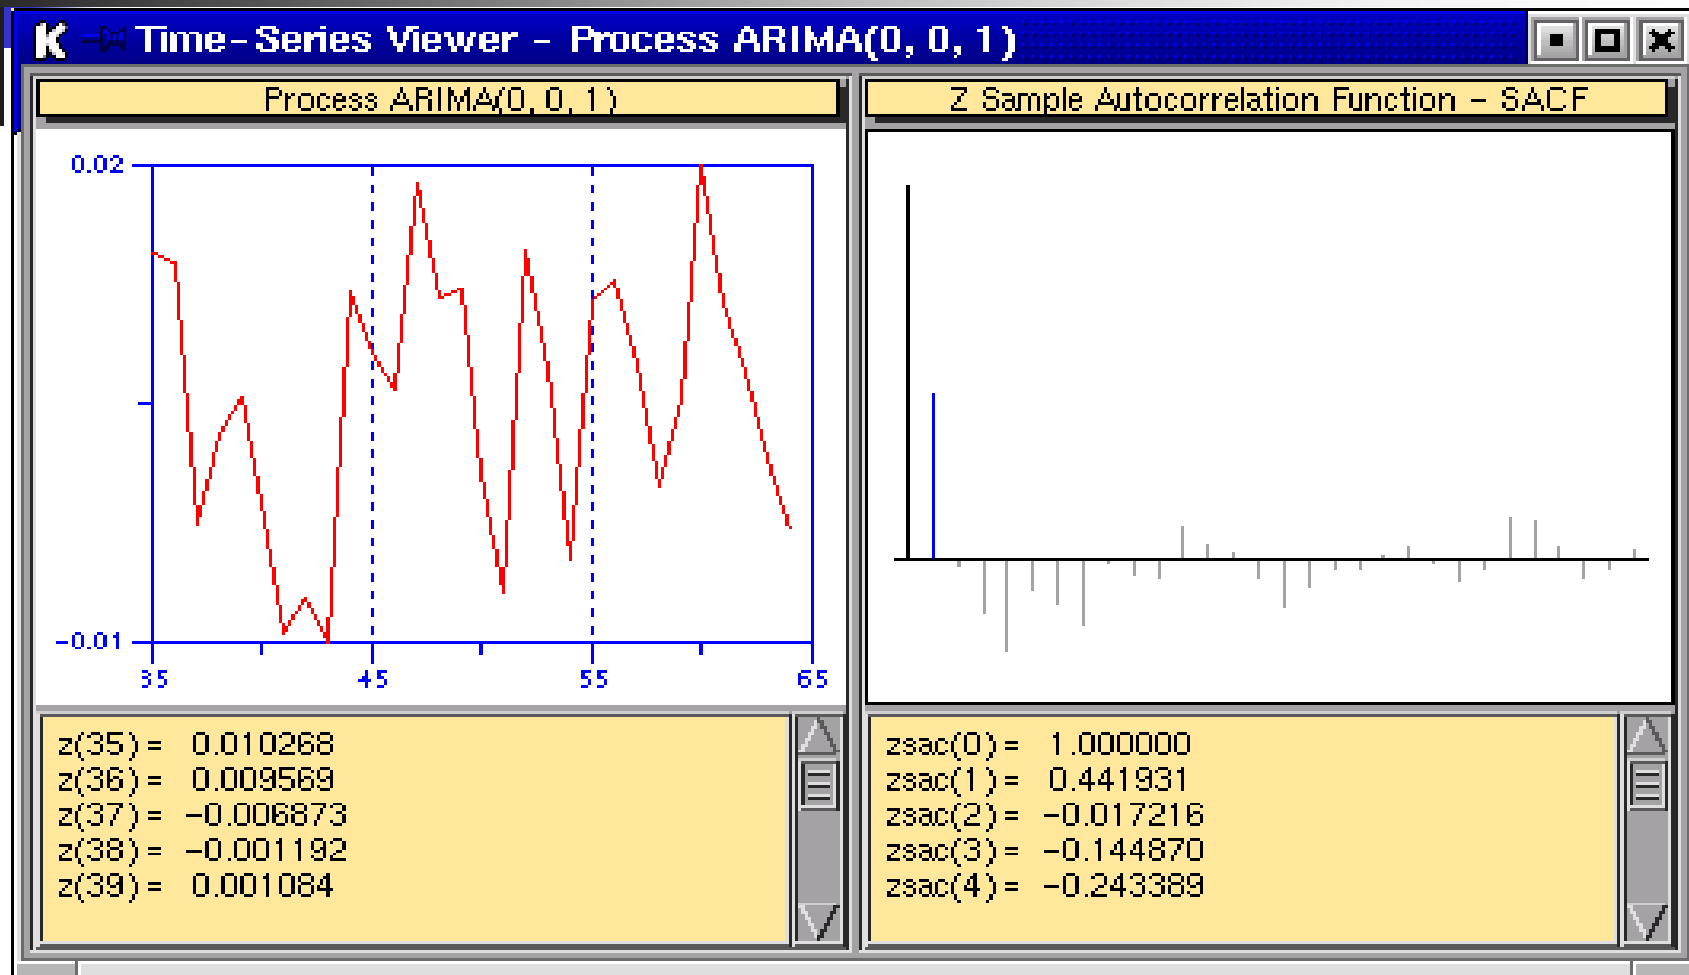
1-diferenças da Série A (BoxJenkins) - Estacionária



Função Autocorrelação (ACF)

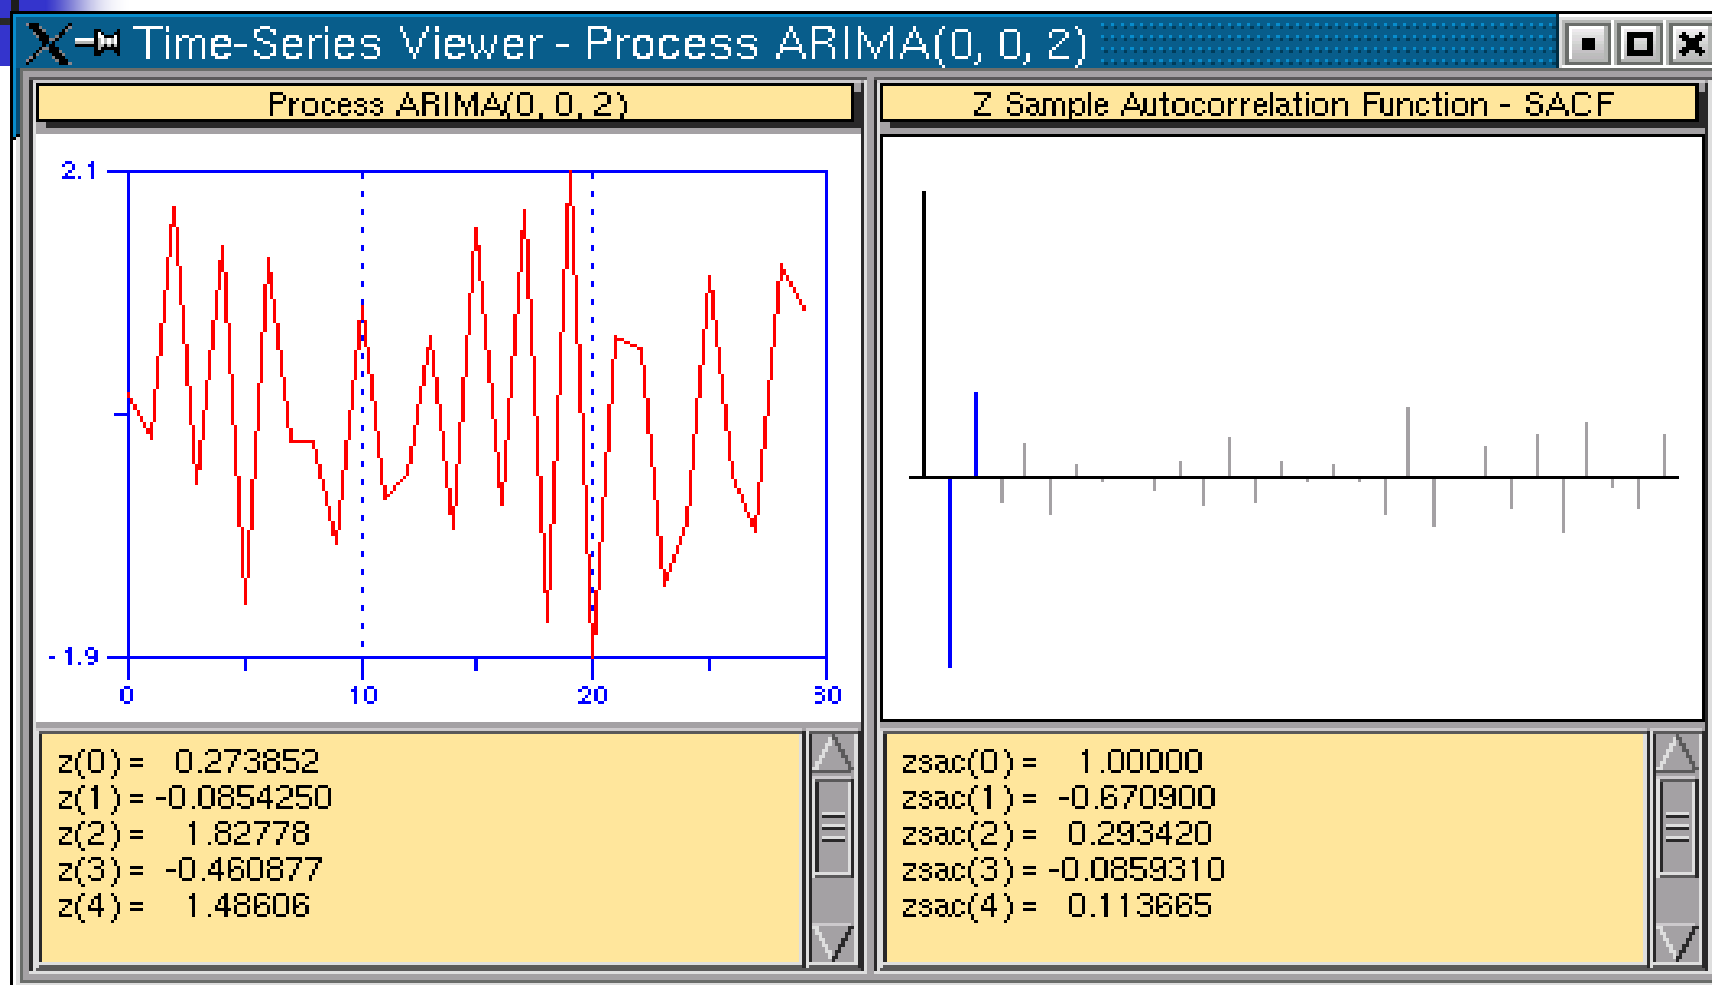
- **A ACF de um processo MA(q) somente terá valores até o *lag* p , com corte abrupto (*cut-off*).**
 - Dependência serial (regressão) com os q resíduos passados (a).

Função Autocorrelação (ACF)



Série MA(1) $\Phi = -0.8$ - Estacionária

Função Autocorrelação (ACF)



Série MA(2) $\Phi_1 = 0.85$, $\Phi_2 = -0.65$ - Estacionária



Função Autocorrelação Parcial (PACF)

- A PACF calcula a autocorrelação entre z_t e z_{t+k} excluindo o efeito dos pontos intermediários.

➤ $\exists \text{ Corr}(z_t, z_{t-1}), \exists \text{ Corr}(z_{t-1}, z_{t-2}) = \exists \text{ Corr}(z_t, z_{t-2})$

então a correlação de *lag* 1 se propaga para as correlações de *lag* 2 e superiores.

- A **correlação parcial** no *lag* k é a correlação descontada das correlações esperadas devido à propagação das correlações de *lag* inferiores.
- No *lag* 1 a ACF e PACF são iguais.



Função Autocorrelação Parcial (PACF)

- Cálculo dos coeficientes da PACF (Equações de Yule-Walker):

$$r_{kk} = \phi_{kk} = \begin{cases} r_1 & , se\ k = 1 \\ \frac{r_k - \sum_{j=1}^{k-1} r_{k-1,j} r_{k-j}}{1 - \sum_{j=1}^{k-1} r_{k-1,j} r_j} & , se\ k = 2, 3, \dots \end{cases}$$



Função Autocorrelação Parcial (PACF)

- Cálculo recursivo dos coeficientes da PACF.

Algoritmo de Durbin - Levinson
para $l = 1, 2, \dots, (L-1)$.

$$\text{inicialização} \begin{cases} p_{11} &= r_1 \\ v_1 &= 1 - r_1^2 \end{cases}$$

$$p_{l+1,l+1} = (r_{l+1} - p_{l,1}r_l - p_{l,2}r_{l-1} - \dots - p_{l,l}r_1) / v_l$$

$$p_{l+1,j} = p_{l,j} - p_{l+1,l+1}p_{l,l+1-j}, j = 1, 2, \dots, l$$

$$v_{l+1} = v_l(1 - p_{l+1,l+1})(1 + p_{l+1,l+1})$$



Função Autocorrelação Parcial (PACF)

- *Standard Error* dos coeficientes da PACF (Critério de Quenouille)

$$\sigma_{r_{kk}}^2 \cong \frac{1}{N} \quad , \text{ para } k \geq p + 1$$

$$se_{r_k} = \frac{1}{\sqrt{N}}$$

$$r_{kk} < 1.96 se_{r_{kk}} \rightarrow r_{kk} \cong 0$$



Função Autocorrelação Parcial (PACF)

- A PACF mostra quais as correlações são efetivas:
 - Se uma ACF tem correlações até o *lag* n e a PACF tem até o *lag* 1, então as correlações de *lag* $k > 1$ da ACF são explicadas como propagações da correlação de *lag* 1.
- **A PACF de um processo AR(p) somente terá valores até o *lag* p , com corte abrupto (*cut-off*).**
 - Dependência serial (regressão) com os p valores passados de z .



Função Autocorrelação Parcial (PACF)

- Outro significado dos coeficientes da PACF:

- Os coeficientes r_{kk} da PACF são os coeficientes ϕ_{kk} de maior ordem para um modelo AR(k) para a série, ou seja:

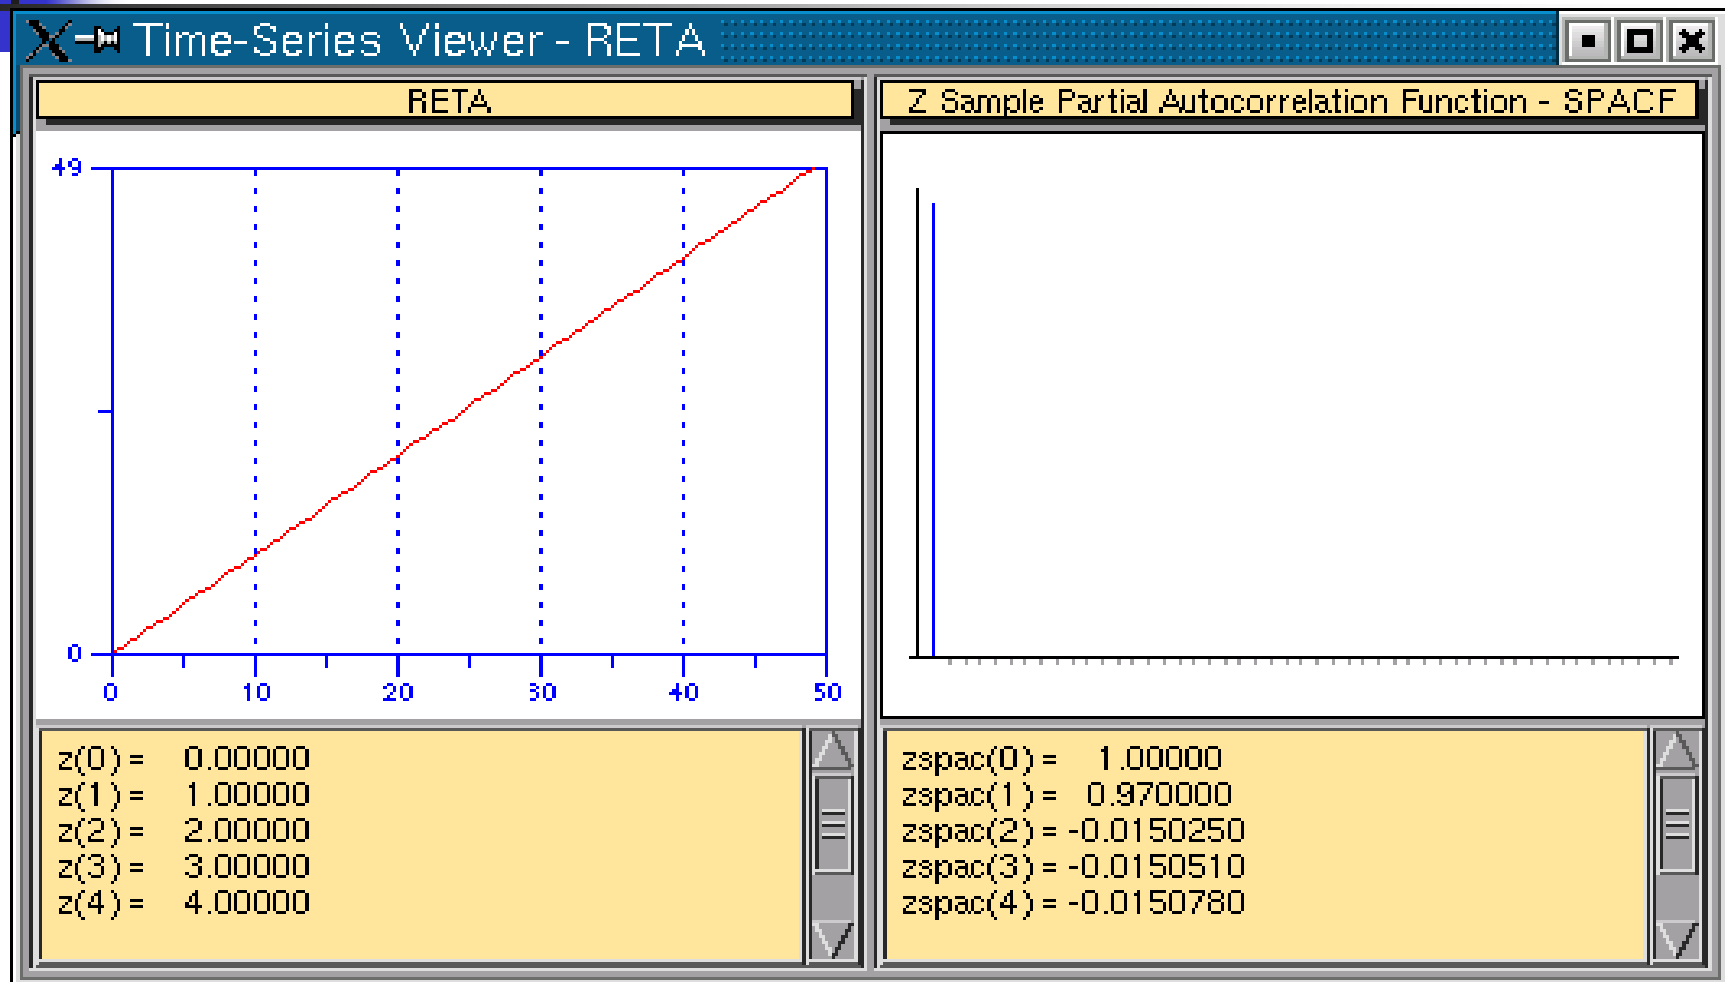
$$k = 1 \rightarrow \text{AR}(1) : \phi_{11}$$

$$k = 2 \rightarrow \text{AR}(2) : \phi_{21}, \phi_{22}$$

$$k = 3 \rightarrow \text{AR}(3) : \phi_{31}, \phi_{32}, \phi_{33}$$

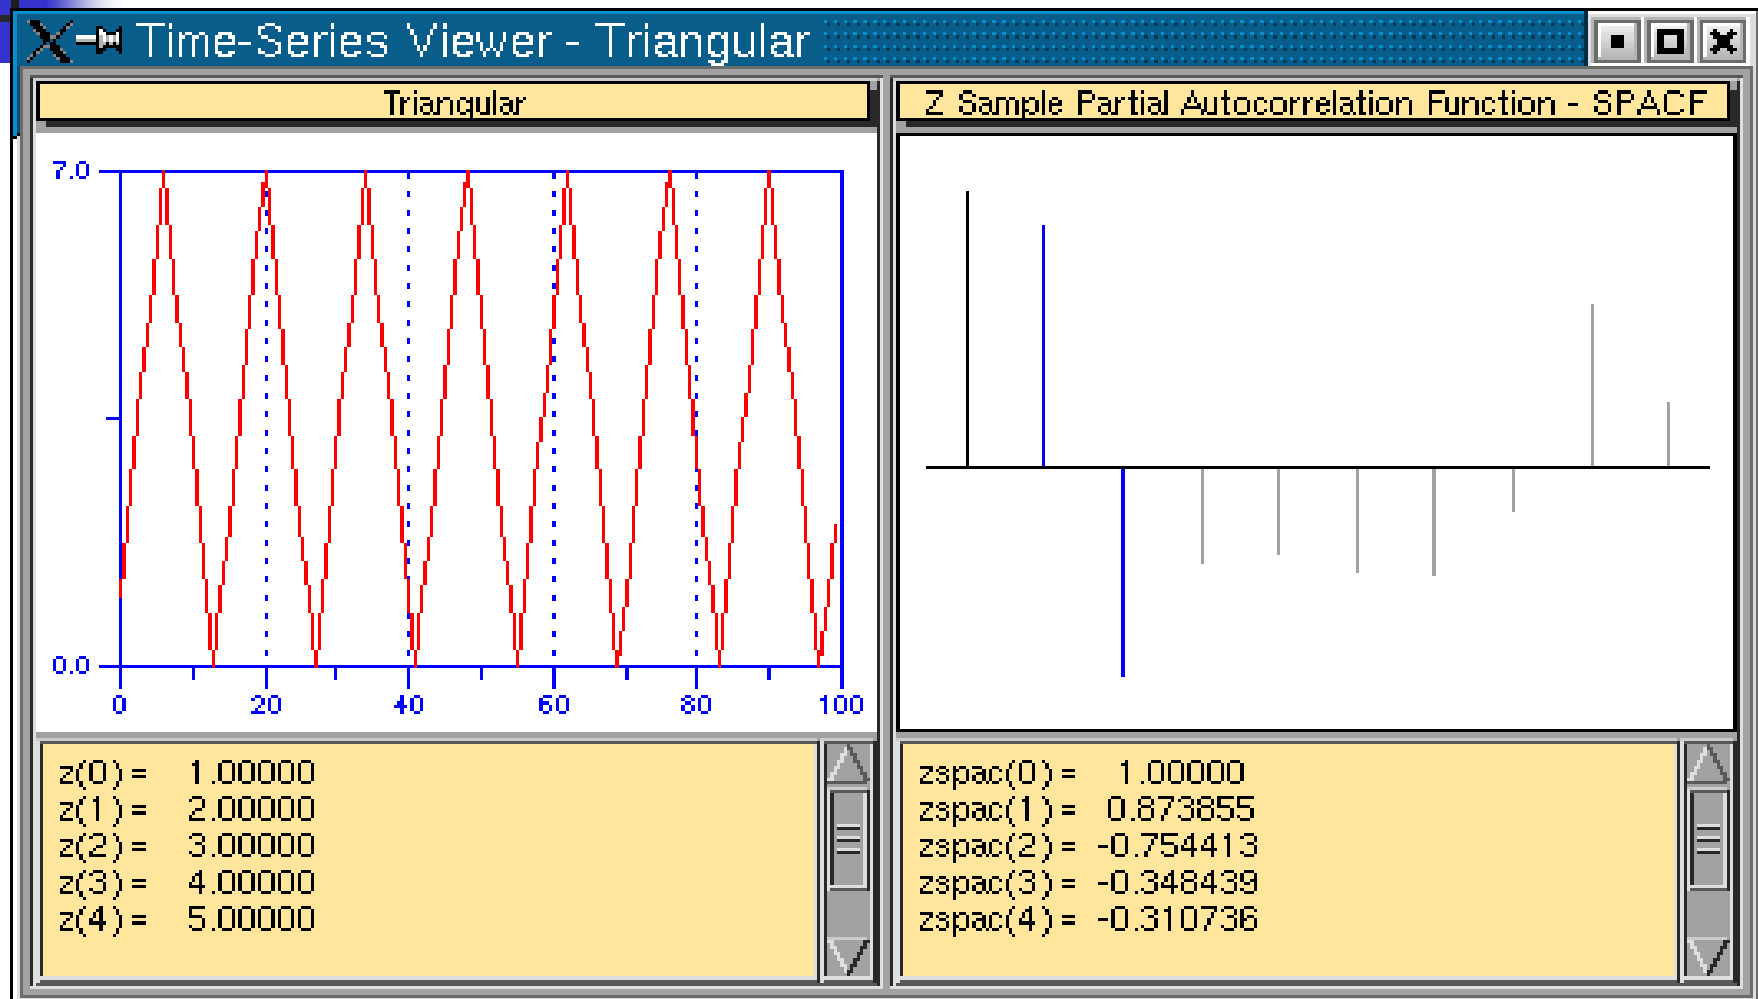
$$k = 4 \rightarrow \text{AR}(4) : \phi_{41}, \phi_{42}, \phi_{43}, \phi_{44}$$

Função Autocorrelação Parcial (PACF)



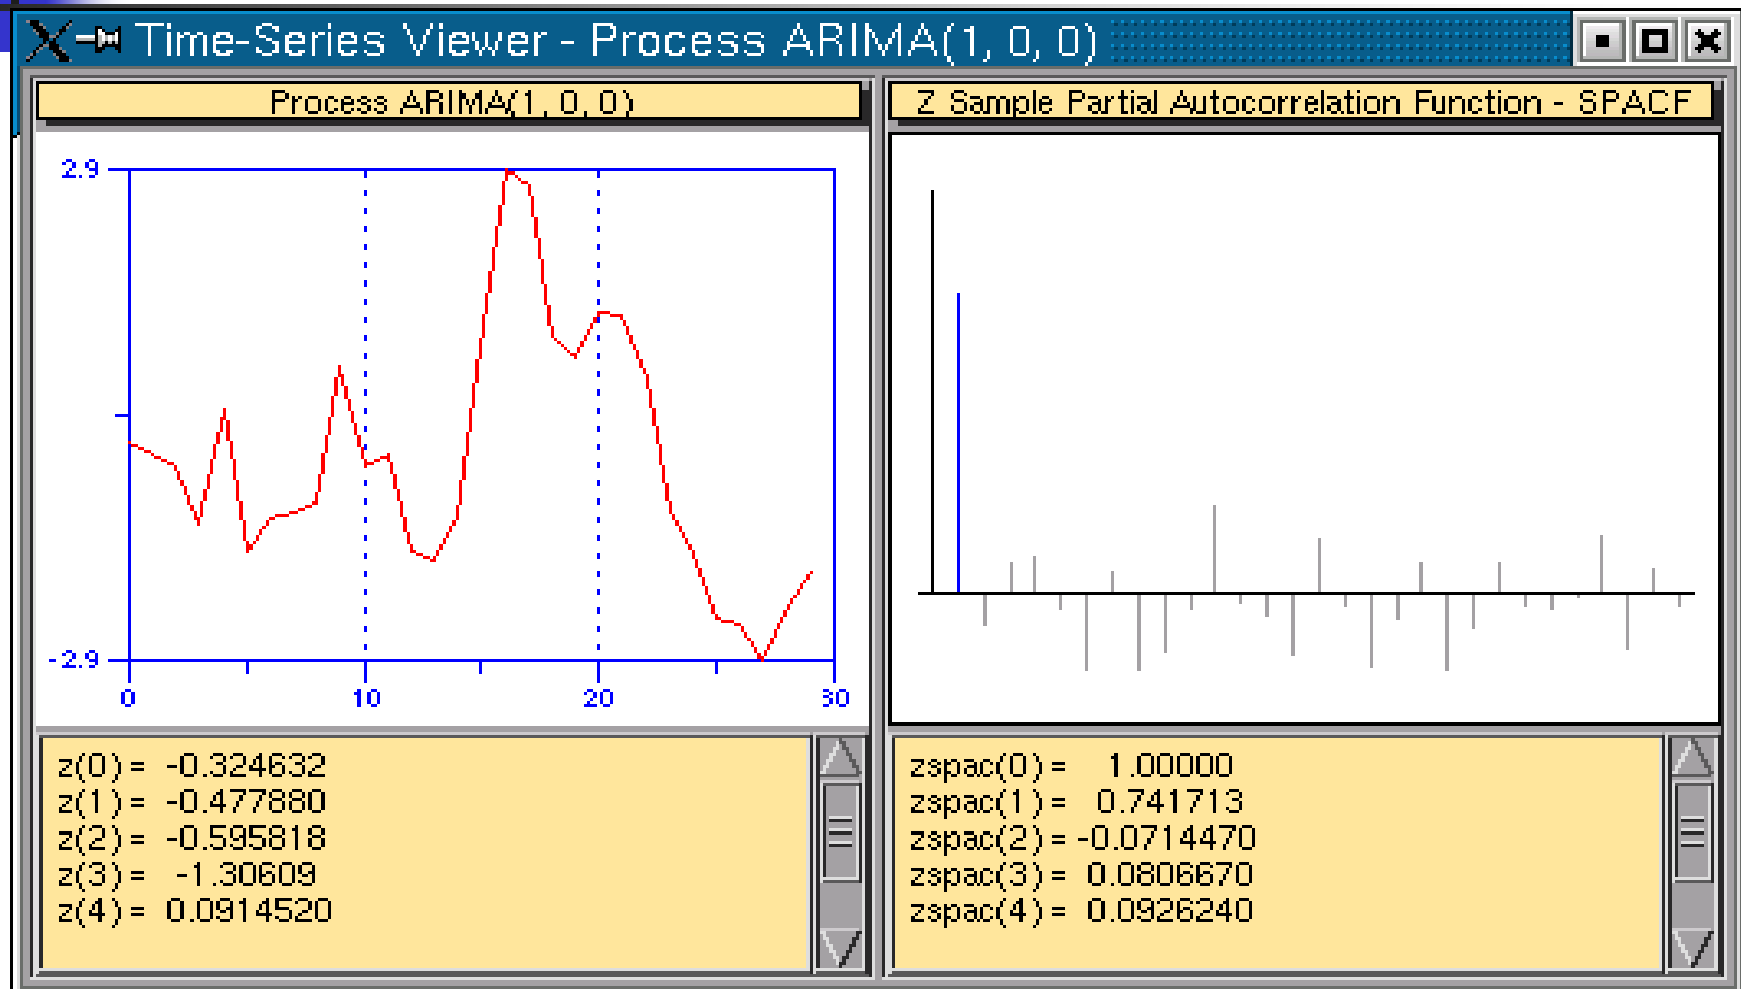
Da série de correlações da reta, apenas a primeira é efetiva

Função Autocorrelação Parcial (PACF)



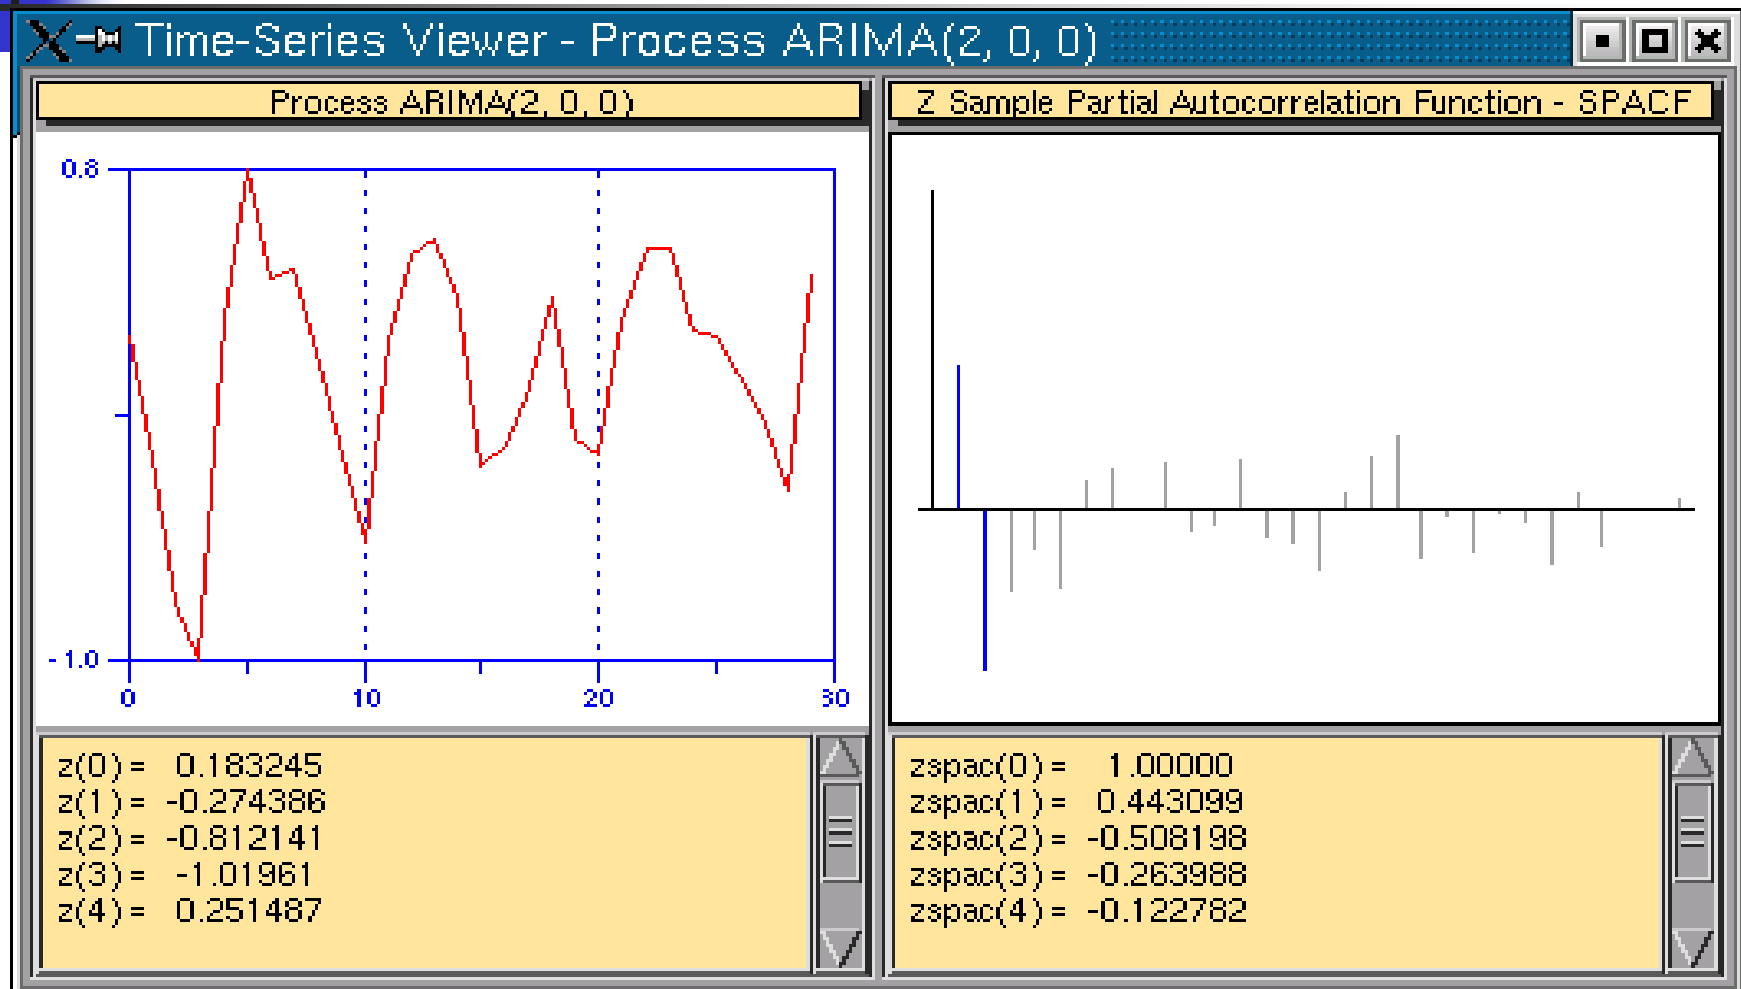
Correlações efetivas

Função Autocorrelação Parcial (PACF)



SAPCF de um processo AR(1)

Função Autocorrelação Parcial (PACF)



SAPCF de um processo AR(2)



Identificação – Estimativas Iniciais

- As estimativas iniciais dos parâmetros do modelo ARIMA:
 - Solução inicial para os algoritmos da etapa de Estimação.
 - Obtidas através das correlações (ACF) e covariâncias da séries.
 - Método Box-Jenkins

Identificação – Estimativas Iniciais

- 1- Estimativas iniciais dos parâmetros AR(p): solução do sistema (c_i são as autocovariâncias de w):

$$\begin{array}{ccccccc} c_{q+1} & = & \hat{\phi}_1 c_q & + & \hat{\phi}_2 c_{q-1} & + & \dots + \hat{\phi}_p c_{q-p+1} \\ c_{q+2} & = & \hat{\phi}_1 c_{q+1} & + & \hat{\phi}_2 c_q & + & \dots + \hat{\phi}_p c_{q-p+2} \\ \vdots & & \vdots & & \vdots & & \vdots \\ c_{q+p} & = & \hat{\phi}_1 c_{q+p-1} & + & \hat{\phi}_2 c_{q+p-2} & + & \dots + \hat{\phi}_p c_q \end{array}$$



Identificação – Estimativas Iniciais

- 2- Primeiras $q+1$ autocovariâncias do processo MA derivado são obtidas:

$$w_t^* = w_t - \hat{\phi}_1 w_{t-1} - \dots - \hat{\phi}_p w_{t-p}$$

$$w_t^* = \hat{\phi}(B)w_t \therefore w_t^* = \theta(B)a_t \quad \text{processo MA derivado}$$

$$c_j^* = \sum_{i=0}^p \phi_i^2 c_j + \sum_{i=1}^p (\phi_0 \phi_i + \phi_1 \phi_{i+1} + \dots + \phi_{p-1} \phi_p)(c_{j+i} + c_{j-i})$$

para $j = 0, 1, \dots, q$

onde $\phi_0 = -1$

Identificação – Estimativas Iniciais

- 3- Estimativas iniciais dos parâmetros MA(q):
processo linearmente convergente da função autocovariância.

$$\gamma_0 = (1 + \theta_1^2 + \dots + \theta_q^2) \sigma_a^2$$

$$\gamma_k = (-\theta_k + \theta_1 \theta_{k+1} + \dots + \theta_{q-k} \theta_q) \sigma_a^2 \quad \text{para } k \geq 1$$

computa - se os parâmetros $\sigma_a^2, \theta_q, \theta_{q-1}, \dots, \theta_1$ nesta ordem.

inicialmente, $\theta_1, \theta_2, \dots, \theta_q = 0$

$$\sigma_a^2 = \frac{c'_0}{1 + \theta_1^2 + \dots + \theta_q^2}$$

$$\theta_j = - \left(\frac{c'_j}{\sigma_a^2} - \theta_1 \theta_{j+1} - \theta_2 \theta_{j+2} - \dots - \theta_{q-j} \theta_q \right)$$

usando - se $\theta_0 = 0$

ARIMA-Checkpoint 2

- Ordem das d -diferenças obtidas pela análise da ACF
- Propriedades da ACF e PACF:

Process

ACF

PACF

White-noise

All $\rho_s = 0$

all $\phi_{ss} = 0$

AR(1): $a_1 > 1$

Direct exponential decay($\rho_s = a_1^s$)

$\phi_{11} = \rho_1, \phi_{ss} = 0, s \geq 2$

AR(1): $a_1 < 1$

Oscilating decay: $\rho_s = a_1^s$

$\phi_{11} = \rho_1, \phi_{ss} = 0, s \geq 2$

AR(p)

Decays to 0, May Oscillate

Spikes thru lag p,

All $\phi_{ss} = 0, s \geq p$

MA(1): $\beta > 0$

Positive spike at lag 1, $\rho_s = 0$
for $s \geq 0$

Oscillating decay: $\phi_{11} < 0$

MA(1): $\beta < 0$

Negative spike at lag 1, $\rho_s = 0$
for $s \geq 0$

Decay: $\phi_{11} < 0$

ARMA(1,1)


Exponential decay beginning
at lag 1, Sign $\rho_1 = \text{sign}(a_1 + \beta)$

Exponential decay begin-
ing at lag 1. $\phi_{11} = \rho_1 \text{ sign}$
(ϕ_{ss}) = sign (ϕ_{11})

ARMA(p,q)

Decay(either direct or
oscillatory) beginning at lag q

Decay (either direct or
oscillatory) beginning at
lag p





Estimação

- Objetivos:

- Obter estimativas eficientes dos parâmetros de modelo, a partir do modelo identificado e da solução inicial.
- Utilização eficiente da série histórica disponível.



Estimação

- Métodos:

- Maximização da função de *verossimilhança* (*Maximum Likelihood-ML*) dos parâmetros do modelo para os valores da série histórica.



Estimação

- Maximizar a Função *log-verossimilhança*:

$$l(\phi, \theta, \sigma_a^2) \cong -\frac{S(\phi, \theta)}{2\sigma_a^2} \quad \text{para } n \geq 20$$

- Minimizar a Função Soma dos Quadrados-S (*Sum of Squares*)

$$S(\phi, \theta) = \sum_{t=-c}^N \left[a_t | \mathbf{w}, \phi, \theta \right]^2$$



Estimação

- Outras métodos de estimação bastante utilizados (Box-Jenkins):
 - Bayesiana
 - Kalman Filter

Estimação

- S pode ser minimizada por rotinas de *Quadrados Mínimos (Least Squares)*.
 - preenche-se $N+Q$ equações

$$a_t = \tilde{w}_t - \varphi_1 \tilde{w}_{t-1} - \dots - \varphi_p \tilde{w}_{t-p_t} + \theta_1 a_{t-1} + \dots + \theta_q a_{t-q}$$

- os valores dos parâmetros de modelo são obtidos pela minimização de $S(\phi, \theta)$.

$$S(\phi, \theta) = \sum_{t=-c}^N \left[a_t | \mathbf{w}, \phi, \theta \right]^2$$



Estimação

- Solução para a origem de t :
 - *Backforecasts*: valores iniciais para $t < 1$ são obtidos aplicando-se o modelo no sentido inverso do tempo.
 - Na prática S tem a forma:

$$S(\phi, \theta) = \sum_{t=1-Q}^N \left[a_t | \mathbf{w}, \mathbf{e}, \phi, \theta \right]^2$$

onde os

a_t, w_t para $t < 1$

são obtidos pelos backforecasts \mathbf{e}



Estimação

- LS encontra MÍNIMO LOCAL a partir do estado sugerido pela estimativa inicial dos parâmetros.
 - Se a solução não for satisfatória, tenta-se outro estado inicial.



Diagnóstico

- Objetivos:

- verificar a qualidade dos parâmetros estimados para o modelo.
- *Benchmark* de diversos modelos.
- Sugerir alterações nos parâmetros.

- Métodos:

- *Overfitting*
- Diagnóstico dos resíduos
- Critérios de Informação



Diagnóstico

- *Overfitting:*

- Preencher um modelo mais elaborado visando expor direções de discrepância permitidas pelos parâmetros adicionais.



Diagnóstico dos resíduos a_t

- Resíduos a_t :

$$a_t = \tilde{w}_t - \varphi_1 \tilde{w}_{t-1} - \dots - \varphi_p \tilde{w}_{t-p_t} + \theta_1 a_{t-1} + \dots + \theta_q a_{t-q}$$

- Inspeção visual do gráfico dos resíduos – *primeiro passo indispensável no diagnóstico.*
- se o modelo é correto, a_t se aproxima do ruído branco quando N cresce.



Diagnóstico dos resíduos a_t

- Teste *Portmanteau Lack-of-Fit*

$$Q = n \sum_{k=1}^K r_k^2(\hat{a}), \quad \text{com } n = N - d$$

é aproximado pela distribuição Chi - Quadrados
 $\chi^2(K - p - q)$

- Testa K autocorrelações r em grupo.
- $K \sim 20$.
- se o modelo é inadequado, os valores de Q são maiores que os Chi-Quadrados.



Diagnóstico dos resíduos a_t

- Estatística Ljung-Box modificada

$$\tilde{Q} = n(n+2) \sum_{k=1}^K \frac{r_k^2(\hat{a})}{(n-k)} \quad \text{com } n = N - d$$

$$E[\tilde{Q}] \approx K - p - q$$

da distribuição Chi - Quadrados

$$\chi^2(K - p - q)$$

Diagnóstico dos resíduos a_t

- *Information criteria:* AIC (Akaike) e BIC(Scharwz)
 - Modelos com menor AIC e BIC são preferidos.
 - Modelos escolhidos com BIC terão nunca número de parâmetros maior que os escolhidos com AIC.

$$AIC_{p,q} \cong \ln(\hat{\sigma}_a^2) + r \frac{2}{n} + \delta$$


$$BIC_{p,q} = \ln(\hat{\sigma}_a^2) + r \frac{\ln(n)}{n}$$

$$r = p + q + 1$$

$\hat{\sigma}_a^2$ é a estimativa ML de σ_a^2

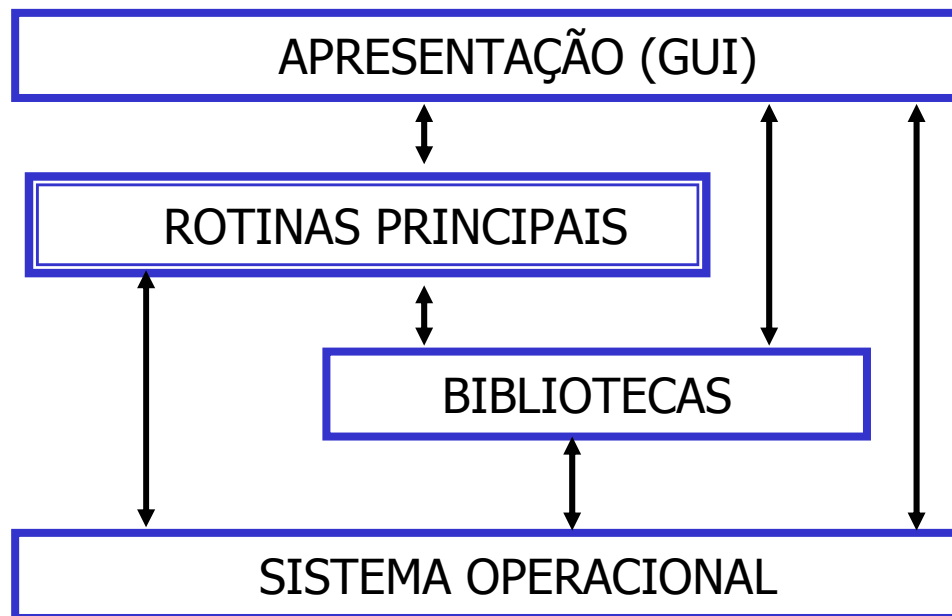
Ferramenta TSTOOL/ARIMA

- Ambiente gráfico modular multi-modelos para previsão de séries temporais
 - Linux
 - Linguagem C
 - Bibliotecas auxiliares:
 - XForms
 - gsl (Gnu Scientific Library).



Ferramenta TSTOOL/ARIMA

- Arquitetura das aplicações
 - Base de código tenta maximizar o isolamento entre camadas para modularidade e portabilidade





Ferramenta TSTOOL/ARIMA

- Módulos do TSTOOL
 - TSTOOL - módulo principal :carrega, salva, exporta, etc...
 - TSVIEW – módulo de gráficos: *plot*, dados, etc...
 - FPARSER– *file parser* com suporte a séries temporais (vetores) para armazenamento e IPC.
 - ARIMA – Box-Jenkins
 - NEURAL* – Rede neural com Aspirin/MIGRAINES
 - GENÉTICO* – Algoritmo genético, neuro-genético.
- ≈ 14.500 LOC** (linhas de código)

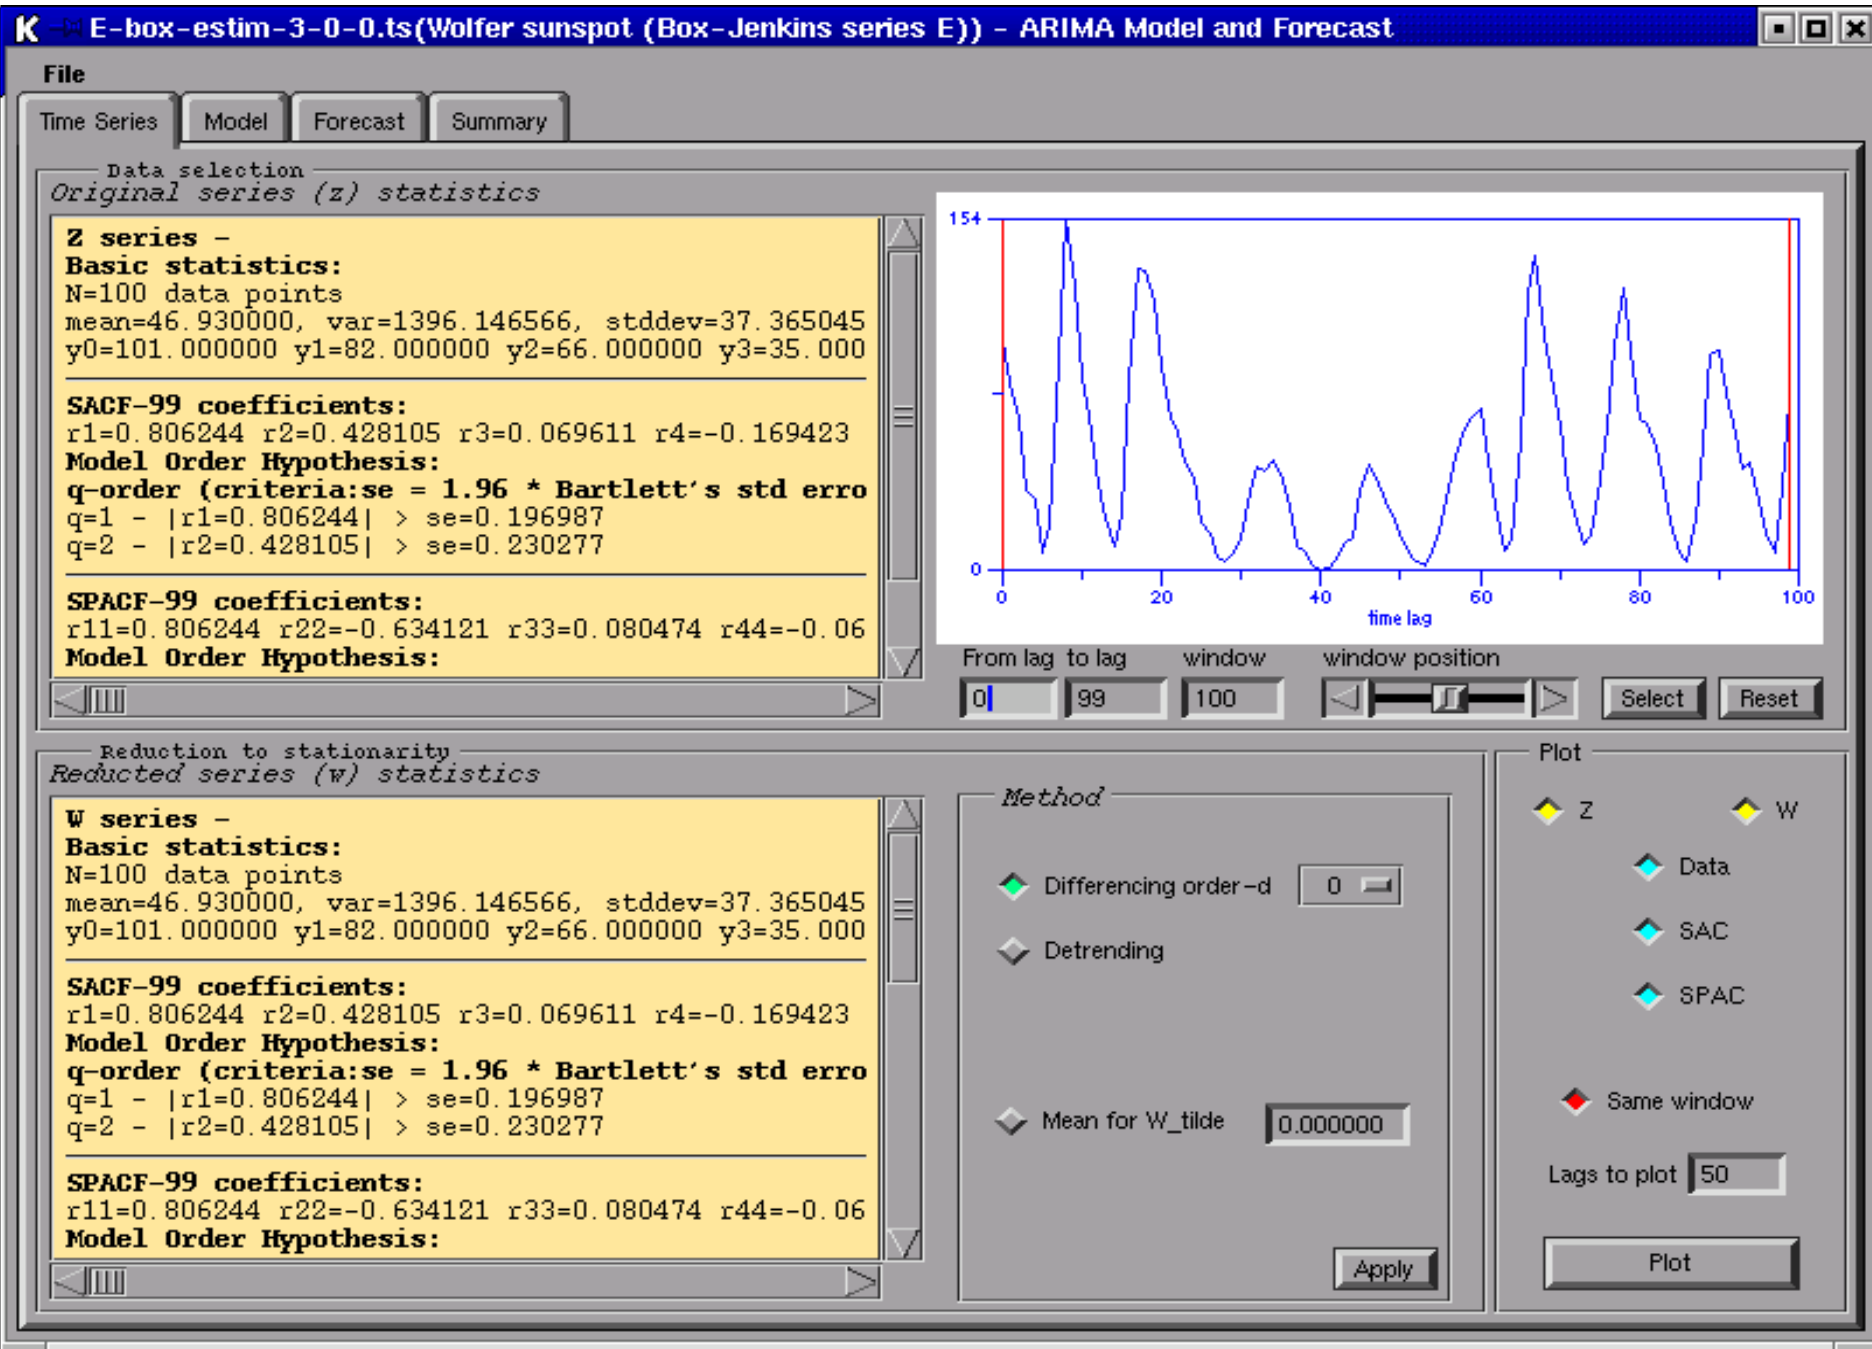
(*) Implementados porém ainda não integrados ao TSTOOL

(**) módulos TSTOOL, TRSVIEW, FPARSER, ARIMA



Ferramenta TSTOOL/ARIMA

- Estágio de desenvolvimento – *alpha*.
- Screenshots do módulo TSTOOL/ARIMA
 - Time-series – seleção de *range*, estatísticas, SAC, SPAC.
 - Model – parâmetros, estimativas iniciais, estimativas finais, diagnóstico.
 - Forecast– previsão, erros e resíduos.



File

Time Series | **Model** | Forecast | Summary

General ARIMA (Box-Jenkins) model

$$\phi_p(B) \phi_p(B^L) z_t = \delta + \theta_q(B) \theta(B^L) a_t$$

Realize process Lags 0 Save process as TS

Model orders

Autoregressive order -p 3 Moving average order -q 0 d 0

A.R. seasonal order -P 0 M.A. seasonal order -Q 0 L 0

Non-seasonal Seasonal Residuals

ϕ θ ϕ θ σ^2 218.0000

Calculate

Constant δ 11.31000

Calculate

Estimation

Nonlinear (ML-Marquardt-Levenberg Solver)

☒ ULS (Marquardt-Levenberg) ☐ CLS

Estimate

Results

ARIMA(3,0,0) parameters final estimates
 Procedure: estimate procedure not called, default pa

w stats: n=100 w_mean=46.930000 var_w=1396.146566
 stderr(w_mean)=3.563496 w_mean interval=[43.366504,
 ar1=1.570000 ar2=-1.020000 ar3=0.210000
 AR(B) roots: z0=1.034354+0.798653j |z0|=1.306803 z1=
 ALL roots lie out of unit circle
 delta=11.310000
 Sum of squares of a=22284.559126
 var_a=218.381907
 Information criteria: AIC=16.776245 BIC=5.570452

Diagnostic checking

Num. of autocorrelations to use 98 Check model Plot residuals

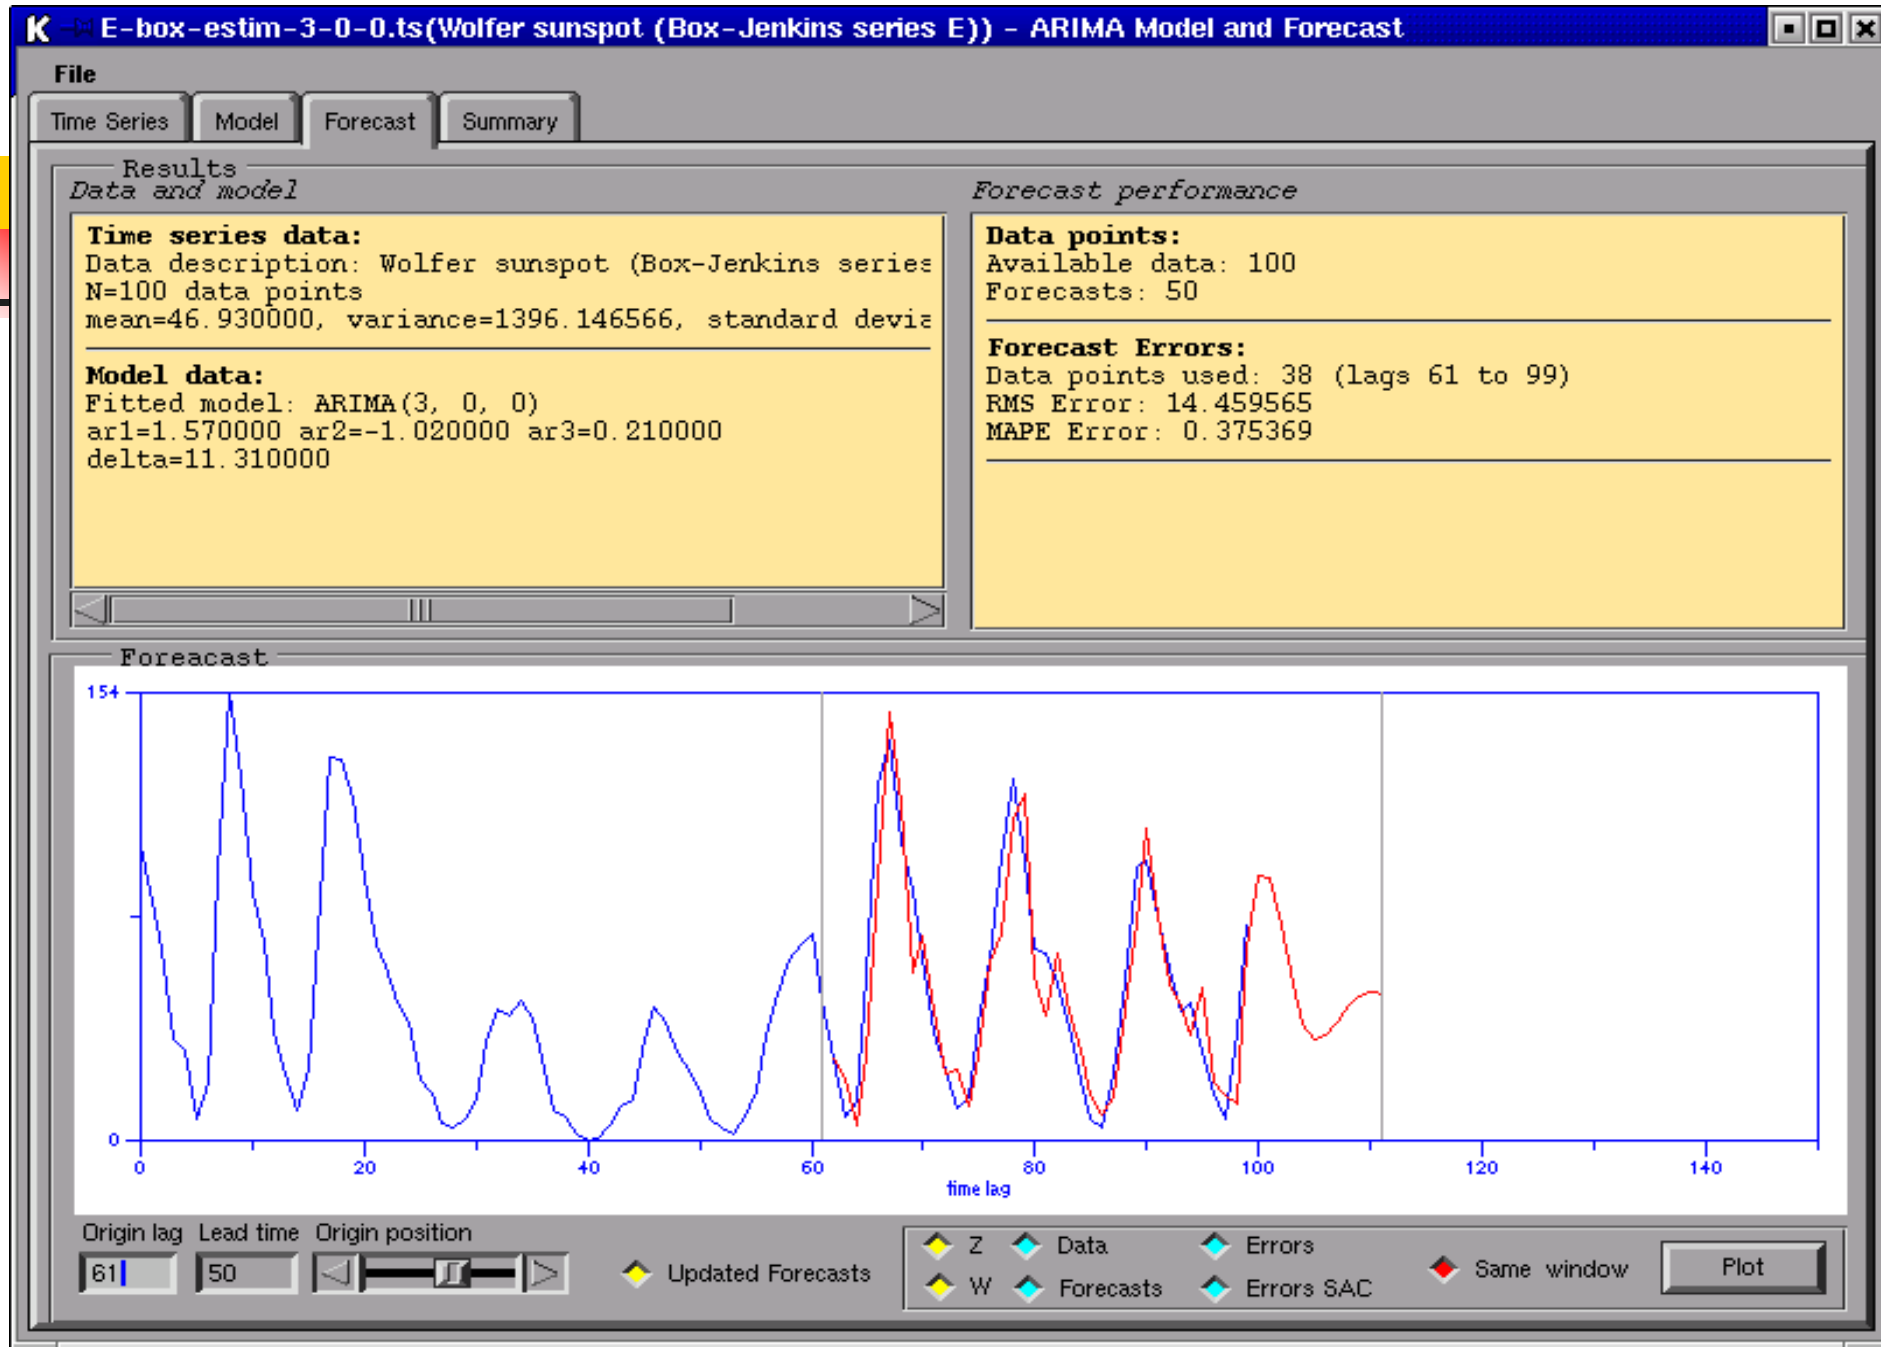
Results

ARIMA(3,0,0) parameters final estimates
Roots of Characteristic Equations:
 AR(B) roots: z0=1.034354+0.798653j |z0|=1.306803
 ALL roots lie out of unit circle

Residuals(a)-100 values: mean=0.012409 var=218.38
 a0=4.247303 a1=-16.239173 a2=16.413169 a3=-17.453

SACF of residuals (a)-98 coefficients used:
 r0=1.000000 r1=-0.009550 r2=-0.109450 r3=0.044965

Checking criteria:
 Max.stderr for AC-1/sqrt(100)=0.100000
 Ljung-Box: Q=221.078566



TSTOOL/ARIMA- *Benchmark* com os exemplos de Box-Jenkins

Resultados do módulo TSTOOL/ARIMA X Exemplos Box-Jenkins					
<i>Série</i>	<i>Modelo</i>	<i>Estimativas Iniciais</i>		<i>Estimativas</i>	
		Box-Jenkins	TSTOOL/ARIMA	Box-Jenkins	TSTOOL/ARIMA
Chemical proc. concentration (Box-Jenkins series A)	(1,0,1)	ar1 =0.87 ma1 =0.48 delta =2.45 var_a =0.098 S =19.270010	ar1 =0.868278 ma1 =0.480381 delta =2.247506 var_a =0.097630 S =19.270133	ar1 =0.92 ma1 =0.58 delta =1.45 var_a =0.097 S =19.182801	ar1 =0.916566 ma1 =0.609902 delta =1.423594 var_a =0.097067 S =19.175424
Chemical proc. concentration (Box-Jenkins series A)	(0,1,1)	ma1 =0.53 delta =0.0 var_a =0.107 S =20.265666	ma1 =0.528070 delta =0.002041 var_a =0.103100 S =20.276040	ma1 =0.70 delta =0.0 var_a =0.101 S =19.719609	ma1 =0.718569 delta =0.002041 var_a =0.002041 S =19.721280
IBM stock (Box-Jenkins series B)	(0,1,1)	ma1 =-0.09 delta =0.0 var_a =52.2 S =19192.615141	ma1 =-0.086212 delta =-0.279891 var_a =52.152651 S =19192.213953	ma1 =-0.09 delta =0.0 var_a =52.2 S =19192.615141	ma1 =-0.073683, delta =-0.279891 var_a =52.160028 S =19194.920355

TSTOOL/ARIMA- *Benchmark* com os exemplos de Box-Jenkins

Chemical temperature (Box-Jenkins series C)	(1,1,0)	ar1 =0.81 delta =0.0 var_a =0.019 S =4.366651	ar1 =0.805496 delta =-0.006743 var_a =0.017864 S =4.063117	ar1 =0.82 delta =0.0 var_a =0.018 S =4.060537	ar1 =0.825973, delta =-0.006033 var_a =0.017863 S =4.060911
Chemical temperature (Box-Jenkins series C)	(0,2,2)	ma1 =0.09 ma2 =0.07 delta =0.0 var_a =0.020 S =4.061787	ma1 =0.085572 ma2 =0.066229 delta =-0.002679 var_a =0.019496 S =4.368707	ma1 =0.13 ma2 =0.12 delta =0.0 var_a =0.019 S =4.355676	ma1 =0.130983, ma2 =0.122996, delta =-0.002679 var_a =0.019423 S =4.355705
Chemical viscosity (Box-Jenkins series D)	(1,0,0)	ar1 =0.86 delta =1.32 var_a =0.093 S =27.990700	ar1 =0.861462 delta =1.265212 var_a =0.089483 S =27.987230	ar1 =0.87 delta =1.17 var_a =0.090 S =27.976432	ar1 =0.876410, delta =1.128692 var_a =0.089510 S =27.978955
Chemical viscosity (Box-Jenkins series D)	(0,1,1)	ma1 =0.05 delta =0.0 var_a =0.096 S =29.718366	ma1 =0.051262 delta =0.003560 var_a =0.096174 S =29.717809	ma1 =0.06 delta =0.0 var_a =0.096 S =29.716169	ma1 =0.059482, delta =0.003560 var_a =0.096169 S =29.716159

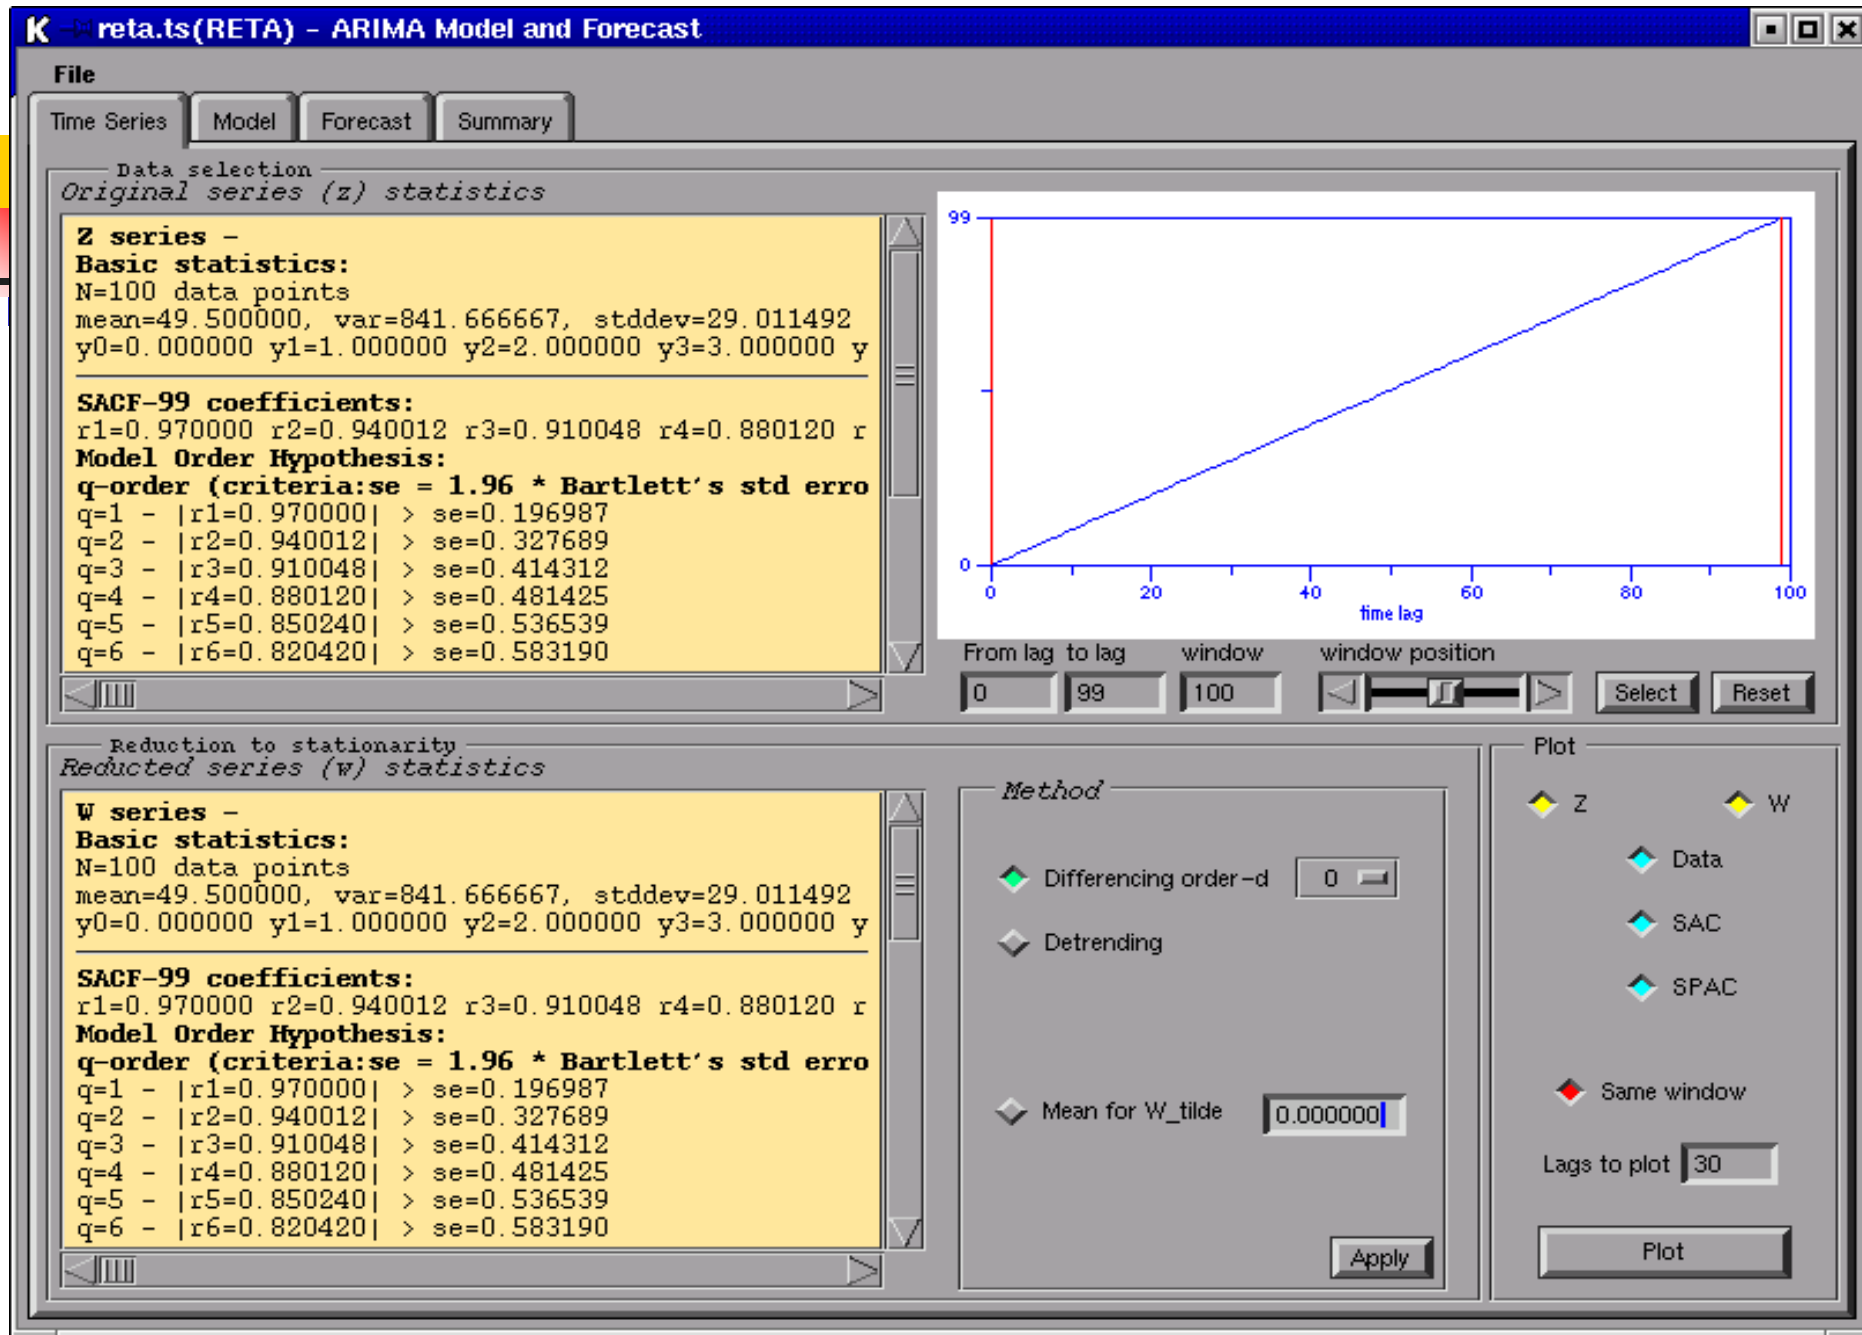
TSTOOL/ARIMA- *Benchmark* com os exemplos de Box-Jenkins

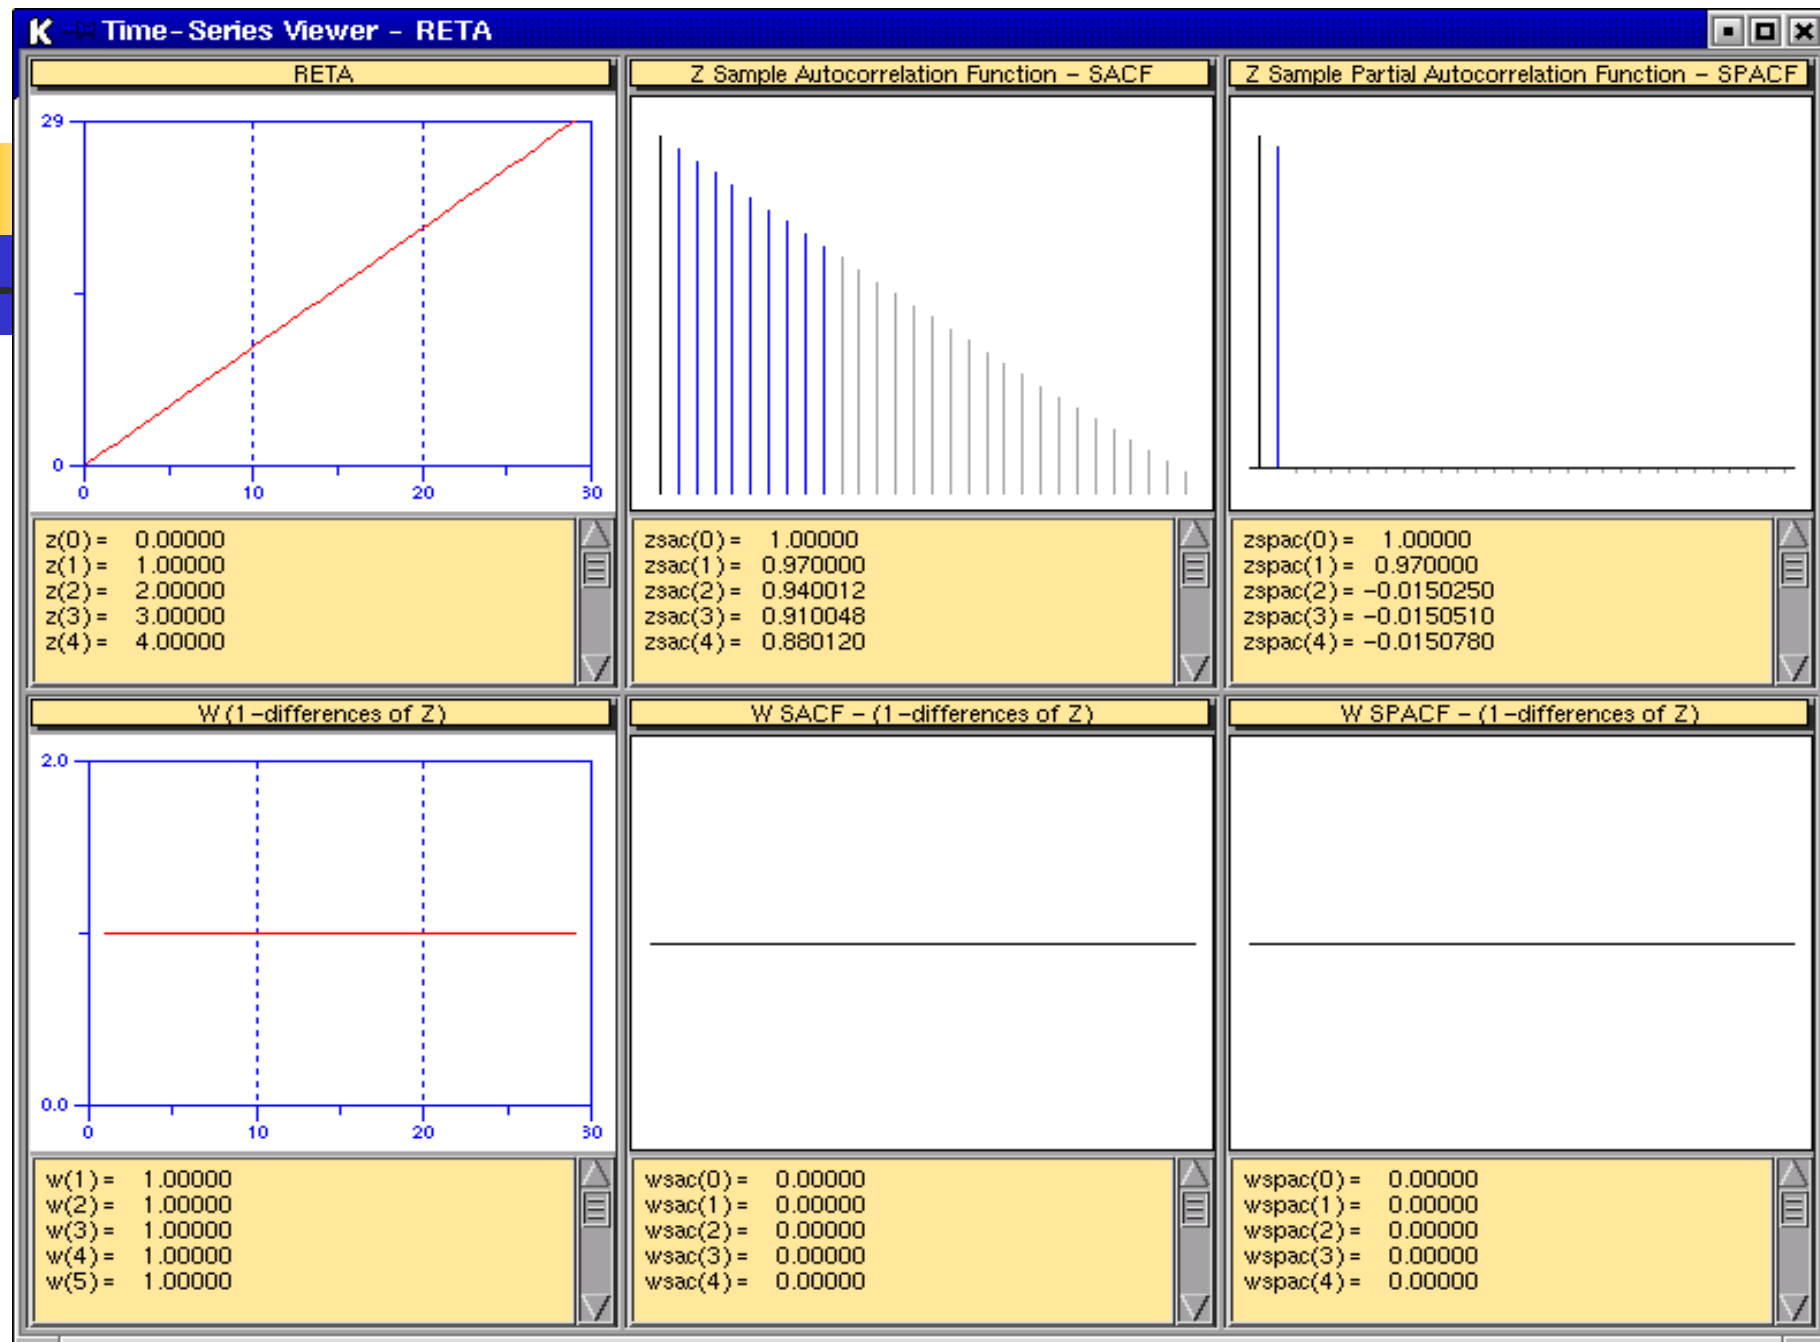
Wolfer sunspot (Box-Jenkins series E)	(2,0,0)	ar1 =1.32 ar2 =-0.63 delta =14.9 var_a =289.0 S =23538.354642	ar1 =0.806244 ar2 =-0.221924 delta =19.507863 var_a =388.158329 S =39547.779856	ar1 =1.42 ar2 =-0.73 delta =14.35 var_a =228.0 S =23085.065862	ar1 =1.410409, ar2 =-0.700836, delta =13.629755 var_a =226.406298 S =23096.631910
Wolfer sunspot (Box-Jenkins series E)	(3,0,0)	ar1 =1.37 ar2 =-0.74 ar3 =0.08 delta =13.7 var_a =287.0 S =23048.543429	ar1 =0.806244 ar2 =-0.221924 ar3 =-0.096621 delta =24.042304 var_a =373.486098 S =38054.067240	ar1 =1.57 ar2 =-1.02 ar3 =0.21 delta =11.31 var_a =218.0 S =22284.559126	ar1 =1.547141, ar2 =-0.973827, ar3 =0.189886, delta =11.113035 var_a =218.056043 S =22264.205800
Chemical yields (Box-Jenkins series F)	(2,0,0)	ar1 =-0.32 ar2 =-0.18 delta =58.3 var_a =115.0 S =7923.092342	ar1 =-0.389878 ar2 =-0.152389 delta =63.271062 var_a =113.105096 S =7928.507849	ar1 =-0.34 ar2 =-0.19 delta =58.87 var_a =113.0 S =7916.294670	ar1 =-0.348361, ar2 =0.193983, delta =59.021704 var_a =112.913167 S =7916.976328



TSTOOL/ARIMA- Exemplos de modelagem

- Reta
- Série triangular.
- Cotações de COFAP (FAP4)





K - reta.ts (RETA) - ARIMA Model and Forecast

File Time Series Model Forecast Summary

General ARIMA (Box-Jenkins) model

$$\phi_p(B) \phi_p(B^L) z_t = \delta + \theta_q(B) \theta(B^L) a_t$$

Realize process Lags 0 Save process as TS

Model orders

Autoregressive order -p 1 Moving average order -q 0 d 0

A.R. seasonal order -P 0 M.A. seasonal order -Q 0 L 0

Non-seasonal Seasonal Residuals

ϕ θ ϕ θ σ_a^2 0.879037

0.970000

Calculate

Constant δ 1.485000

Calculate

Estimation

Nonlinear (ML-Marquardt-Levenberg Solver)

☒ ULS (Marquardt-Levenberg) ☐ CLS

Estimate

Results

ARIMA(1,0,0) parameters final estimates
 Procedure: Levenberg-Marquardt (gsl-lmder)
 Convergence (2 iterations): success

w stats: n=100 w_mean=49.500000 var_w=841.666667
 stderr(w_mean)=13.106043 w_mean interval=[36.393957,
 ar1=1.009454
 AR(B) roots: z0=0.990634+0.000000j |z0|=0.990634
 NOT ALL roots lie out of unit circle
 delta=-0.467991
 Sum of squares of a=60.614850
 var_a=0.072309
 Information criteria: AIC=-3.054802 BIC=-2.534707

Diagnostic checking

Num. of autocorrelations to use 99

Check model Plot residuals

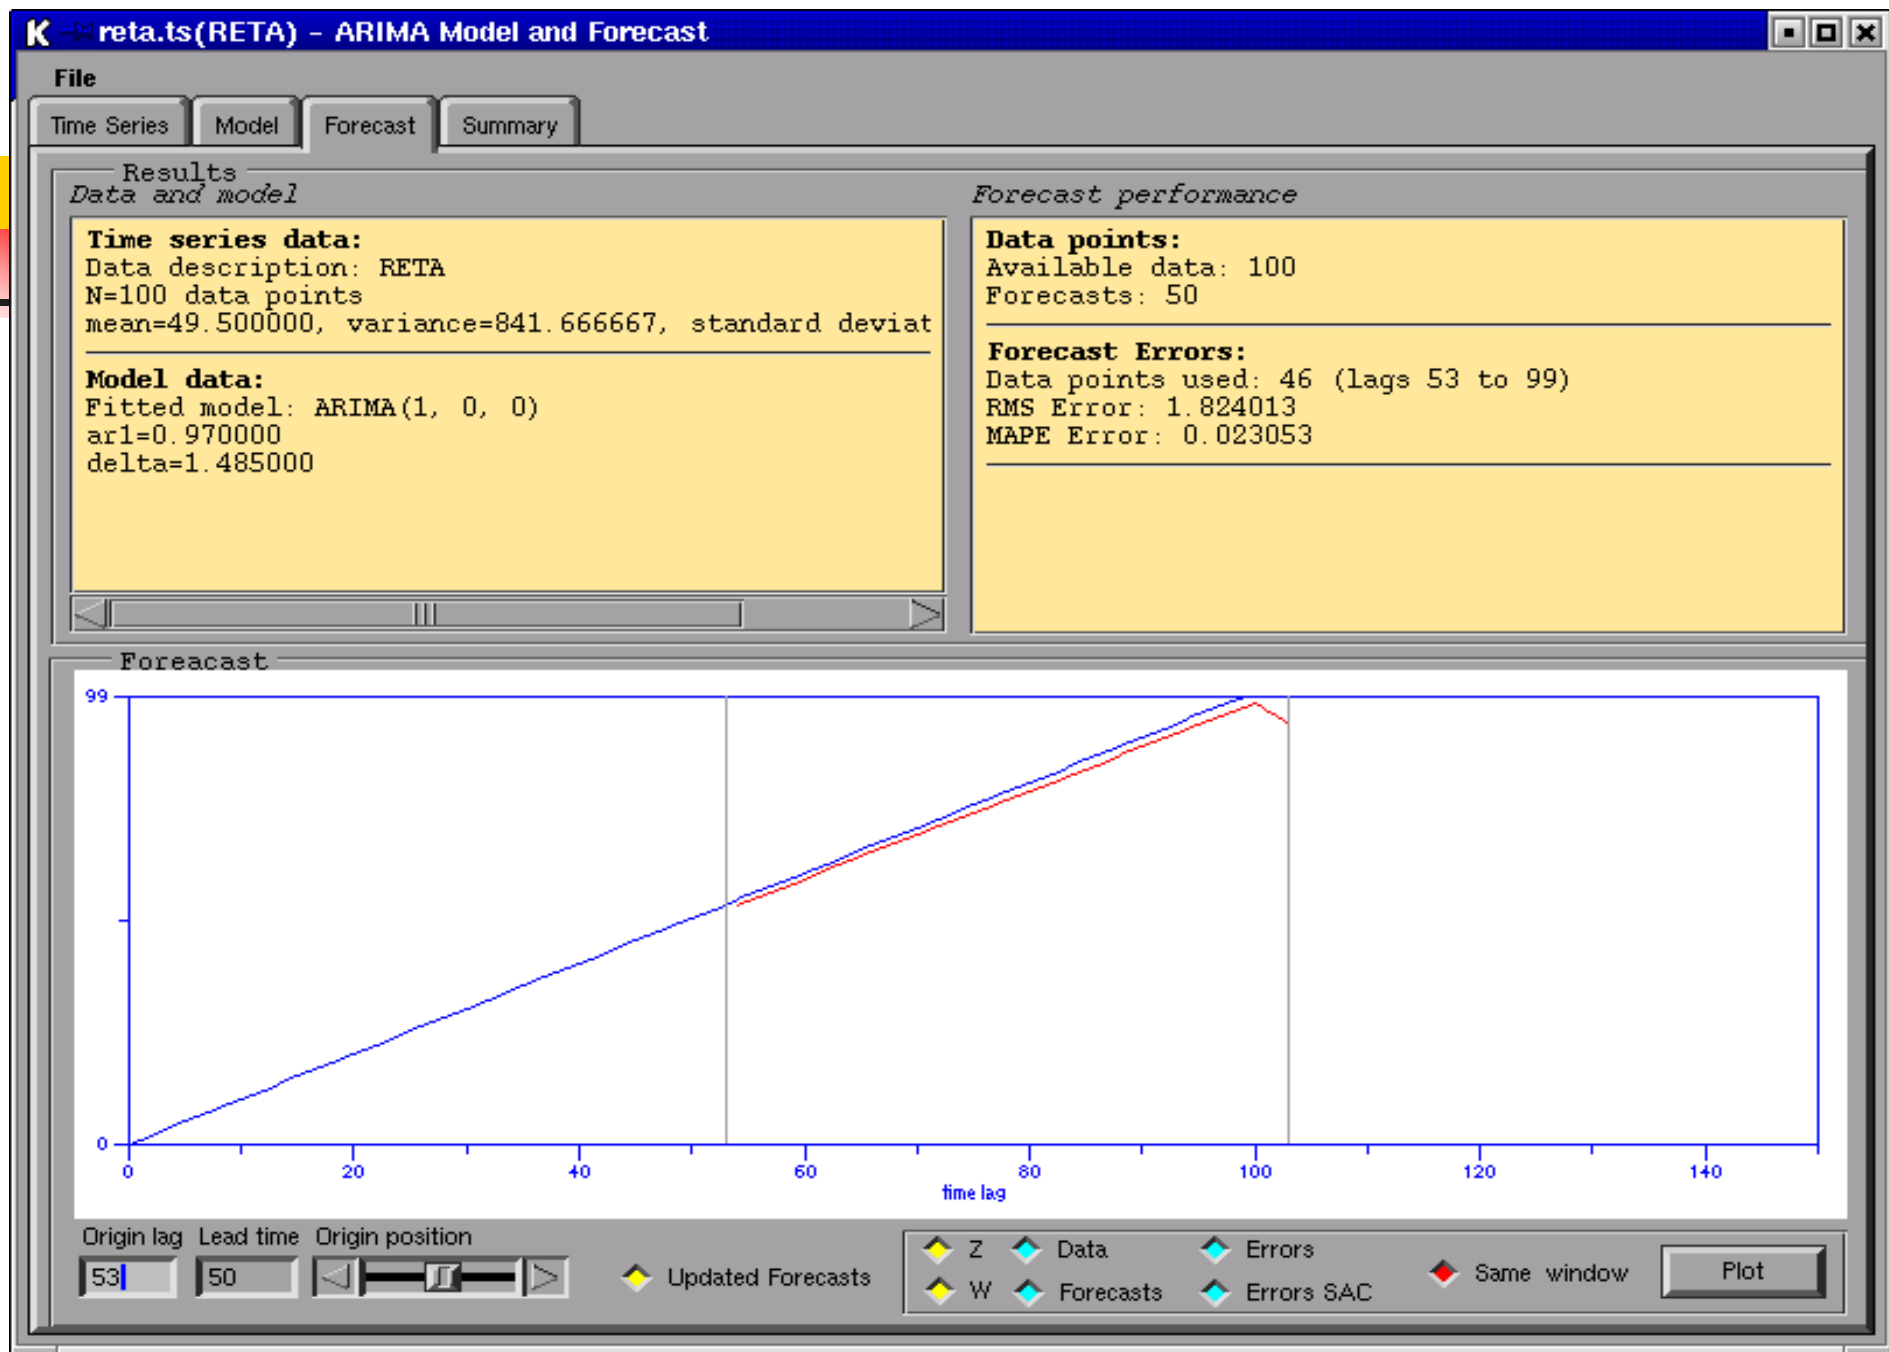
Results

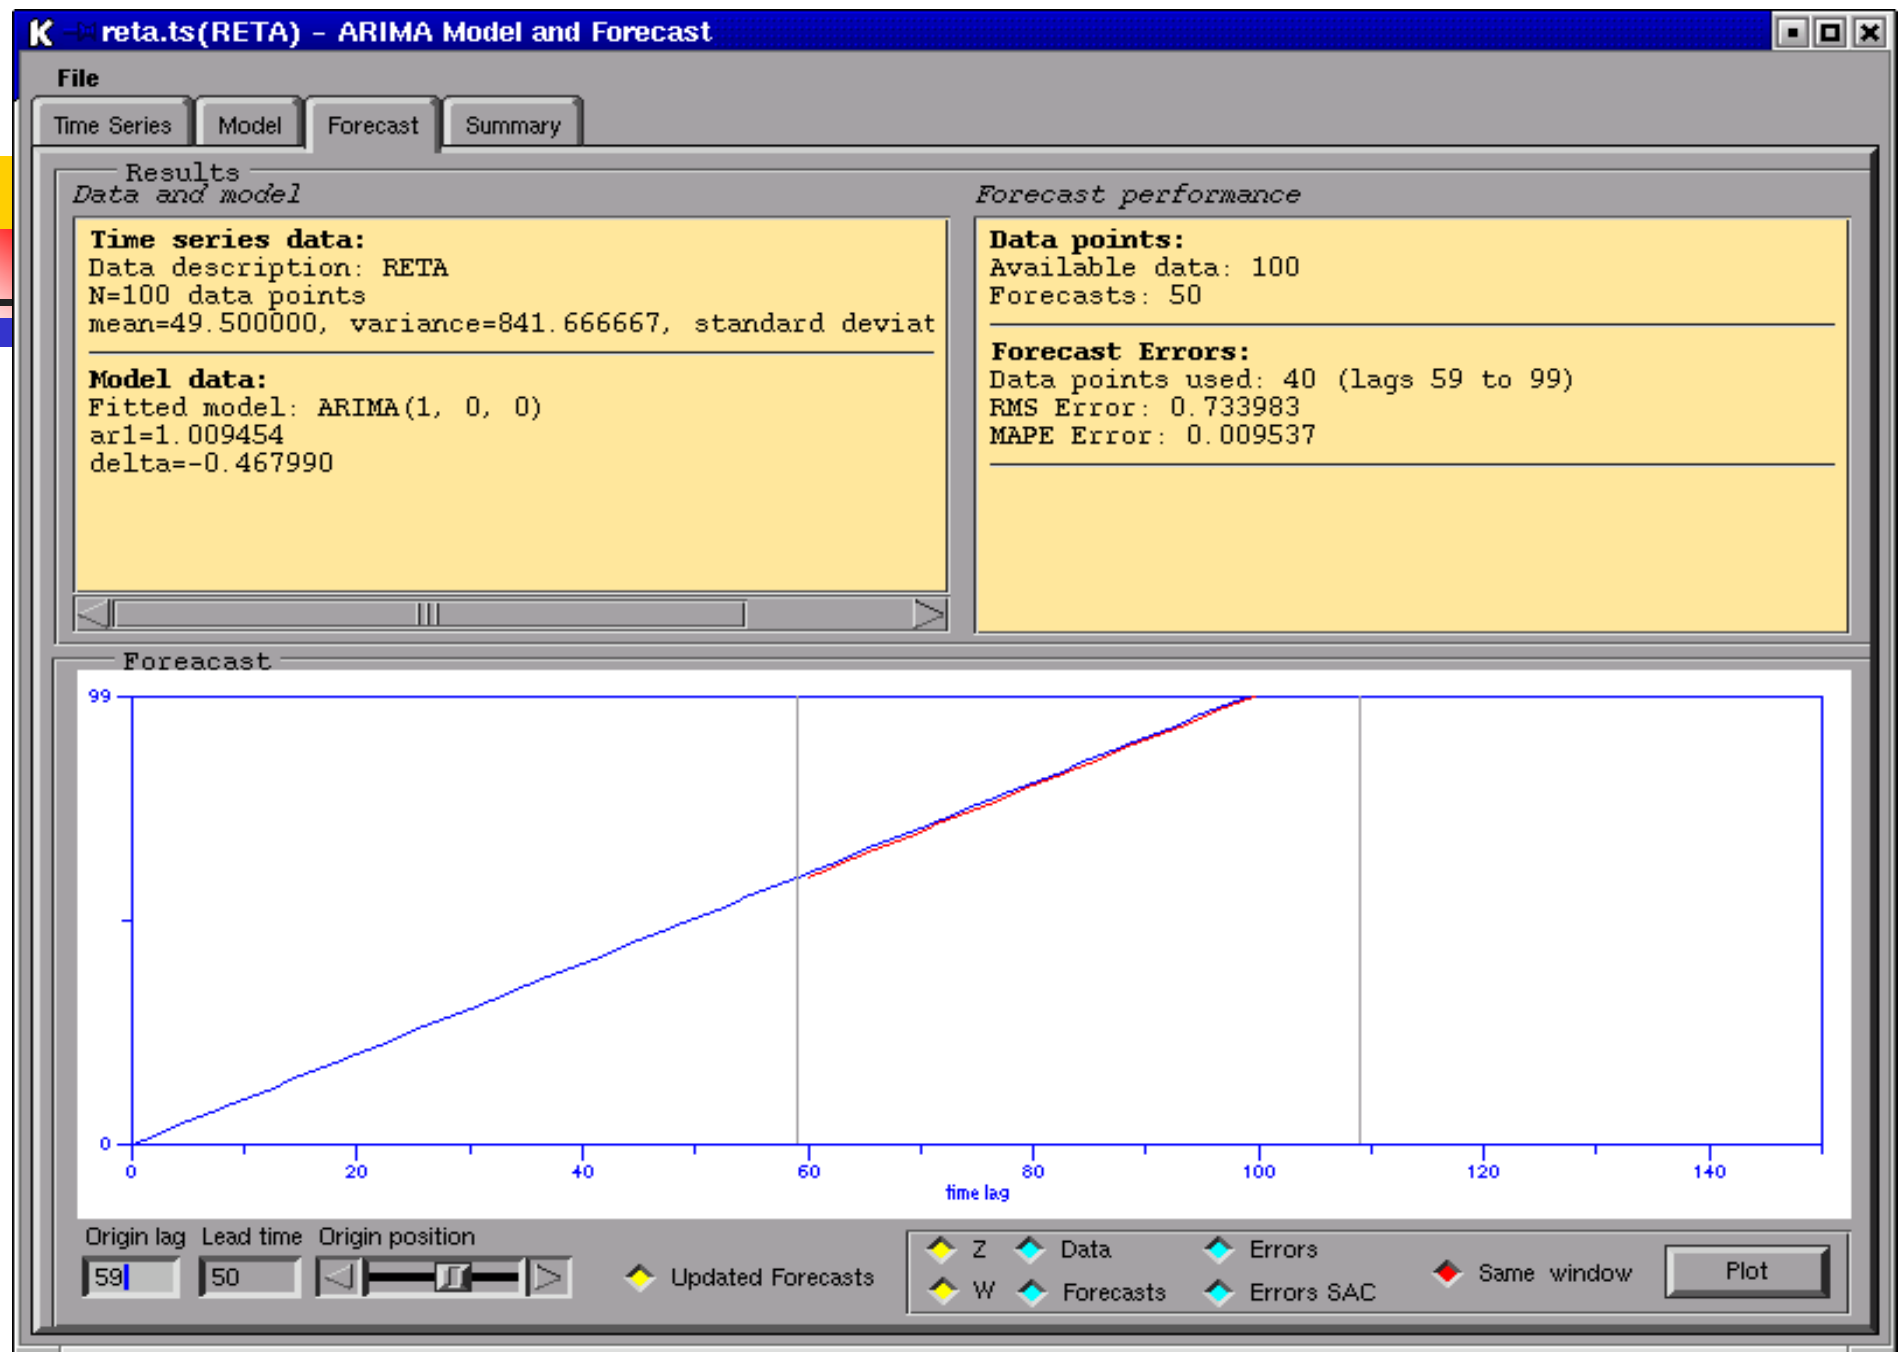
ARIMA(1,0,0) parameters final estimates
Roots of Characteristic Equations:
 AR(B) roots: z0=1.030928+0.000000j |z0|=1.030928
 ALL roots lie out of unit circle


Residuals(a)-100 values: mean=0.945896 var=0.8790
 a0=-2.925450 a1=-0.485000 a2=-0.455000 a3=-0.4250

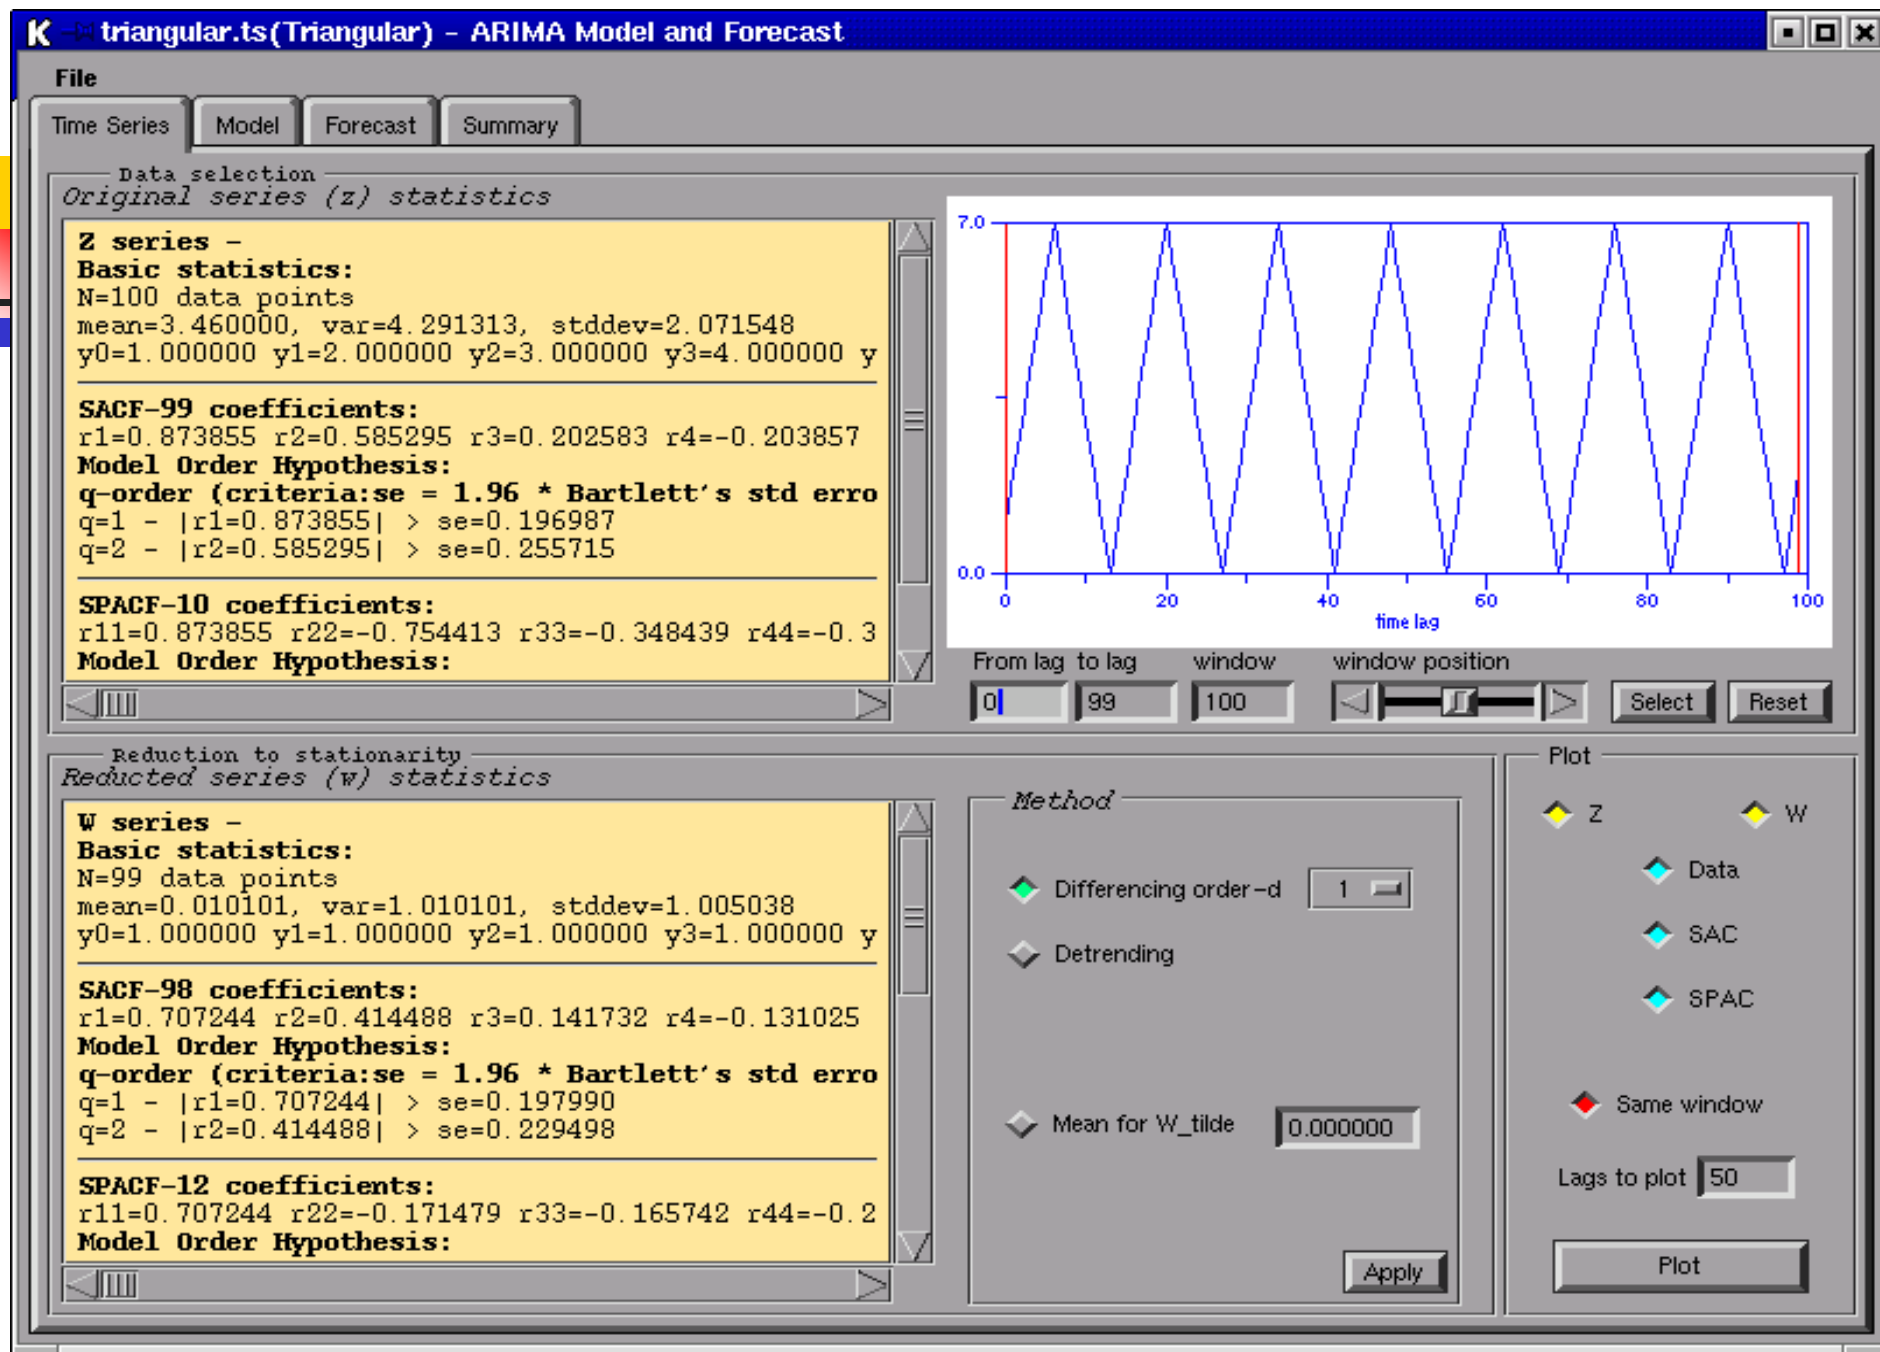
SACF of residuals (a)-99 coefficients used:
 r0=1.000000 r1=0.941849 r2=0.923458 r3=0.905077 r

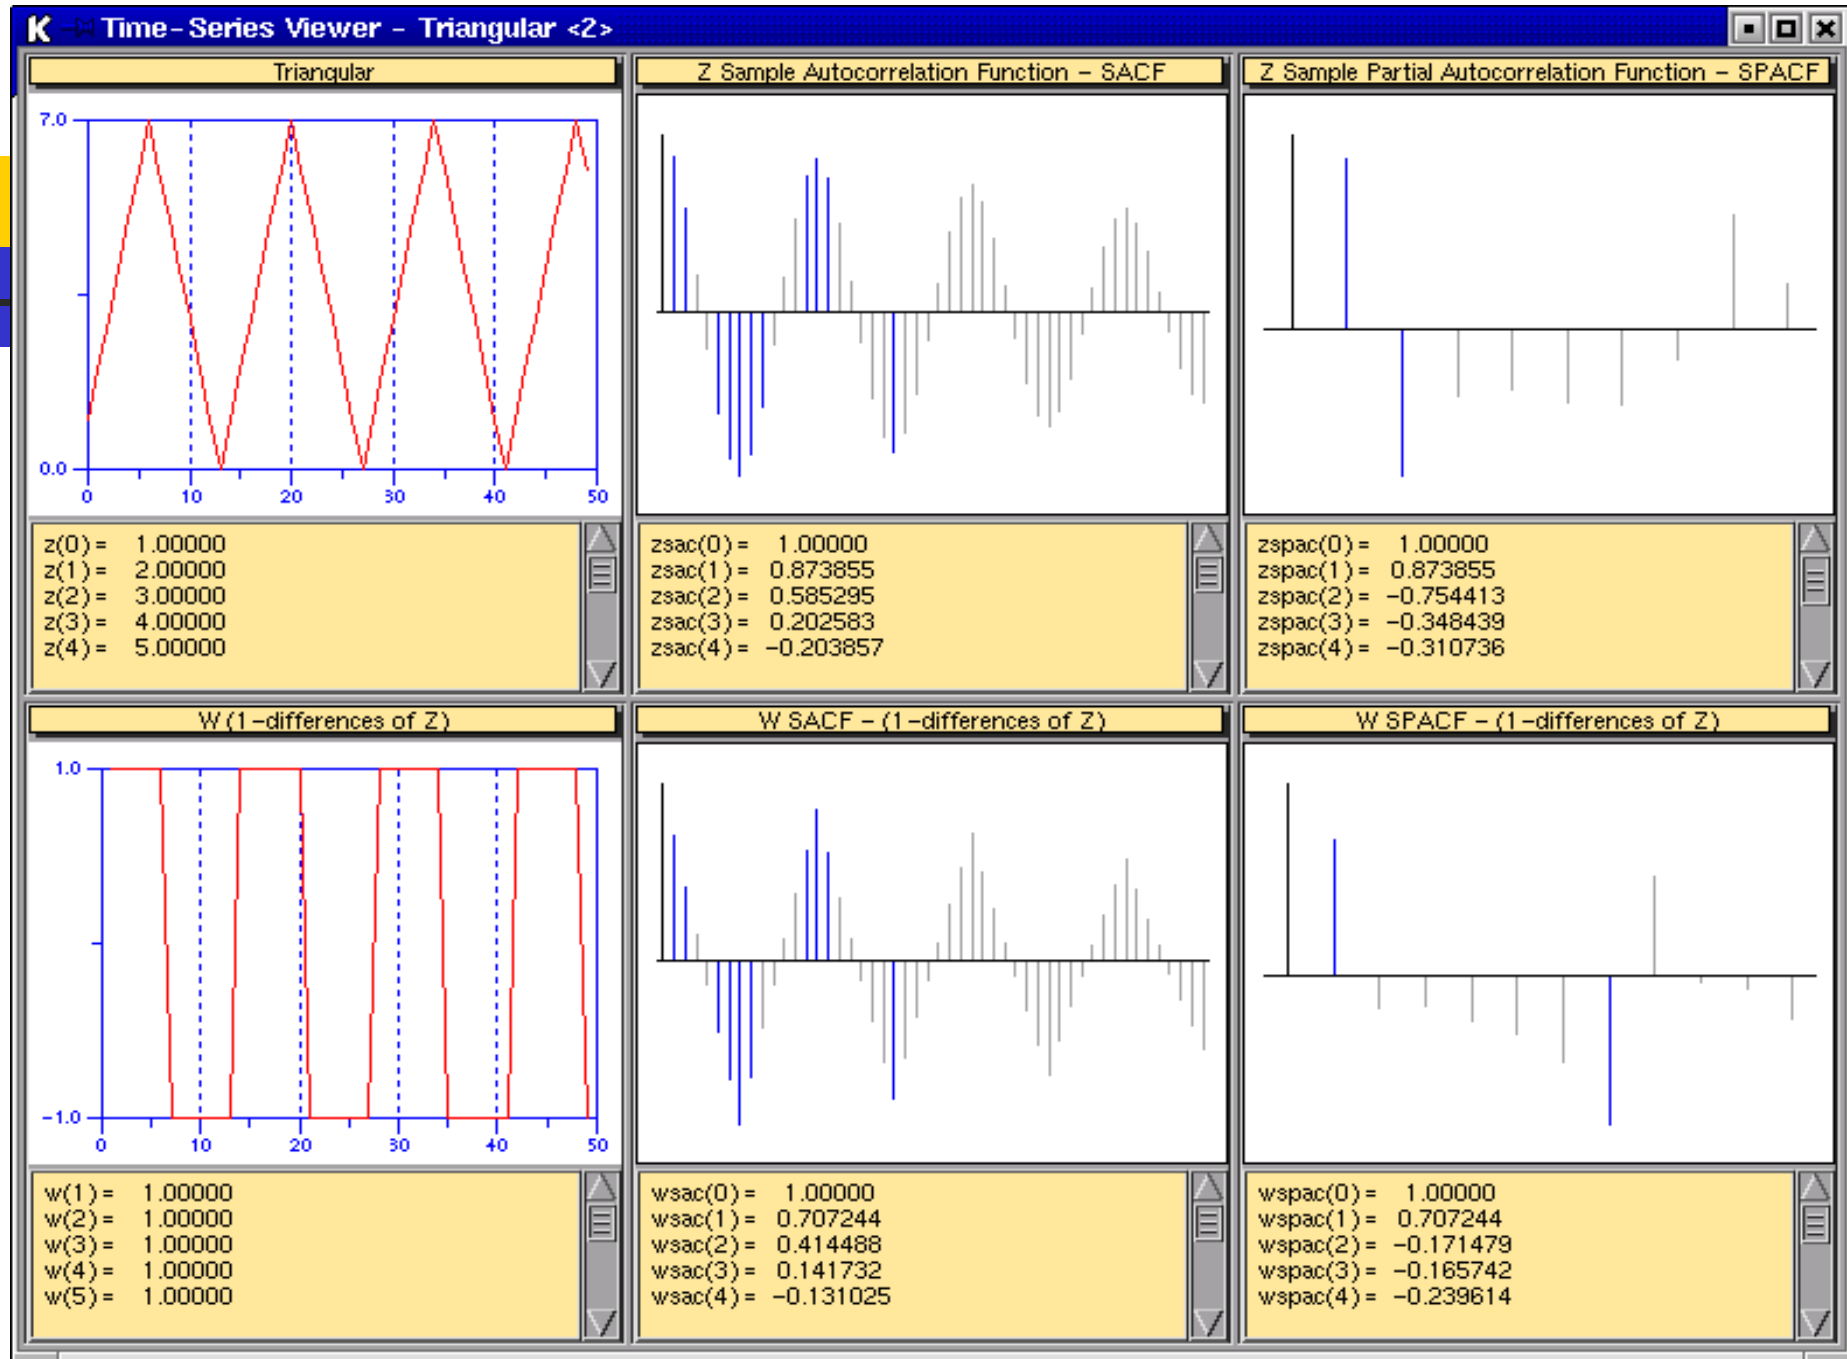
Checking criteria:
 Max. stderr for AC-1/sqrt(100)=0.100000
 Ljung-Box: Q=2229.566166











K triangular.ts (Triangular) - ARIMA Model and Forecast

File Time Series Model Forecast Summary

General ARIMA (Box-Jenkins) model

$$\phi_p(B) \phi_p(B^L) z_t = \delta + \theta_q(B) \theta(B^L) a_t$$

Realize process Lags 0 Save process as TS

Model orders

Autoregressive order -p 2 Moving average order -q 0 d 0

A.R. seasonal order -P 0 M.A. seasonal order -Q 0 L 0

Non-seasonal Seasonal Residuals

ϕ θ ϕ θ σ^2 0.302906

1.616980 -0.818226

Calculate

Constant δ 0.696311

Calculate

Estimation

Nonlinear (ML-Marquardt-Levenberg Solver)

☒ ULS (Marquardt-Levenberg) ☐ CLS

Estimate

Results

ARIMA(2,0,0) parameters final estimates
 Procedure: estimate procedure not called, default pa

w stats: n=100 w_mean=3.460000 var_w=4.291313
 stderr(w_mean)=0.086834 w_mean interval=[3.373166, 3.546834]
 ar1=1.616980 ar2=-0.818226
 AR(B) roots: z0=0.988101+0.495795j |z0|=1.105512 z1=0.988101-0.495795j |z1|=1.105512
 ALL roots lie out of unit circle
 delta=0.696311
 Sum of squares of a=30.842269
 var_a=0.302906
 Information criteria: AIC=-0.438023 BIC=-1.056178

Diagnostic checking

Num. of autocorrelations to use 100 Check model Plot residuals

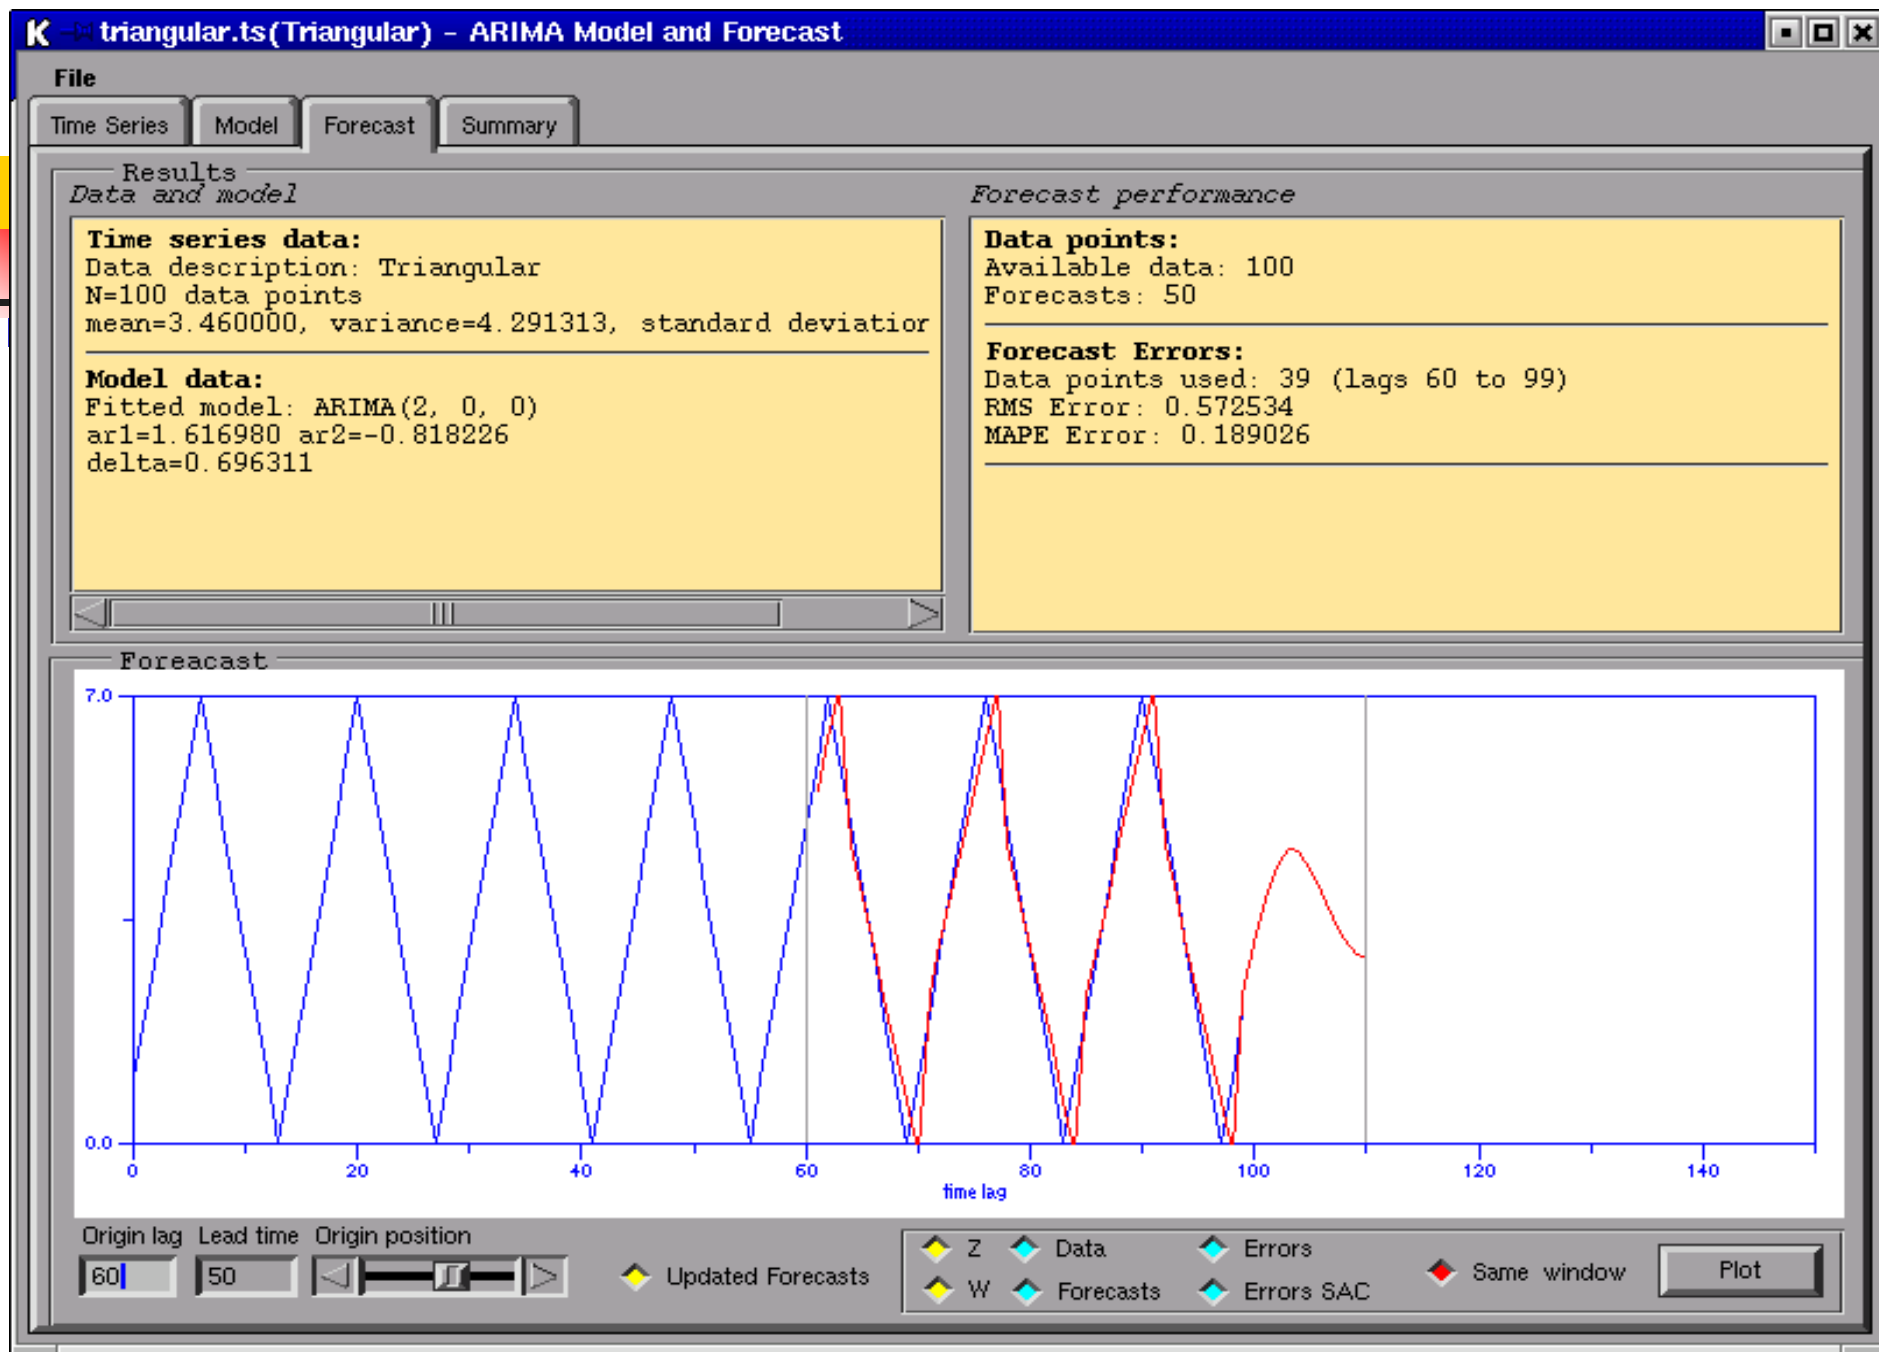
Results

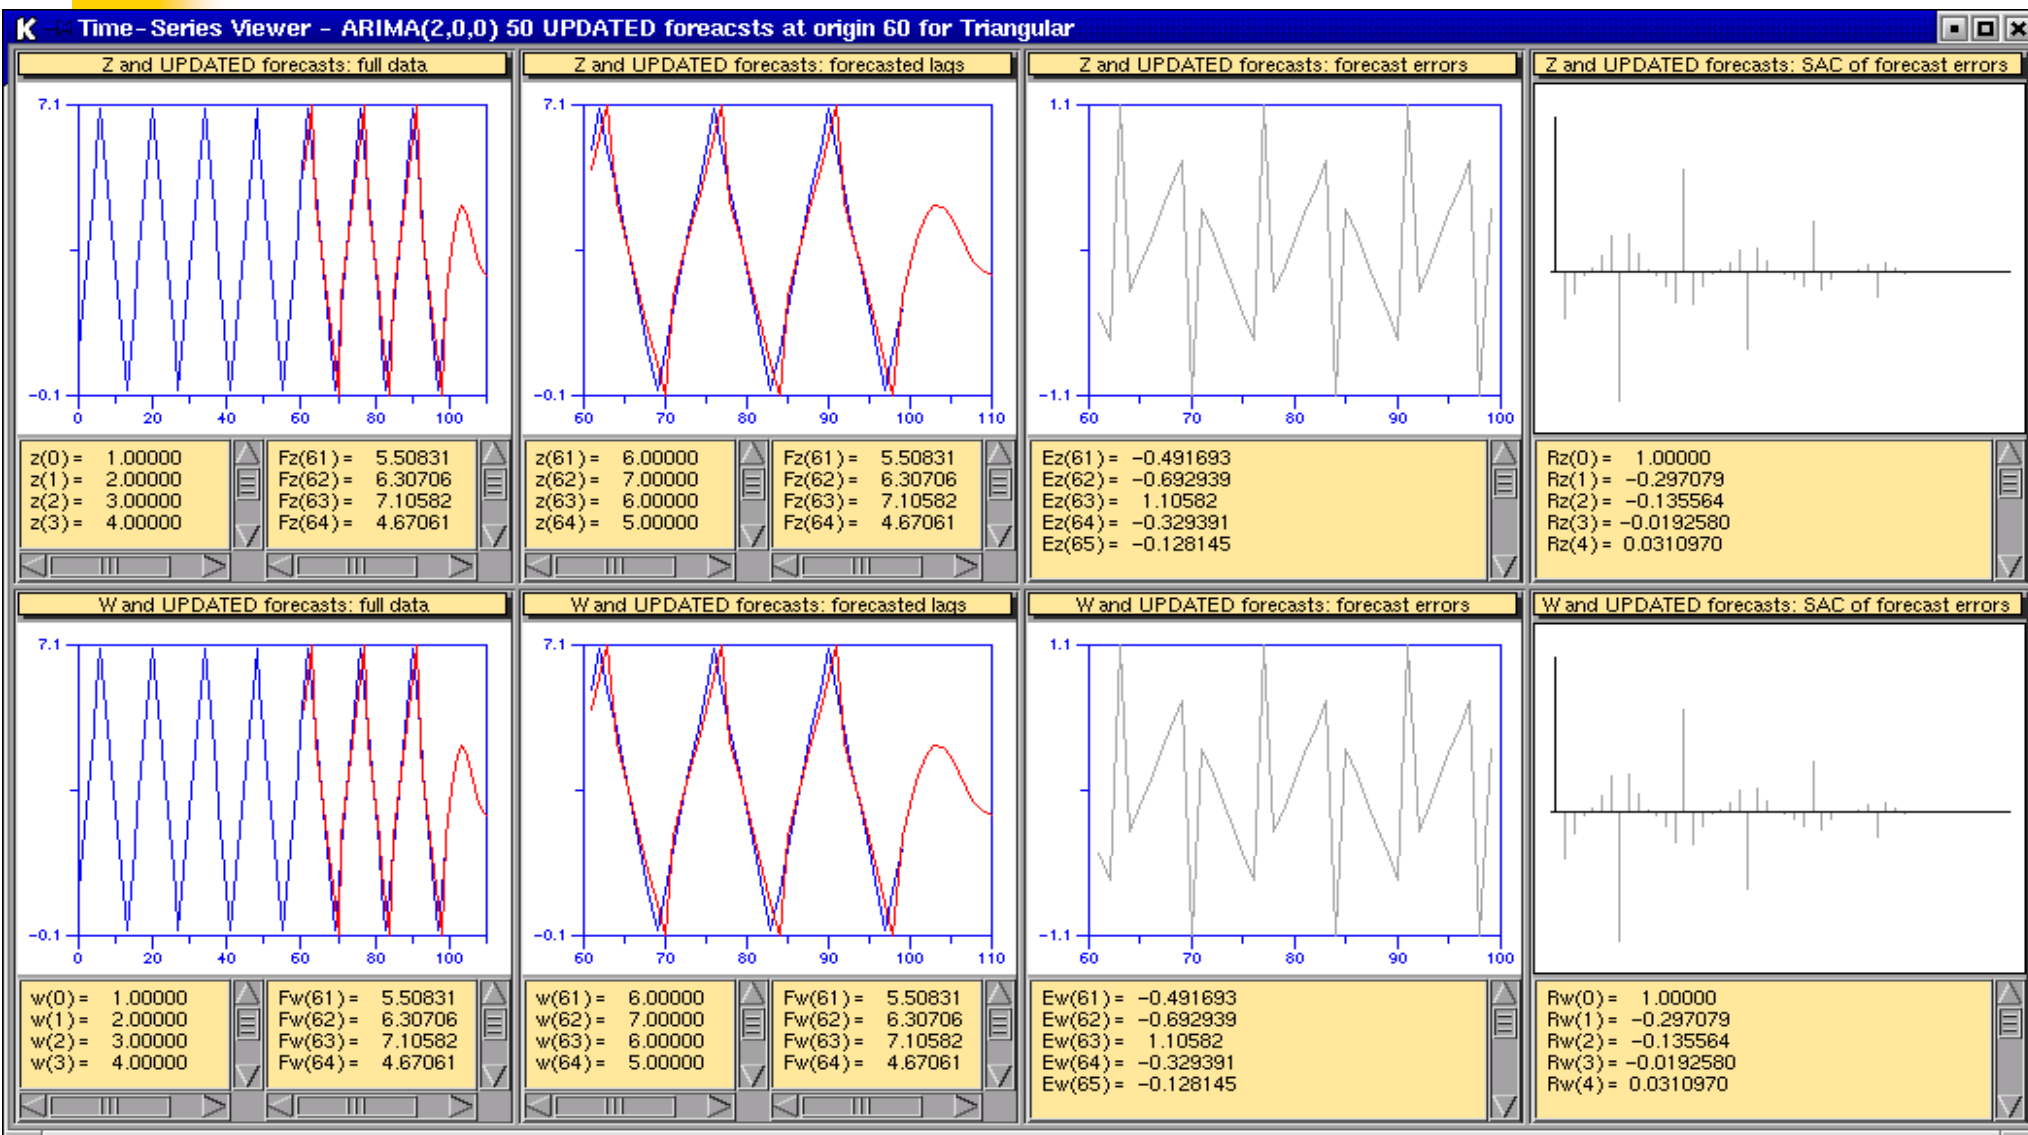
Roots of Characteristic Equations:
 AR(B) roots: z0=0.988101+0.495795j |z0|=1.105512
 ALL roots lie out of unit circle

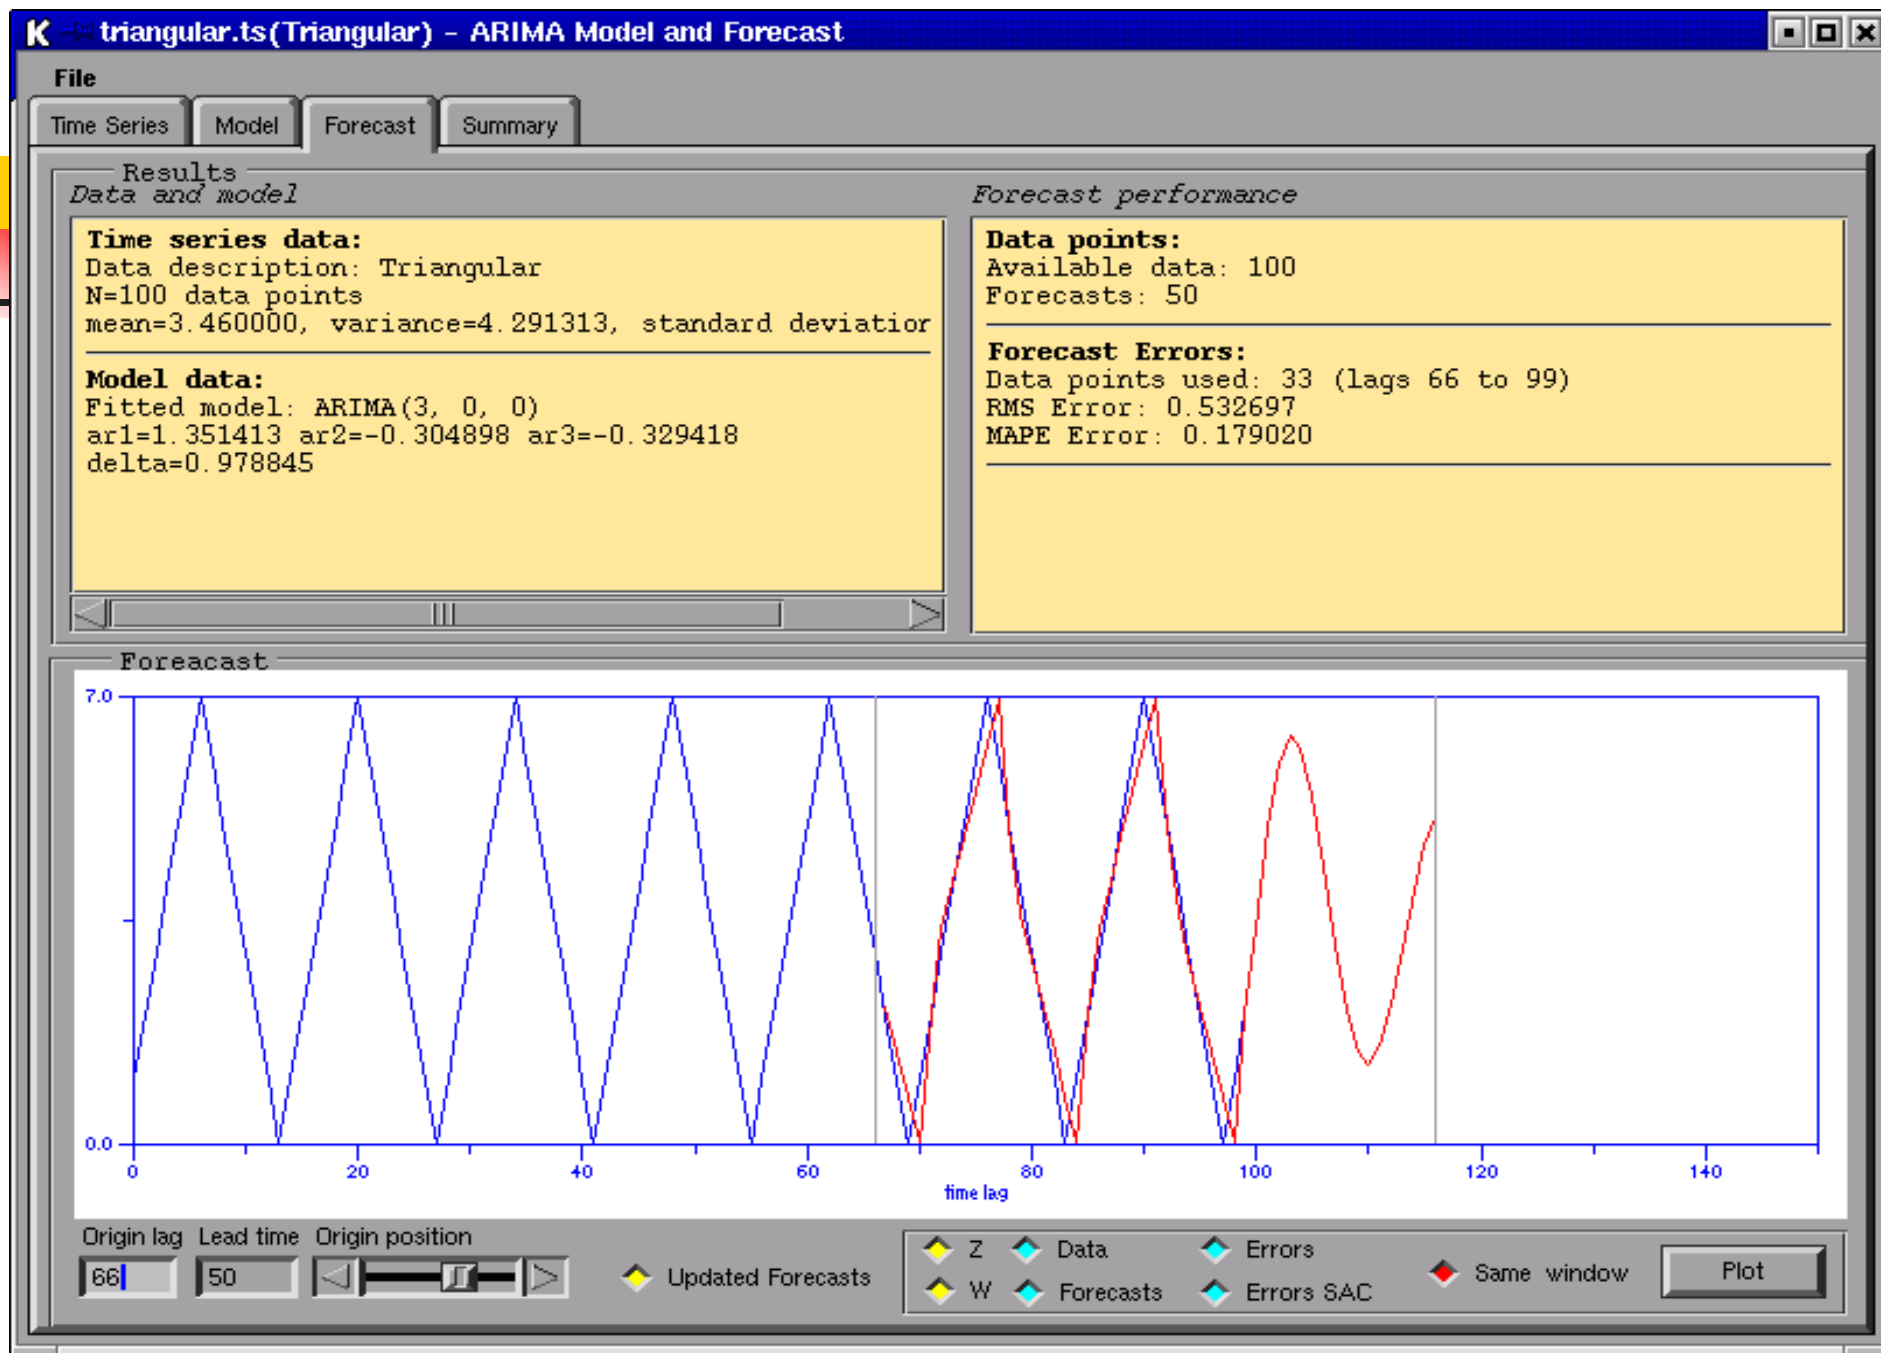
Residuals(a)-100 values: mean=0.012763 var=0.3029
 a0=0.004995 a1=0.482450 a2=-0.112045 a3=0.089201

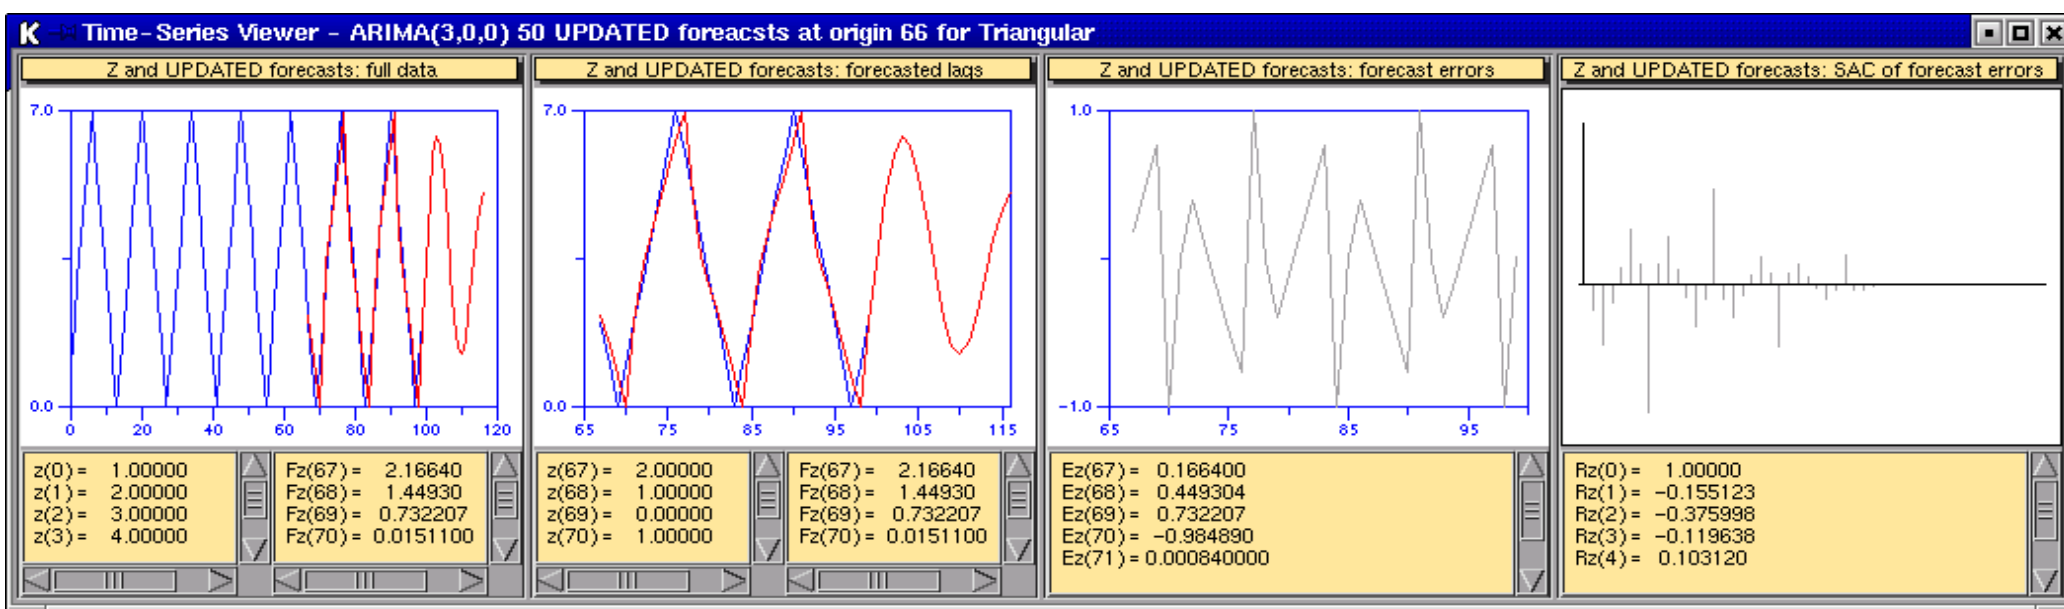

SACF of residuals (a)-100 coefficients used:
 r0=1.000000 r1=-0.280382 r2=-0.122539 r3=-0.03479

Checking criteria:
 Max. stderr for AC-1/sqrt(100)=0.100000
 Ljung-Box: Q=860.927871
 Information criteria: AIC=-0.438023 BIC=-1.056178









File

Time Series

Model

Forecast

Summary

Data selection

Original series (z) statistics

Z series -**Basic statistics:**

N=100 data points

mean=0.302983, var=0.020208, stddev=0.142155

y0=0.760938 y1=0.800000 y2=0.744267 y3=0.756952 y

SACF-99 coefficients:

r1=0.861505 r2=0.700135 r3=0.583616 r4=0.458742 r


Model Order Hypothesis:**q-order (criteria:se = 1.96 * Bartlett's std erro**

q=1 - |r1=0.861505| > se=0.196987

q=2 - |r2=0.700135| > se=0.277212

q=3 - |r3=0.583616| > se=0.321373

q=4 - |r4=0.458742| > se=0.345851

SPACF-99 coefficients:

From lag to lag

window

window position

0

99

100

Select

Reset

Reduction to stationarity

Reduced series (w) statistics

W series -**Basic statistics:**

N=100 data points

mean=0.302983, var=0.020208, stddev=0.142155

y0=0.760938 y1=0.800000 y2=0.744267 y3=0.756952 y

SACF-99 coefficients:

r1=0.861505 r2=0.700135 r3=0.583616 r4=0.458742 r

Model Order Hypothesis:**q-order (criteria:se = 1.96 * Bartlett's std erro**

q=1 - |r1=0.861505| > se=0.196987

q=2 - |r2=0.700135| > se=0.277212

q=3 - |r3=0.583616| > se=0.321373

q=4 - |r4=0.458742| > se=0.345851

SPACF-99 coefficients:**Method**☒ Differencing order-d

0

☐ Detrending☐ Mean for W_tilde

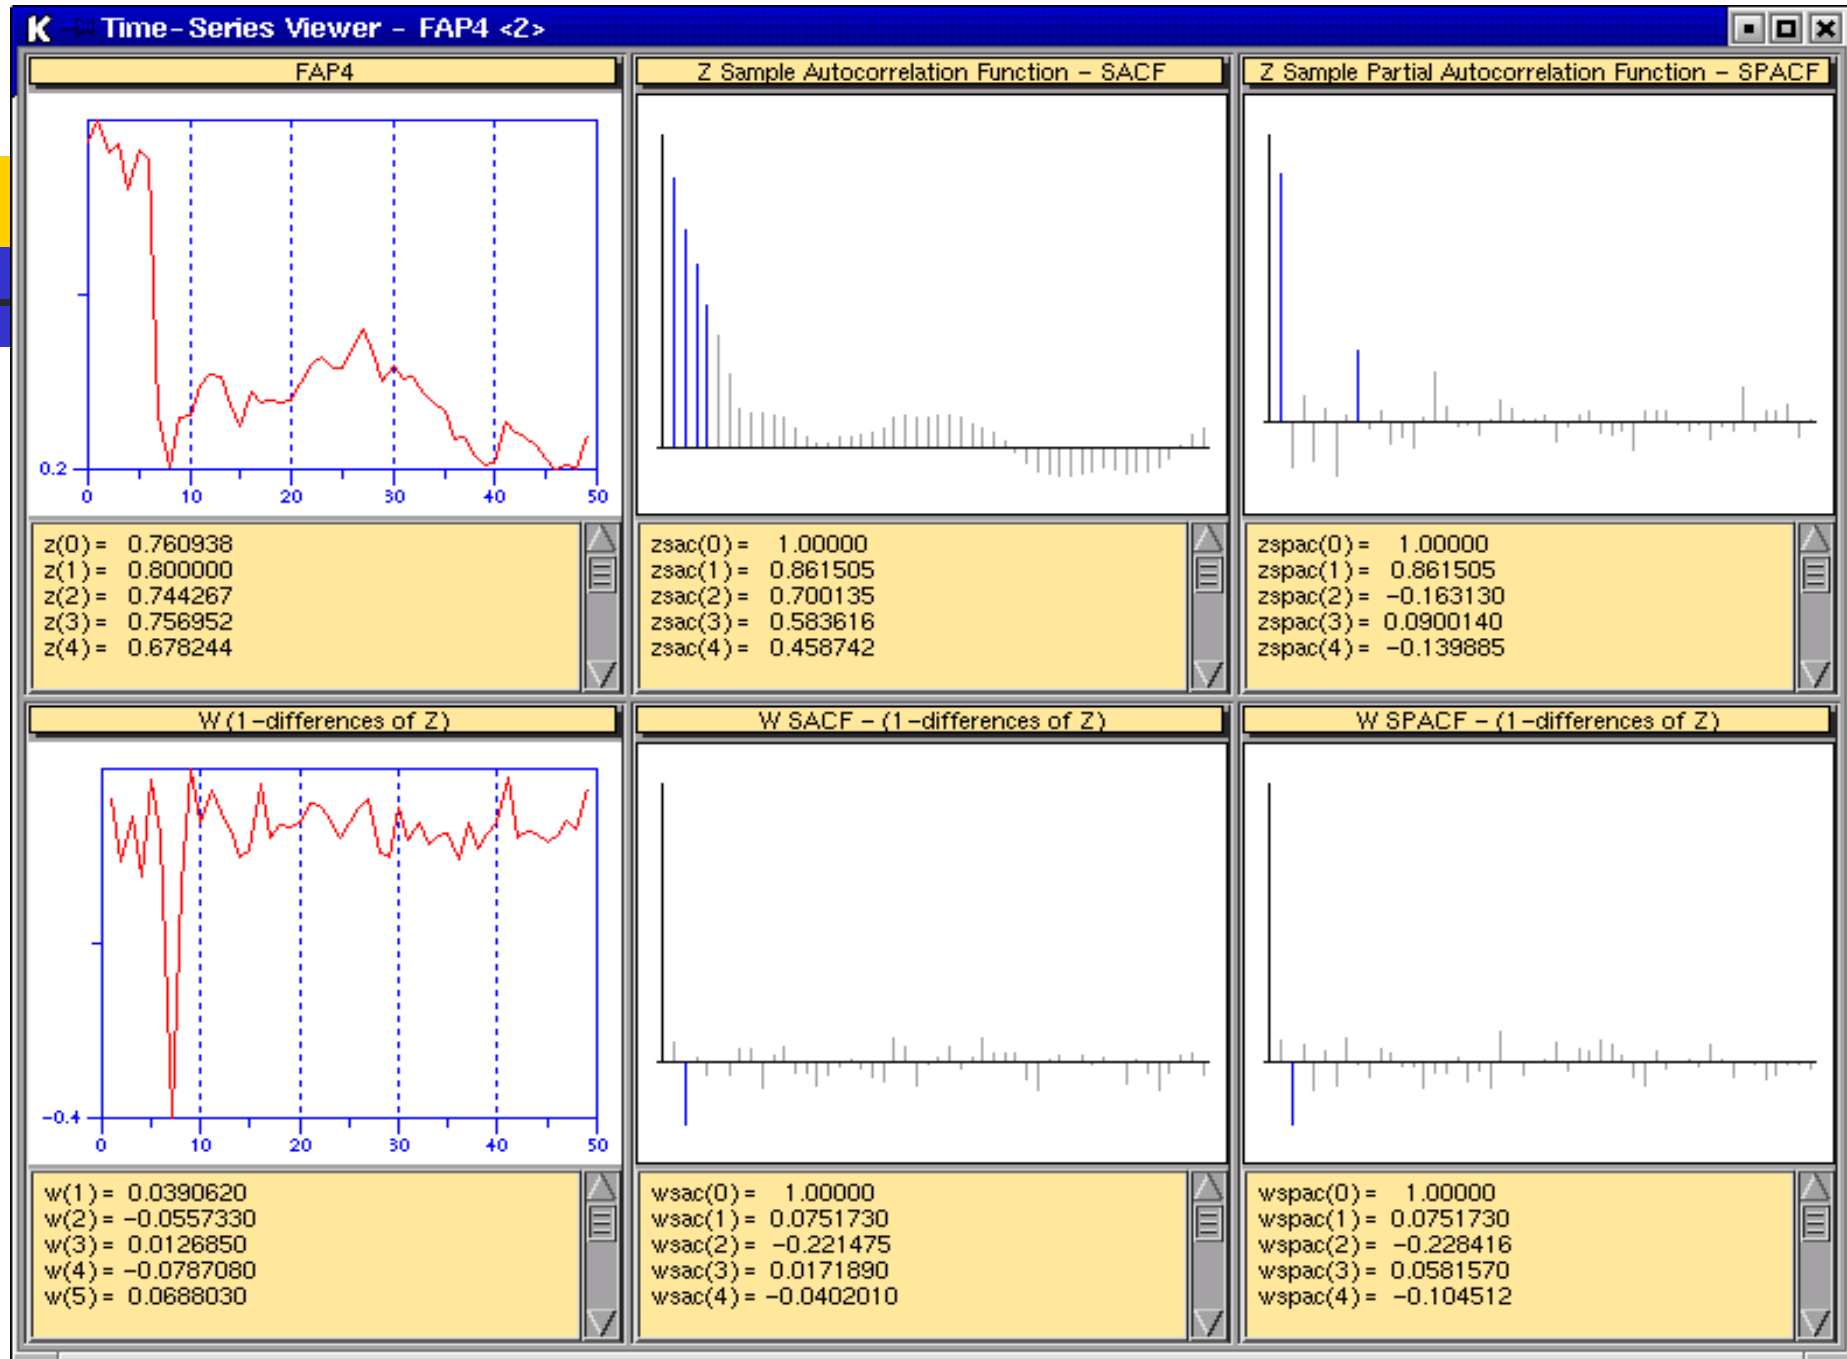
0.000000

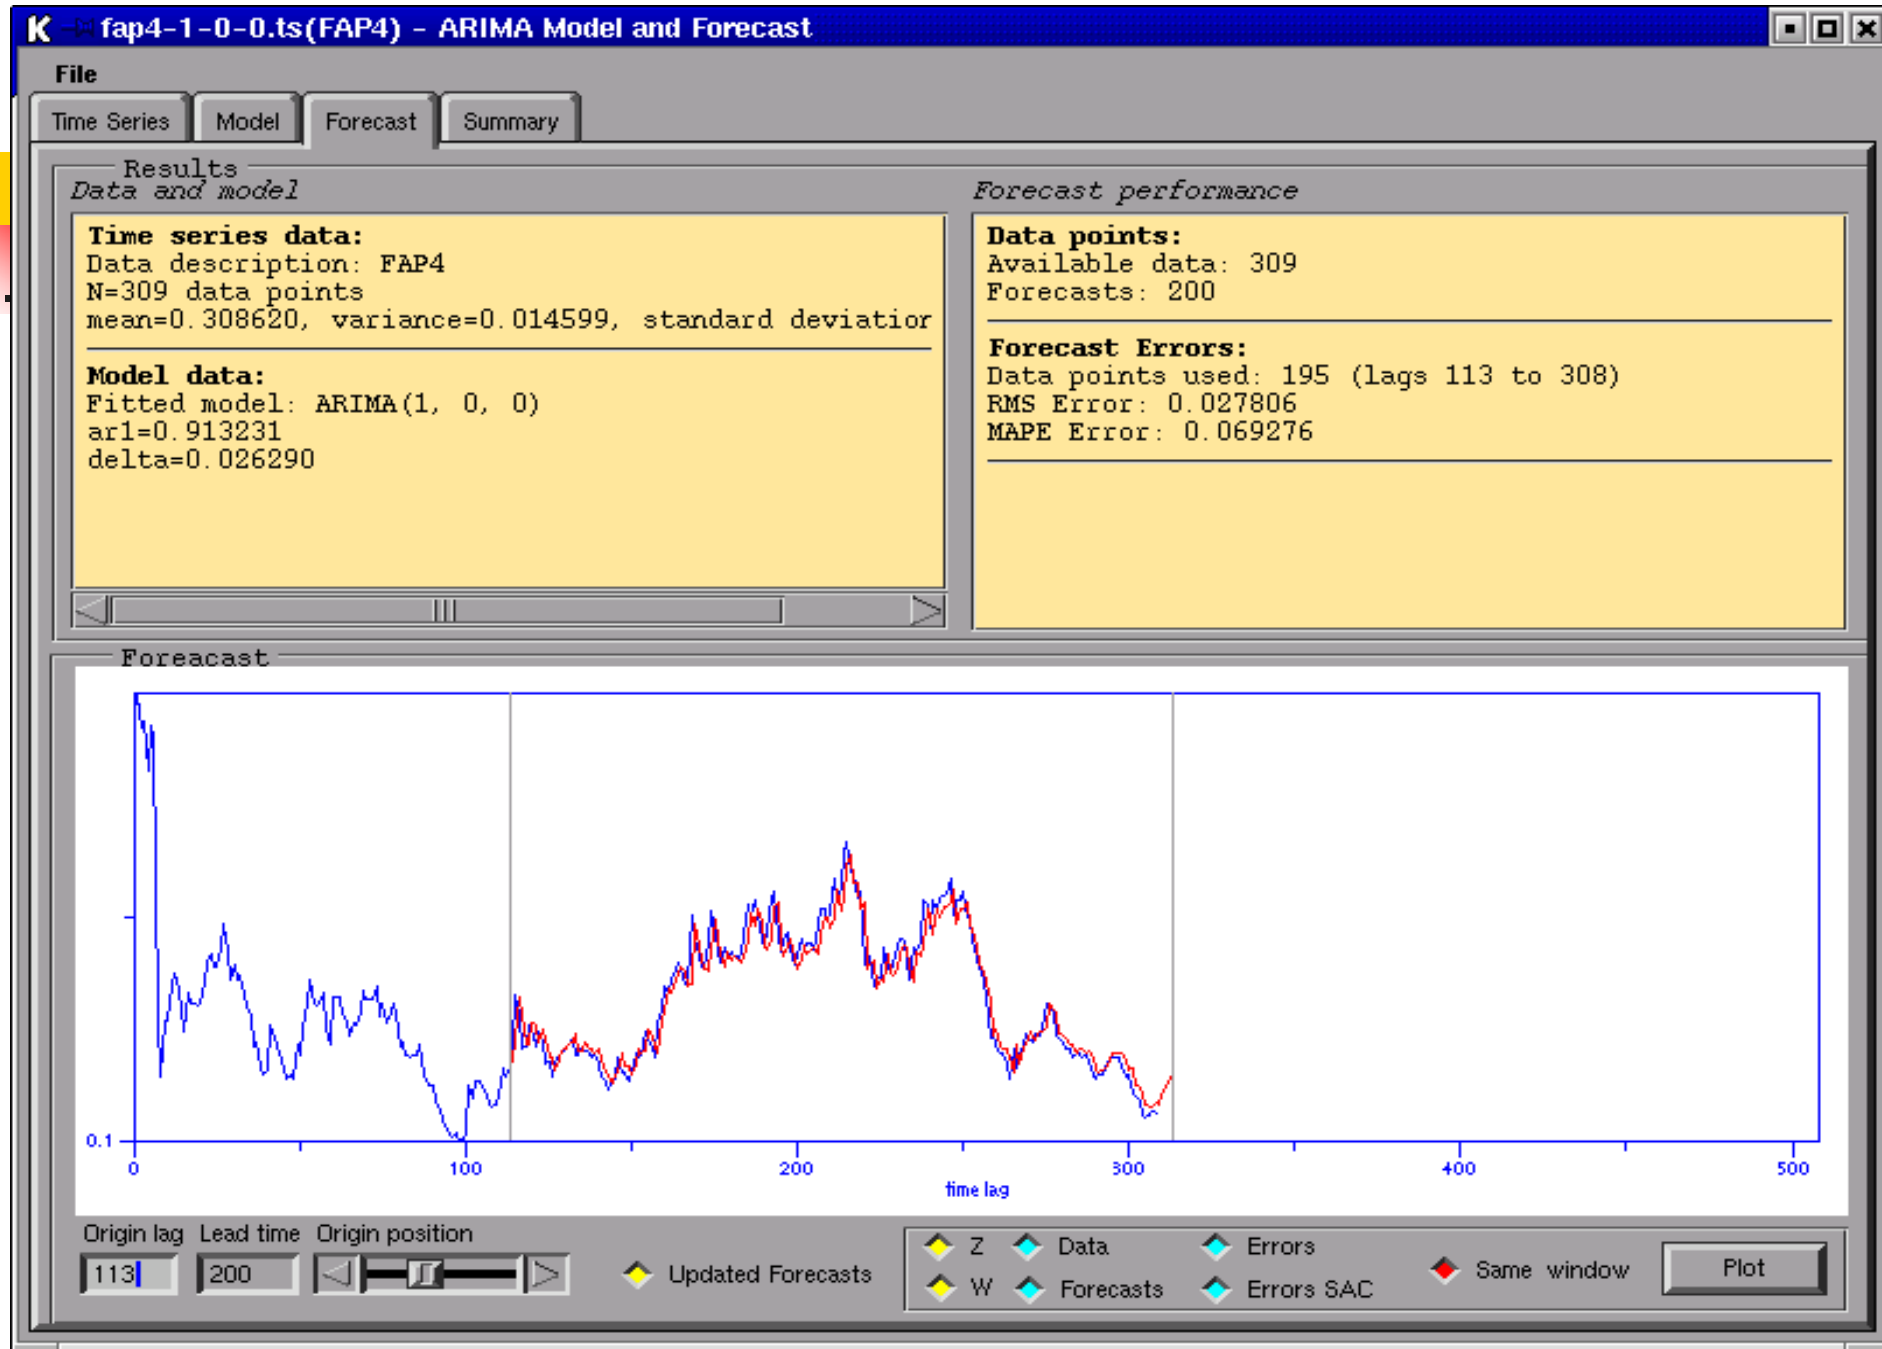
Apply

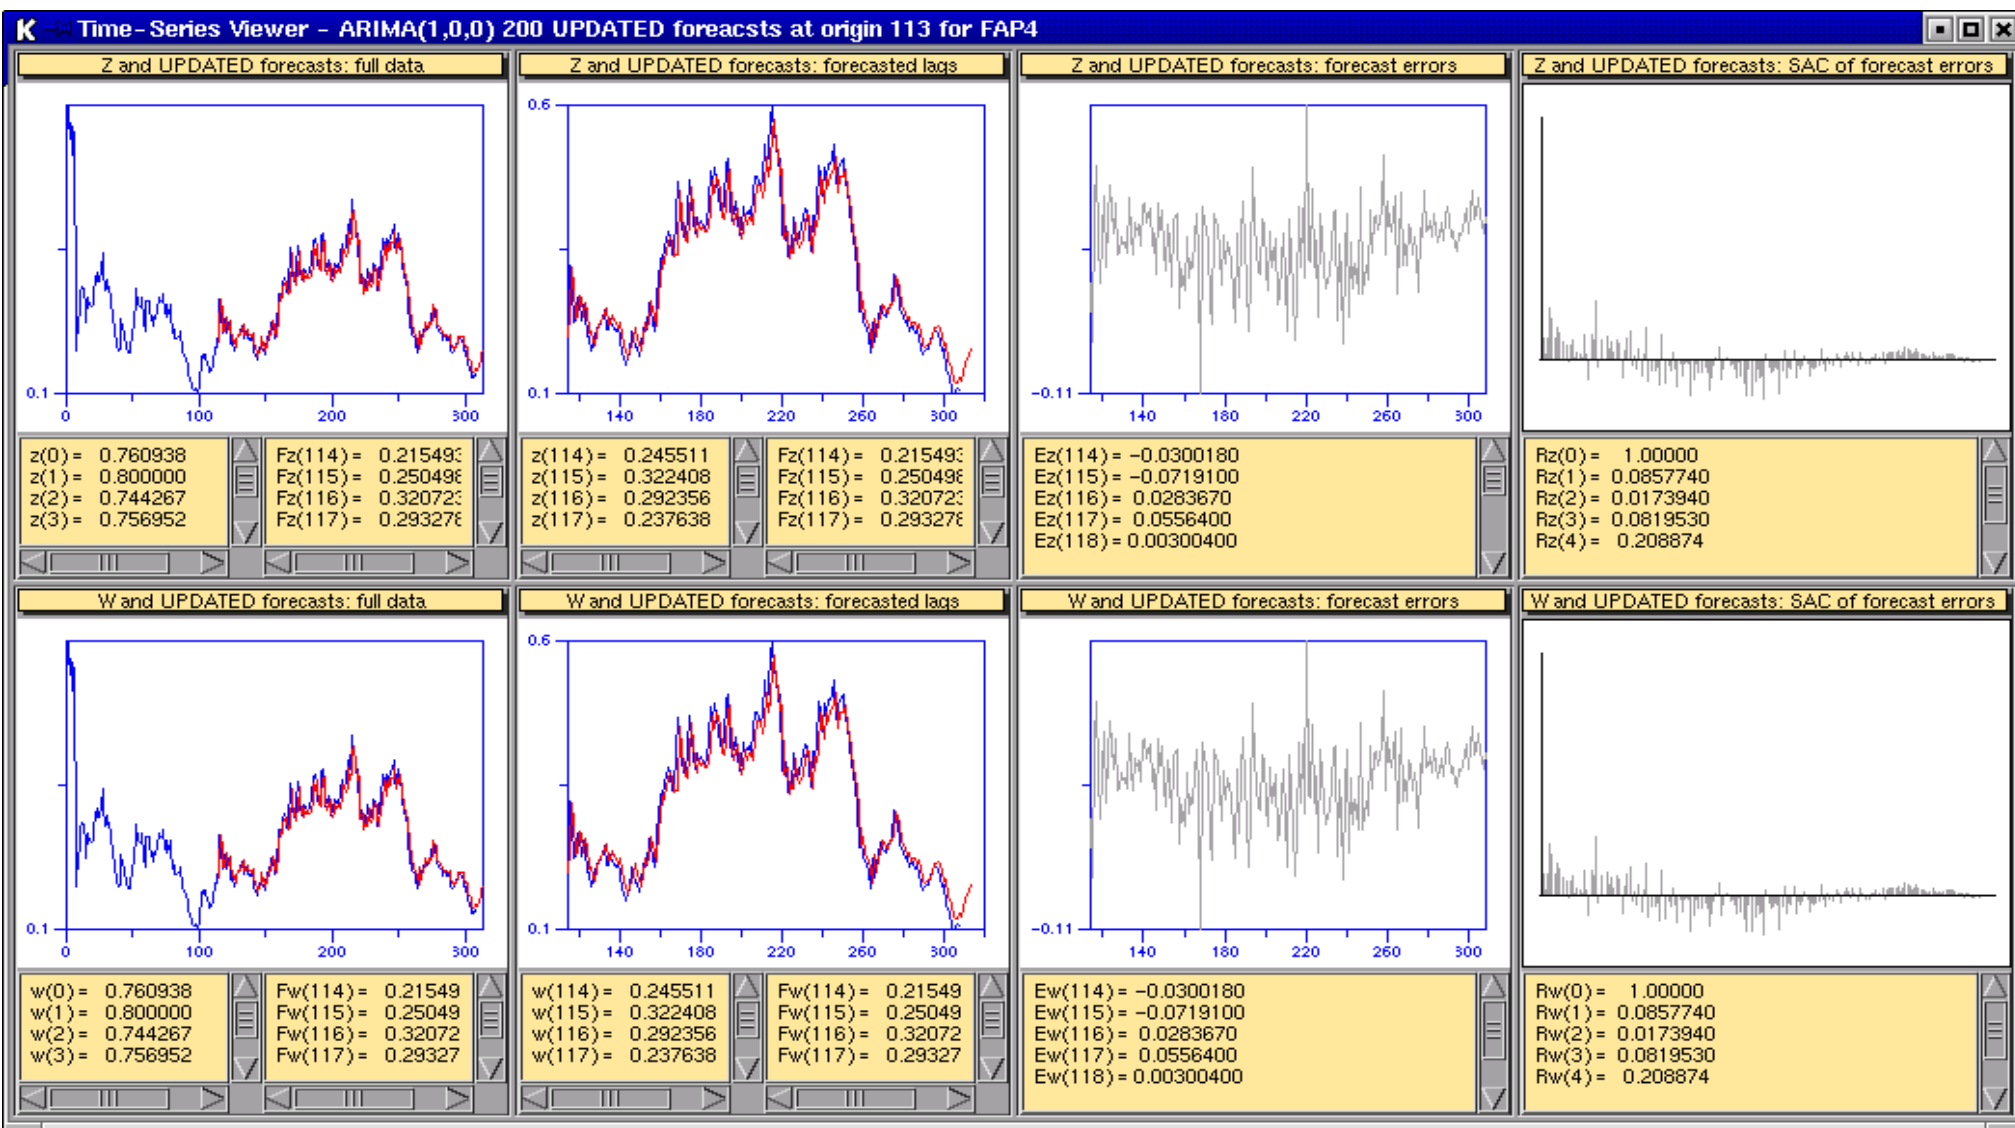
Plot☒ Z☒ W☒ Data☒ SAC☒ SPAC☒ Same window

Lags to plot 50

Plot









Preditor Neural para COFAP (FAP4)

➤ RMSE=0.039731 MAPE=0.086861



ARIMA(1,0,0) para COFAP (FAP4)

➤ RMSE=0.037596 MAPE=0.080951





Conclusão

■ Metodologia ARIMA

➤ Vantagens:

- Corpo de conhecimento bastante sólido.
- Permite calcular os erros e intervalos de confiança para a estimativa dos parâmetros.
- Relativa imunidade à amplitude dos dados.
- Necessita de pequena quantidade de dados (*backforecast*).

➤ Desvantagens

- Modelagem fundamentada na intervenção humana – experiência do modelador é determinante.
- Processos lineares.



Discussão

■ Identificação


- Automatização da Identificação dos modelos com redes neurais.
- Utilização da SACF e SPACF para a seleção de arquiteturas de preditores neurais.

Discussão

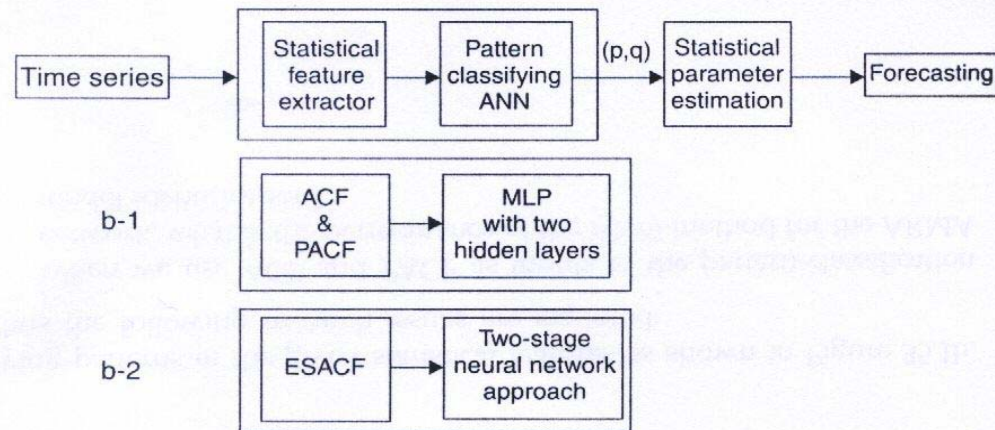
Figure 35.1

ARMA Modeling Procedure and Suggested ANN Approaches


a. Traditional ARMA Model Building Procedure



b. Automating the Identification Step by Adopting the ANN



c. Time Series Modeling and Prediction with an ANN





Discussão


- Estimação

- Estimação dos parâmetros com método de otimização global → Algoritmo genético (GA).



Refêrencias Bibliográficas

- “Time Series Analysis – Forecasting and Control”, G.P.Box, G.M.Jenkins, G.C.Reisnel, 3rd edition 1994
- “Applied Time Series Analysis”, Charles R. Nelson, 1973
- “Performance of Neural Networks in Managerial Forecasting”, W.C.Jhee and J.K. Lee, *Intelligent Systems in Accounting, Finance and Management*, April 1993



Fábio Daros de Freitas

www: www.inf.ufes.br/~freitas

E-mail: freitas@computer.org

2003

